Ciclos económicos reales y contabilidad del ciclo

Macroeconomía avanzada

ITAM, Otoño 2026

Semanas 7–8

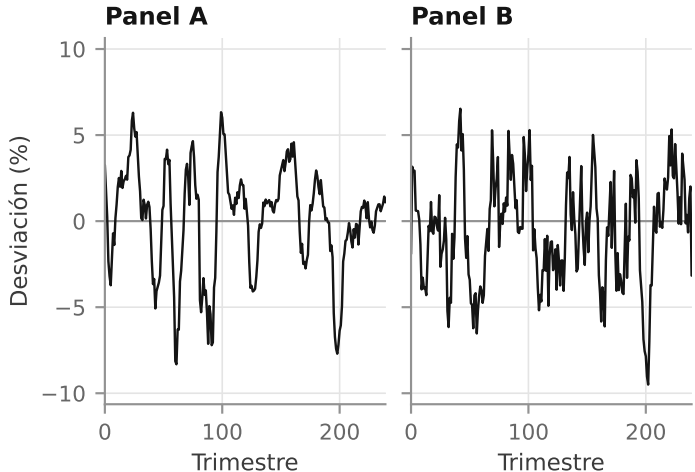
Introducción

Con los estados de la naturaleza ya sabemos cómo introducir riesgo/incertidumbre para analizar su impacto en una economía agregada. Vamos a aplicar ese conocimiento teórico para estudiar las características de un ciclo "típico" frente a fenómenos cíclicos atípicos, como grandes depresiones y recesiones, o incluso la reacción de las economías ante una pandemia. En concreto vamos a:

- Mostrar cómo un ciclo se parece a un proceso estocástico, como onservó Slutsky
- Mostrar cómo el modelo de ciclos económicos reales reproduce (o no) los segundos momentos del ciclo
- Mostrar cómo todo ciclo puede descomponerse de forma similar a como hacemos contabilidad de crecimiento

El ciclo puede ser fruto del azar: Slutsky

Uno de los dos paneles es el componente cíclico (filtro de Hamilton) del PIB de EUA; el otro, una media móvil de 8 trimestres de puro ruido blanco. ¿Cuál es cuál?



Juglar, Kondrátiev y lo que se lleva el filtro

El nombre viene de Clément Juglar (1862), que documentó una recurrencia de **prosperidad** → **crisis** → **liquidación** de 7 a 11 años y la atribuyó al crédito. Slutsky (1927) y Frisch (1933) sustituyeron esa recurrencia por **choques** más **mecanismos de transmisión**: una media móvil sobre ruido blanco basta para producir ciclos "indistinguibles" de los reales.

El acertijo de los datos

Si cambiar la ventana de la media móvil cambia el "periodo" del ciclo, ¿cuánto de Juglar y de Kondrátiev es un artefacto del filtrado? ¿Cuánto depende de usar HP o Hamilton?

La galería histórica completa —Jevons y las manchas solares, Kondrátiev, Mitchell y el comité del NBER— y la receta en ocho líneas están en el apéndice.

Kydland y Prescott: el ciclo se resume en segundos momentos

La caracterización moderna del ciclo implica que las series económicas son procesos estocásticos. Kydland y Prescott (1982) argumentan que los segundos momentos de dichas series ofrecen una caracterización parsimoniosa del ciclo. En el fondo se refieren al **correlograma** y **correlograma cruzado**, dos herramientas de identificación clásicas en la literatura de series temporales.

- Tradicionalmente la literatura reporta la desviación estándar de series como: PIB, consumo, inversión, empleo, horas de trabajo o productividad
- Una medida particularmente popular es la desviación estándar de una variable de interés respecto de la del PIB o **volatilidad relativa**
- Otra medida que típicamente se reporta es la correlación de una variable de interés con el PIB

Una gran parte de la agenda de investigación de esta literatura se ha centrado en documentar segundos momentos en los datos y ver si el MNC, aumentado con incertidumbre y dotado de ciertos mecanismos de transmisión, es capaz de reproducir los momentos encontrados en los datos.

Los momentos de EUA: la vara de medir

La siguiente tabla resume los momentos cíclicos de la economía de EUA sobre el agregado unisectorial: el objeto que nuestro modelo de un solo sector intentará replicar. La comparación con el filtro HP queda en el Módulo 1 de Canvas; la versión multi-país la van a construir ustedes en el siguiente ejercicio.

	y	c	i	e	h/e	ls	a
EUA, filtro de Hamilton ($h = 8, p = 4$), agregado unisectorial							
σ_x/σ_y	—	0.68	1.98	0.62	0.19	0.40	0.56
corr(x, y)	—	0.87	0.92	0.32	0.58	−0.26	0.55
corr(x, a)	0.55	0.77	0.62	−0.31	0.27	−0.32	—

Examinemos si choques aleatorios de productividad, sujetos al mecanismo de transmisión de suavizamiento intertemporal del consumo, pueden reproducir estos hechos empíricos del ciclo económico.

Cuaderno acompañante: `T02_B_rbc_dynare_local`, celda 9 (modelo vs. EUA y México, filtro HP; no genera esta tabla de Hamilton)

El modelo de ciclos económicos reales

Vamos a desarrollar una versión empírica del modelo neoclásico que incorpora crecimiento a largo plazo de la población y la productividad, además de una elasticidad de sustitución intertemporal del ocio flexible, a través del siguiente problema de planificación social:

$$\max_{l_t, c_t, k_t} E_0 \left\{ \sum_{t=0}^{\infty} N_t \beta^t \left[\log(c_t) + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

sujeto a:

$$C_t + K_t - (1-\delta) K_{t-1} = A_t K_{t-1}^{\alpha} L_t^{1-\alpha}$$

donde escribimos la productividad total de los factores como:

$$A_t = (1+\hat{A})^t e^{a_t} A_0$$

$$a_{t+1} = \rho_a a_t + \epsilon_{at+1}$$

$\epsilon_{at+1} \longrightarrow N(0, \sigma_a^2)$ y $A_0 > 0$.

El modelo deflactado

Deflactamos el modelo para que pueda computarse local (log-linealización) o globalmente (programación dinámica), resultando en:

$$\max_{c_t, l_t, k_t} E_0 \left\{ \sum_{t=0}^{\infty} \tilde{\beta}^t \left[\log(c_t) + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

donde $\tilde{\beta} = \beta(1+\hat{N})$, sujeto a la restricción de recursos deflactada por el crecimiento de la economía en la senda de crecimiento balanceado

$$c_t + (1+g)k_t - (1-\delta)k_{t-1} = e^{a_t} k_{t-1}^{\alpha} l_t^{1-\alpha}$$

donde

$$a_{t+1} = \rho_a a_t + \epsilon_{at+1}$$

Las tres condiciones de equilibrio

Eficiencia intratemporal

$$\mu(1-l_t^*)^{-\nu}c_t^* = (1-\alpha)e^{a_t}(k_{t-1}^*)^{\alpha}(l_t^*)^{-\alpha}$$

Eficiencia intertemporal

$$E_t\left\{\left[\alpha e^{a_{t+1}}(k_t^*)^{\alpha-1}(l_{t+1}^*)^{1-\alpha}+1-\delta\right]\frac{\beta(1+\hat{N})c_t^*}{c_{t+1}^*}\right\}=1+g$$

Esta restricción también puede escribirse en términos del crecimiento del ingreso por habitante $(1+\tilde{g})=\frac{1+g}{1+\hat{N}}$ de tal forma que

$$E_t\left\{\left[\alpha e^{a_{t+1}}(k_t^*)^{\alpha-1}(l_{t+1}^*)^{1-\alpha}+1-\delta\right]\frac{\beta c_t^*}{c_{t+1}^*}\right\}=1+\tilde{g}$$

Condición de factibilidad

$$c_t^*+(1+g)k_t^*-(1-\delta)k_{t-1}^*=e^{a_t}(k_{t-1}^*)^{\alpha}(l_t^*)^{1-\alpha}$$

Solución por log-linealización

Eficiencia intratemporal

$$\tilde{c}_t + \left(\alpha + \nu \frac{l}{1-l}\right) \tilde{l}_t - \alpha \tilde{k}_{t-1} - a_t = 0$$

Eficiencia intertemporal

$$E_t \tilde{c}_{t+1} - \tilde{c}_t - \left[1 - \frac{\beta(1-\delta)}{1+\tilde{g}}\right] E_t \left\{ \left[a_{t+1} + (1-\alpha) \left(\tilde{l}_{t+1} - \tilde{k}_t \right) \right] \right\} = 0$$

Condición de factibilidad

$$\frac{c}{y}\tilde{c}_t + (1+g)\frac{k}{y}\tilde{k}_t - (1-\delta)\frac{k}{y}\tilde{k}_{t-1} - a_t - \alpha \tilde{k}_{t-1} - (1-\alpha)\tilde{l}_t = 0$$

Método de coeficientes indeterminados

Como vimos en el mazo A2, expresamos el sistema de ecuaciones que depende de los parámetros del modelo, de las variables del modelo en la senda de crecimiento balanceado y de los coeficientes indeterminados que surgen de sustituir las reglas de decisión log-lineales:

$$\tilde{k}_t = \psi_{kA} a_t + \psi_{kk} \tilde{k}_{t-1}$$

$$\tilde{c}_t = \psi_{cA} a_t + \psi_{ck} \tilde{k}_{t-1}$$

$$\tilde{l}_t = \psi_{lA} a_t + \psi_{lk} \tilde{k}_{t-1}$$

en el sistema log-linealizado. Esto nos lleva a los siguientes pasos:

- **Calibración** para que la economía se parezca en la senda de crecimiento balanceado al país que queramos estudiar
- **Simulación** para poder examinar mecanismos de transmisión y comparar al modelo con los datos

De calibrar a estimar: los datos también pueden elegir los parámetros

La calibración fija los parámetros con momentos de la senda de crecimiento balanceado. La alternativa es **estimarlos** con las mismas series que el modelo pretende explicar — solo conceptual por ahora; la teoría llega en el bloque econométrico del curso:

- **Máxima verosimilitud**: la solución log-lineal es un sistema de espacio de estados; el filtro de Kalman entrega la verosimilitud de los datos y `puremacro.dsge` permite estimar los parámetros
- **Métodos bayesianos**: priors sobre los parámetros $\times$ verosimilitud $\rightarrow$ distribución posterior, aproximada por MCMC; es el estándar actual para modelos DSGE
- **Business Cycle Accounting** (Chari, Kehoe y McGrattan, 2007): en vez de estimar parámetros, mide las "cuñas" que harían que las condiciones de equilibrio se cumplieran exactamente en los datos, y pregunta qué fricción se esconde detrás de cada cuña

Smets y Wouters (2007); Chari, Kehoe y McGrattan (2007); Fernández-Villaverde, Rubio-Ramírez y Schorfheide (2016).

Simulación

Primero necesitamos calcular el estado estacionario. Para preferencias homotéticas y tecnología Cobb–Douglas podemos obtener el estado estacionario de forma analítica. En este ejemplo, no. Es necesario resolver numéricamente la condición de eficiencia estática en la senda de crecimiento balanceado, como en el mazo A2. El siguiente paso es obtener los coeficientes indeterminados y ejecutar una **simulación de Montecarlo**:

- Obtenemos una simulación de choques a la productividad $\overrightarrow{\epsilon}_T$ para un T grande
- Simulamos iterativamente A_t y K_t para la secuencia de choques aleatorios
- Obtenemos las reglas de decisión para el trabajo y el consumo
- Aplicamos el filtro HP o de Hamilton a las simulaciones, para medir exactamente el mismo objeto estadístico en el modelo y en los datos
- Simulamos momentos como lo hicimos con los componentes cíclicos de los datos y calculamos funciones de impulso respuesta

Modelos DSGE declarativos: archivos `.mod` y `puremacro.dsge`

Para automatizar la diferenciación simbólica, el cálculo del estado estacionario y la perturbación de primer orden, la literatura utiliza especificaciones declarativas escritas en archivos `.mod` (estándar de Dynare).
En este curso resolvemos el modelo en **Python puro** mediante el módulo `puremacro.dsge`:

```
from puremacro.dsge import load_mod

# 1. Cargar la especificación declarativa .mod (Dynare estándar, sin MATLAB)
m = load_mod("modelos/rbc_canonico.mod")

# 2. Resolver perturbación de 1.er orden vía descomposición QZ de Klein (2000)
res = m.stoch_simul(order=1, irf=40)
```

Todo archivo `.mod` organiza el modelo en cuatro bloques fundamentales:

- **Variables**: endógenas (`var`) y choques exógenos (`varexo`).
- **Parámetros**: asignación numérica calibrada (`parameters`).
- **Modelo**: ecuaciones no lineales de equilibrio y CPO (`model`).
- **Computación**: estado estacionario (`steady_state_model`) y choques (`shocks`).

El mapa del archivo `.mod`

Todo archivo `.mod` recorre los mismos bloques — los comentarios se escriben como `//`, `/* */` o `%`:

```
var c k l y a;                      // 1. endogenas
varexo e_a;                         //    exogenas (innovaciones)

parameters alpha beta delta mu nu rho_a g;
alpha = 0.33; beta = 0.99;          // 2. asignacion de valores
// ...

model;                              // 3. CPO + factibilidad + proceso de a_t
// eficiencia intra e intertemporal, restriccion de recursos, AR(1) de a
end;

steady_state_model;                 // 4a. estado estacionario
// ...
end;

shocks;                             // 4b. choques
var e_a; stderr 0.007;
end;

stoch_simul(order=1, irf=40, hp_filter=1600);   // 4c. simulacion
```

De la solución a los momentos: tres experimentos diferentes

Experimento	Qué cambia	Qué reportamos
IRF	Un choque, con tamaño declarado	Respuesta por horizonte
Simulación	Una secuencia de innovaciones	Momentos, tras aplicar el mismo filtro que a los datos
FEVD	Todas las fuentes de riesgo	Contribución a la varianza del error de pronóstico

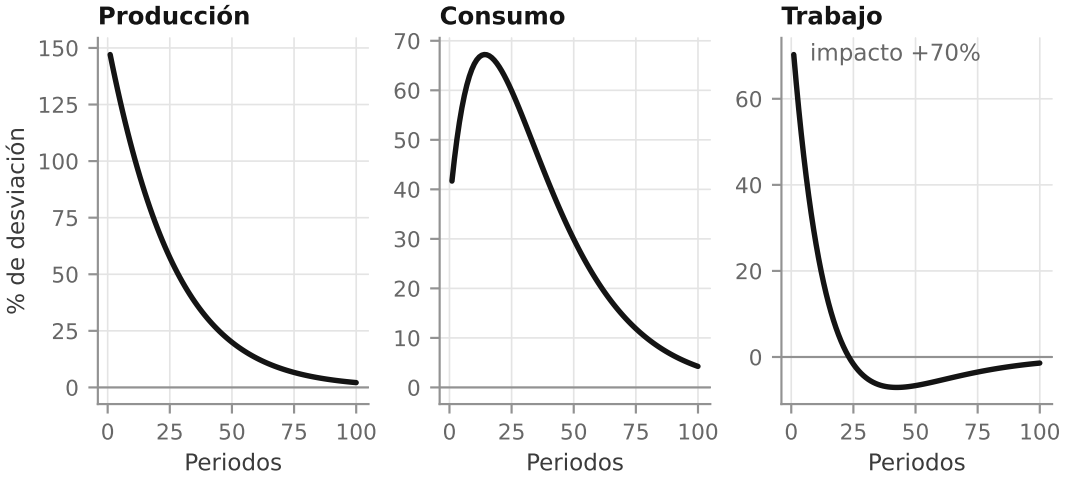
En Python

`load_mod` carga el modelo; `m.solve(order=1)` obtiene la solución local; `m.irf(...)` y `m.simulate(...)` realizan experimentos distintos. La solución ofrece `sol.fevd(...)`.

Antes de comparar con México: misma frecuencia, transformación, muestra efectiva y filtro. Con un solo choque la FEVD le asigna el 100 %; eso no prueba que explique el 100 % del ciclo observado.

Funciones de impulso respuesta

La respuesta del producto, el consumo y el trabajo ante el choque tecnológico:



Persistencia y comovimiento característicos del modelo neoclásico: el suavizamiento intertemporal deja $\sigma_c < \sigma_y$ y la inversión absorbe la mayor parte del choque. Fíjense en el signo de las horas: en el modelo **suben**, y ése es el signo que Galí (1999) lleva a los datos.

El signo de las horas exige decidir qué estamos contrastando

Objeto	Predicción o estimación	Qué puede fallar
RBC del curso	Horas suben tras $e_a > 0$	Mecanismo de transmisión o calibración
SVAR de Galí	Horas caen en impacto	Restricción de largo plazo, muestra o dinámica
Comparación	Signos opuestos	¿Representan ambos choques el mismo cambio tecnológico?

La figura y la réplica están en A2 y T02_B. Galí (1999); Christiano, Eichenbaum y Vigfusson (2003).

Receta: repliquen a Galí con `bq_svar`

```
from puremacro.var.identify.bq import bq_svar
import pandas as pd, numpy as np
from pathlib import Path;  DATA = Path('data_curso')   # el bundle de las lecciones

df = pd.read_csv(DATA / 'gali1999.csv', parse_dates=['date'])  # ophnfb, hoanbs, cnp16ov
df = df[df['date'] <= '2007-12-31']              # la muestra de la figura
x  = 100*np.log(df['ophnfb'])                    # productividad del trabajo
n  = 100*np.log(df['hoanbs']/df['cnp16ov'])      # horas per capita
Y  = np.column_stack([x.diff(), n.diff()])[1:]
res = bq_svar(Y, p=4, horizon=20, permanent_var_idx=0)
print(res.irf_point[0, 1, 0].round(2))           # horas en impacto: -0.24
```

Superpongan la IRF empírica sobre la de Dynare. ¿Falla el modelo o falla la identificación? Si se estima en niveles, el signo se revierte (CEV 2003). Cuando no estamos seguros de la precisión de algún parámetro — ¿o de un mecanismo? — el paso natural es un **análisis de sensibilidad**: vamos a analizar las IRFs para distintos valores de ν, la curvatura del ocio ($\eta = (1-l)/(\nu l)$ es la elasticidad de Frisch implícita).

Galí (1999); Christiano, Eichenbaum y Vigfusson (2003); Francis y Ramey (2005).

Sensibilidad: variar una elasticidad sin mover el estado estacionario

En el modelo $\eta = (1 - \bar{l})/(\nu\bar{l})$. Si cambiamos ν sin recalibrar el peso del ocio, cambian también las horas de largo plazo.

1. Fijen $\bar{l} = 0.33$ y el resto de la calibración.
2. Recorran $\nu \in \{0.2, 0.5, 1, 2, 5\}$ y recalibren μ para conservar $\bar{l}$.
3. Apliquen el mismo impulso de productividad, en las mismas unidades.
4. Registren impacto de las horas, persistencia y σ_l/σ_y con el mismo filtro.

Predicción antes de ejecutar

Una Frisch mayor debería amplificar las horas. ¿Hay algún valor del barrido que cambie su signo en impacto? Si no lo hay, variar ν no resuelve esa discrepancia.

El abanico de IRFs está en A2; aquí cambia la pregunta: aislar el mecanismo. Cuaderno: T02_B.

¿Margen intensivo o extensivo? El dato detrás de ν

La sensibilidad a ν supone que todo el ajuste del trabajo es margen intensivo (horas por trabajador). Descompongan la varianza de las horas totales, país a país — por fin usamos las columnas e y h/e de la tabla inicial:

```
import numpy as np, pandas as pd
from pathlib import Path;  DATA = Path('data_curso')   # el bundle de las lecciones
lab = pd.read_csv(DATA / 'oecd_qna_labor_margenes.csv', parse_dates=['date'])
w = lab[lab['code'].isin(['MEX','DEU','ESP','FRA'])].pivot_table(
        index=['code','date'], columns='variable', values='value')
fred = lambda s: pd.read_csv(DATA / f'{s}.csv', index_col=0, parse_dates=True)[s]
usa = pd.DataFrame({'log_hours_qna': np.log(fred('AWHI')),    # BLS via FRED
                    'log_emp_qna': np.log(fred('USPRIV'))})
usa = usa.resample('QS').mean().loc['1995':]           # horas y empleo, EUA
w = pd.concat([w, pd.concat({'USA': usa}, names=['code','date'])])
dH = 100*w.groupby('code')['log_hours_qna'].diff()     # horas totales
dE = 100*w.groupby('code')['log_emp_qna'].diff()       # empleo
d = pd.DataFrame({'E': dE, 'h': dH - dE, 'H': dH}).dropna()
def reparto(x):  # var(dH) = var(dE) + var(dh) + 2cov(dE,dh), sobre var(dH)
    return pd.Series({'E': x.E.var(), 'h': x.h.var(),
                      '2cov': 2*x.E.cov(x.h)}) / x.H.var()
fecha = d.index.get_level_values('date')
print(d.groupby('code').apply(reparto).round(2))                # todo
print(d[fecha < '2020'].groupby('code').apply(reparto).round(2)) # sin COVID
```

El caché de las lecciones (`oecd_qna_labor_margenes.csv`) cubre DEU, ESP, FRA y MEX (MEX desde 2005; KOR sólo trae empleo); EUA no está en él y entra por las series de la BLS en FRED (`AWHI`, `USPRIV`), congeladas en el mismo bundle. En línea, `fetch.qna_labor(codes, start='1995')` trae la QNA en niveles: tomen logaritmos antes de diferenciar.

La pandemia cambia el reparto entre empleo y horas

La identidad $\Delta \log H = \Delta \log E + \Delta \log(H/E)$ permite comparar episodios sin volver a mostrar toda la serie.

- En toda la muestra, $\mathrm{var}(\Delta \log E)/\mathrm{var}(\Delta \log H)$ es 0.81 en EUA y 0.89 en México.
- En Alemania, España y Francia está entre 0.04 y 0.10: las suspensiones de empleo de 2020 desplazaron mucho ajuste a las horas.
- Estas razones no suman uno con la razón intensiva: falta el término de covarianza.

Prueba del mecanismo

Repitan la cuenta hasta 2019 y después para 2020–2021. ¿Qué institución o restricción debe añadir el modelo para reproducir el cambio de margen?

Series y figura en A1; T01_B, sección de márgenes laborales.

Trabajo indivisible: la lotería de empleo vuelve lineal la desutilidad agregada

Hansen (1985): cada persona trabaja una jornada fija $\bar{h}$ o no trabaja. **Rogerson (1988)**: el hogar sortea quién trabaja con una **lotería de empleo** con seguro perfecto — elige la probabilidad de empleo π_t y todos consumen lo mismo. La utilidad esperada del periodo es

$$\log(c_t) + \pi_t \, \mu \frac{(1-\bar{h})^{1-\nu}}{1-\nu} + (1-\pi_t) \, \mu \frac{1}{1-\nu}$$

Con horas agregadas $l_t = \pi_t \bar{h}$, la utilidad del hogar queda **lineal en el trabajo**:

$$\log(c_t) + \frac{\mu}{1-\nu} - B \, l_t, \qquad B \equiv \frac{\mu \left[1 - (1-\bar{h})^{1-\nu}\right]}{(1-\nu)\,\bar{h}} > 0$$

La desutilidad marginal del trabajo agregado es constante: la elasticidad de Frisch **macro** es infinita aunque la elasticidad micro de cada trabajador sea ≈ 0.5. Esa es la respuesta a la pregunta de qué ν "macro" emerge: con margen extensivo dominante, el agregado se comporta como el límite $\nu \to 0$, sin importar el ν micro.

Trabajo indivisible: qué mejora y qué deja sin explicar

Con loterías de empleo y seguro completo	Límite de la explicación
El empleo puede ajustarse aunque cada empleado trabaje horas fijas	La lotería no describe cómo se busca un puesto
La respuesta agregada de horas aumenta	Las horas siguen subiendo tras el choque tecnológico de esta calibración
La volatilidad relativa se acerca a los datos	No determina vacantes, duración del desempleo ni separaciones

Predigan: si introducimos costos de encontrar un empleo, ¿qué parte de la respuesta debería dejar de ser instantánea?

Hansen (1985); Rogerson (1988). La derivación y su figura comparativa se desarrollan en B1.

Mismo choque, dos ofertas laborales: qué compra la indivisibilidad

Con desutilidad lineal (Frisch $\to \infty$) la respuesta de las horas en impacto es ≈ 2 veces la del caso divisible log-log.

Con esto se cierra el círculo de la sensibilidad a ν

El margen extensivo no "elige" un ν intermedio de calibración: empuja la economía agregada al extremo más elástico — y acerca σ_h/σ_y a la del dato.

El precio: el modelo sigue sin desempleo involuntario, la puerta a los modelos de emparejamiento.

Cuaderno acompañante: `T02_B_rbc_dynare_local`, celda 13 — el barrido de ν y el caso de Hansen ($\nu = 0$): la respuesta de impacto de las horas pasa de 0.234 con $\nu = 1$ a 0.496, es decir $\times 2.1$, y $\sigma(l)/\sigma(y)$ (logs, HP) sube a 0.75, frente a 0.86 en EUA.

Choques y suavizamiento intertemporal del consumo

Con las herramientas que hemos desarrollado vamos a evaluar el efecto que tienen los choques que hemos estudiado en la parte empírica a través del mecanismo de transmisión que es el suavizamiento intertemporal del consumo:

- Choques tecnológicos neutrales y no neutrales
- Choques al gasto público y a los impuestos
- Choques de demanda
- Choques a la incertidumbre

Choques neutrales y no neutrales

Vamos a ilustrar el cálculo de la descomposición de la varianza resolviendo un problema muy similar al anterior, pero vamos a añadir choques específicos no neutrales a la inversión, aunque nos abstraemos de cualquier crecimiento de la población o productividad total de los factores neutral o no neutral.

$$\max_{c_t, l_t, k_t} E_0 \left\{ \sum_{t=0}^{\infty} \beta^t \left[\frac{c_t^{1-\sigma}}{1-\sigma} + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

$$c_t + \frac{k_t - (1-\delta)k_{t-1}}{q_t} = e^{a_t} k_{t-1}^{\alpha} l_t^{1-\alpha}$$

donde

$$a_{t+1} = \rho_a a_t + \epsilon_{at+1}$$

$$\log(q_{t+1}) = \rho_q \log(q_t) + \epsilon_{qt+1}$$

donde los errores $[\epsilon_{at+1}, \epsilon_{qt+1}]$ siguen una distribución normal multivariada $N(0, \Sigma)$. Escribir el proceso de q_t en logaritmos garantiza $q_t > 0$ (divide a la inversión) y fija su mediana (media geométrica) de largo plazo en uno.

El reto no es resolver el modelo: es medir q_t

Añadir más elementos a un modelo presenta varios retos. Uno es el de su solución numérica (no en la mayoría de nuestros ejemplos). El más importante es cómo encontrar una contrapartida empírica de los elementos que introducimos. En concreto:

- Existe una literatura bastante amplia que obtiene valores para σ y ν de datos agregados y microdatos
- Existe una tradición económica de más de medio siglo dedicada a medir la productividad total de los factores a_t
- Pero no tenemos tanta idea sobre cómo medir la evolución agregada de la calidad de los bienes de inversión q_t

¿Cómo medimos q_t? El precio relativo de la inversión, invertido

Greenwood et al. (1997) y (2000) son buenos puntos de partida para profundizar en el tema del cambio en la calidad de los bienes de inversión y sus implicaciones a corto y a largo plazo. Nosotros vamos a seguir el enfoque más sencillo y suponer que el precio relativo de la inversión es inversamente proporcional a la calidad

$$q_t \propto \frac{1}{p_{it}}$$

y que el logaritmo del deflactor de la formación bruta de capital fijo es estacionario en torno a una tendencia cuadrática, cuyo componente estacionario sería

$$\log(p_{it+1}) = (1-\rho_i)p_i + \rho_i \log(p_{it}) + \epsilon_{it+1}$$

por lo que el proceso de calidad de bienes de inversión quedaría definido por

$$\log(q_{t+1}) = -(1-\rho_i)p_i + \rho_i \log(q_t) - \epsilon_{it+1}$$

donde $\epsilon_{it+1} \longrightarrow^{iid} N(0, \sigma_i^2)$. Greenwood et al. (2000) encuentran $\rho_i = 0.64$ y $\sigma_i = 0.03$, un proceso menos persistente y más ruidoso que el que suele encontrarse para la productividad total de los factores, aunque tengan en cuenta que el enfoque de los autores es más complejo que el sugerido en el texto.

Medir el choque de inversión empieza por elegir el proceso

Ya vimos la caída de PERIC y PIRIC en A1. Ahora necesitamos una innovación para el modelo.

1. Elijan equipo o inversión total y documenten el ajuste de calidad.
2. Estimen una tendencia en $\log p_I$ y prueben la estabilidad de su componente residual.
3. Comparen con un modelo para $\Delta \log p_I$. Son dos procesos económicos distintos.
4. Trasladen la innovación a $q_t = 1/p_{It}$: el signo se invierte.

No intercambiar parámetros de niveles y crecimiento

Un AR(1) estable para el crecimiento del precio no justifica imponer ese mismo AR(1) al nivel de q_t. Si el nivel tiene tendencia estocástica, hay que reformular y destendencializar el modelo.

Greenwood, Hercowitz y Krusell (2000); Fisher (2006); DiCecio (2009).

Receta: estimen el AR(1) del precio relativo del equipo

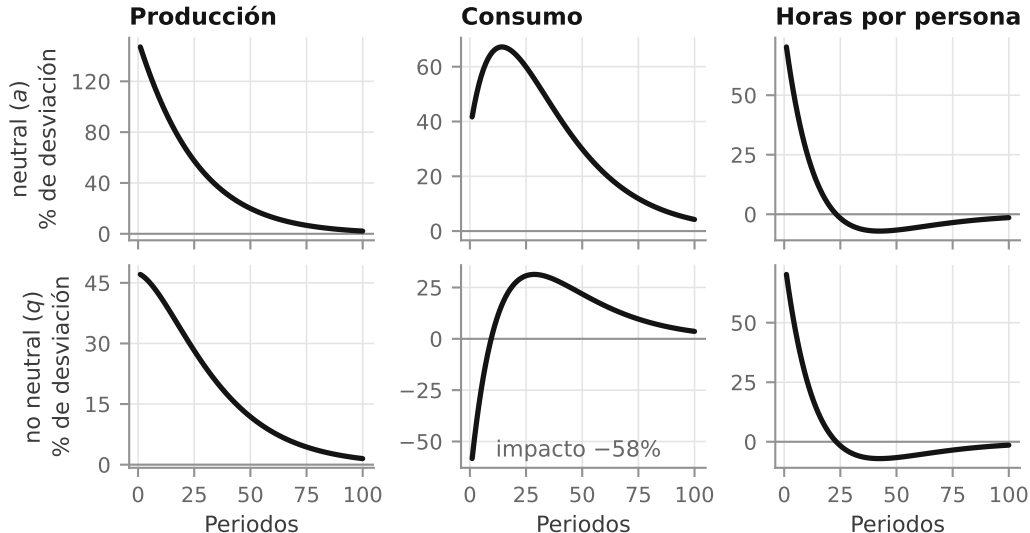
```
# Actualizacion en linea: requiere red; registra la anada.
from puremacro import fetch
import numpy as np, statsmodels.api as sm

p = np.log(fetch.fetch_fred('PERIC'))            # precio relativo del equipo
t = np.arange(len(p))
X = sm.add_constant(np.column_stack([t, t**2]))
pc = sm.OLS(p, X).fit().resid.to_numpy()         # tendencia cuadratica fuera
ar = sm.OLS(pc[1:], sm.add_constant(pc[:-1])).fit()
rho_hat, sig_hat = ar.params[1], ar.resid.std()  # sale rho~1.01, sig=.009
d = np.diff(p.to_numpy())                        # la salida: en Delta log
ar_d = sm.OLS(d[1:], sm.add_constant(d[:-1])).fit()   # rho=.60, sig=.008
```

Usamos `to_numpy()` para alinear observaciones rezagadas por posición, sin que pandas vuelva a emparejar las fechas. **Y si les sale** $\hat{\rho}_i \approx 1.01$ **no se equivocaron:** una tendencia cuadrática no estacionariza $\log(p_{it})$ a frecuencia trimestral, y $\hat{\sigma}_i = 0.009$ queda muy por debajo del 0.03 del texto. En $\Delta \log$ sí sale un AR(1) manejable, $\hat{\rho} = 0.60$ y $\hat{\sigma} = 0.008$, cerca del 0.64 de los autores: no trasladen esos parámetros al nivel de q_t. Estimen un proceso estacionario coherente con el modelo o incorporen crecimiento estocástico y vuelvan a destendencializar antes de comparar la FEVD. Extensión multi-país (opcional): `data_curso/korv_panel_klems.csv` viaja con las lecciones, con $\Delta \log(P_K/P_C)$ anual de 25 países en `dlog_pk_pc`; `puremacro.klems.load_klems_panel(include_investment=True, equip_def='tangible')` es la vía general, pero exige montar a mano el árbol crudo de EU-KLEMS, que **no** se distribuye.

Greenwood, Hercowitz y Krusell (2000); Fisher (2006); DiCecio (2009); Justiniano, Primiceri y Tambalotti (2010).

Funciones de impulso respuesta



La FEVD responde a la calibración de los choques

Con $\rho_q = 0.60$ y $\sigma_q = 0.008$, la descomposición de A2 arroja:

Contribución	$h = 1$	$h = 40$
PTF neutra a la varianza del producto	$83\,\%$	$97\,\%$
Choque de inversión a la varianza de la inversión	$62\,\%$	$27\,\%$

Predigan antes del barrido:

- Si duplicamos σ_q, ¿se duplica su contribución no normalizada a la varianza o se cuadruplica?
- ¿Por qué su participación porcentual no se cuadruplica necesariamente?
- ¿Cambiaría la IRF a un impulso de tamaño fijo? ¿Y a un impulso de una desviación estándar?

Choques ortogonales y solución de primer orden. Una FEVD calibrada no identifica por sí sola la importancia histórica de cada choque.

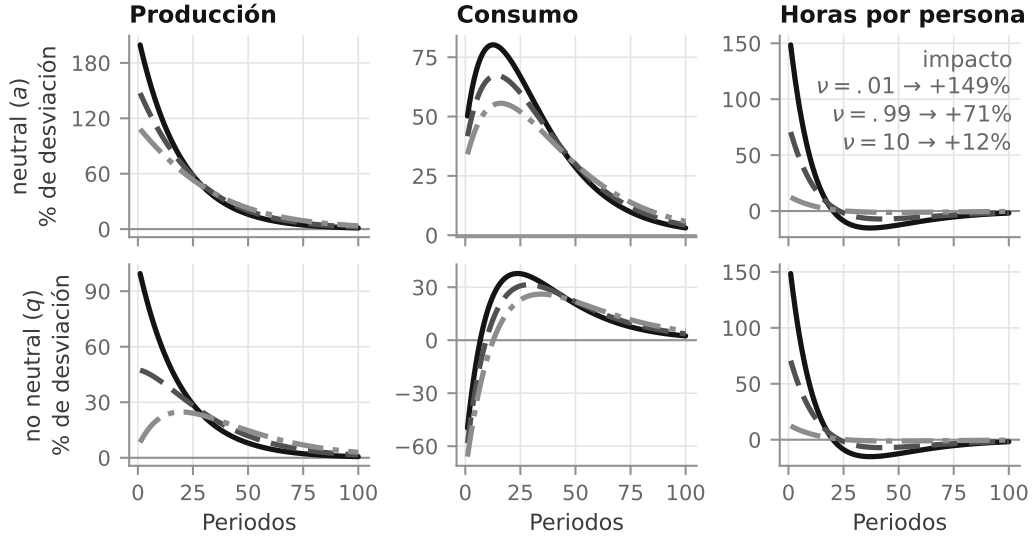
Sensibilidad: hay que fijar la normalización del choque

Repetimos la simulación estocástica para distintos valores de ν (curvatura del ocio) y de σ_q. En la lámina siguiente comparamos las IRFs para tres valores de ν manteniendo el mismo tamaño de choque; en la de después, la VD para tres valores de σ_q. Las figuras complementarias están en el apéndice.

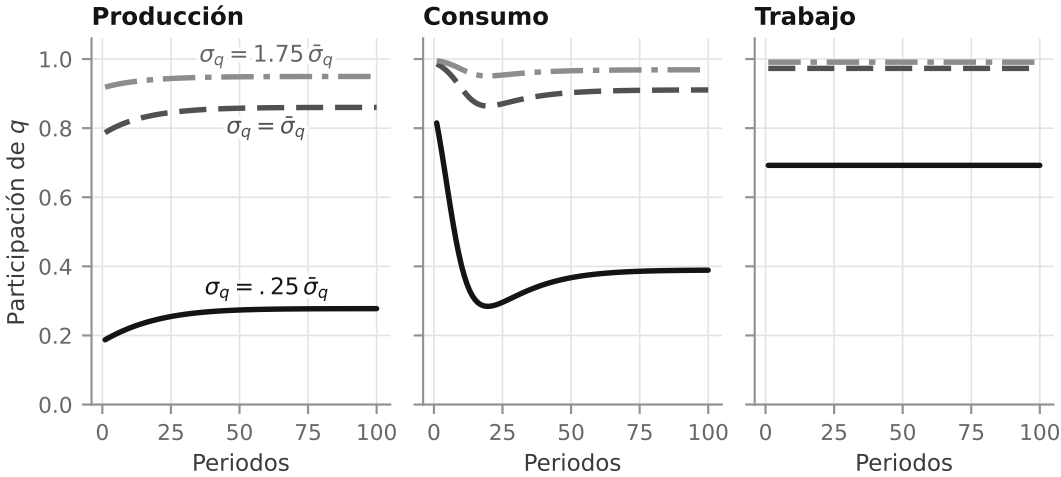
En esta calibración: ν cambia las IRFs y puede cambiar las participaciones de varianza. A primer orden, σ_q cambia las participaciones y las IRFs de un choque de una desviación estándar; no cambia la IRF normalizada a una unidad.

Cambiar la varianza de una innovación no es introducir un choque de volatilidad. El segundo experimento necesita una ley estocástica para la volatilidad y un método que retenga sus efectos sobre las expectativas.

Sensibilidad a ν: las IRFs se desplazan



Sensibilidad a σ_q: cambia la descomposición de la varianza



Choques fiscales: los impuestos obligan a descentralizar el modelo

Con impuestos distorsionantes no se cumplen los teoremas del bienestar: el modelo se escribe de forma descentralizada, con precios de factores w_t y p_{kt} (la motivación completa, en el apéndice):

$$\max_{c_t, l_t, k_t, b_t} E_0 \left\{ \sum_{t=0}^{\infty} \beta^t \left[\frac{(c_t + \psi G_t)^{1-\sigma}}{1-\sigma} + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

sujeto a:

$$c_t + \frac{k_t - (1-\delta)k_{t-1}}{q_t} + b_t = (1-\tau_t)\left(w_t l_t + p_{kt} k_{t-1}\right) + (1+r_{t-1})b_{t-1} + \Omega_t^*$$

donde

$$\begin{aligned} a_{t+1} &= (1-\rho_a)a + \rho_a a_t + \epsilon_{at+1} \\ q_{t+1} &= (1-\rho_q)q + \rho_q q_t + \epsilon_{qt+1} \\ \tau_{t+1} &= (1-\rho_\tau)\tau + \rho_\tau \tau_t + \epsilon_{\tau t+1} \\ g_{t+1} &= (1-\rho_g)g + \rho_g g_t + \epsilon_{gt+1} \end{aligned}$$

donde los errores siguen una distribución normal multivariada $N(0, \Sigma)$; $G_t = g_t y_t$ es el gasto público, con g_t su participación en el PIB, y Ω_t^* es la transferencia que cierra el presupuesto público (las dos formas de cerrarlo — balanceado o con deuda — están en el apéndice).

Aquí escribimos q_t en niveles con media $q > 0$ como aproximación local; la versión en logaritmos de la lámina de choques no neutrales es la que garantiza $q_t > 0$ globalmente.

De dos a cuatro choques: ¿qué observables permiten separarlos?

Choque	Dónde entra	Información adicional
PTF neutra	Producción	Productividad ajustada por utilización
Inversión	Capital instalado por unidad de gasto	Precio relativo y composición de la inversión
Impuestos	Rendimientos netos de factores	Cambios legislativos y tasas marginales
Gasto público	Recursos disponibles	Compras, anuncios y calendario presupuestario

La figura de cuatro choques de A2 ilustra cómo repartir varianza. Para convertirla en evidencia hay que estimar o justificar sus procesos y declarar las restricciones de identificación.

Discusión: ¿qué par de choques sería más difícil de distinguir si solo observamos el PIB?

Debate: el auge de la IA — ¿a_t, q_t o ζ_t?

Los choques de demanda entran por las preferencias: ζ_t altera el descuento intertemporal mediante el factor $\prod_{s=0}^{t-1} e^{\zeta_s}$ y θ_t multiplica a la utilidad del ocio; ambos siguen AR(1) (el modelo completo, en el apéndice).
Clasifiquen ahora el auge de centros de datos 2023–2026: tres hipótesis con implicaciones observables (comovimiento C–I, precio relativo del equipo, descomposición de la varianza condicional):

- ¿Choque de noticias (*news shock*) de PTF futura (Beaudry–Portier)? La inversión sube hoy por una productividad que todavía no aparece en a_t
- ¿Δq? El costo de cómputo cae más rápido que nunca: sería el choque q_t que acaban de estimar
- ¿ζ_t? Una fiebre inversora: choque al descuento intertemporal sin contrapartida tecnológica

Anclas de datos: la participación de la propiedad intelectual en la inversión fija no residencial (`Y001RC1Q027SBEA/PNFI`) ronda el $40\,\%$, cerca de su máximo histórico ($41.6\,\%$ en 2021Q4) —la serie completa, en el apéndice—; `PIRIC` sigue cayendo.
Cierre incómodo: si es ζ_t, el auge puede acabar sin ganancia de productividad. ¿Cómo lo distinguirían en tiempo real y qué dice Acemoglu (2024)? Salvedad empírica: Angeletos, Collard y Dellas (2020) encuentran que el choque que domina el ciclo no se parece a la PTF ni a las noticias sobre ella.

Beaudry y Portier (2006); Fisher (2006); Angeletos, Collard y Dellas (2020); Acemoglu (2024).

Choques a la incertidumbre

La historia económica, desde finales de los años 70, nos muestra la importancia cíclica de la incertidumbre que ocasionan acontecimientos políticos, el precio de los energéticos, el mercado inmobiliario de un país o, recientemente, las guerras comerciales globales. Los macroeconomistas se han esforzado en incorporar la incertidumbre de al menos tres formas distintas. Supongamos un proceso

$$a_{t+1} = \rho_a a_t + e^{v_{t+1}} \epsilon_{t+1}$$

donde $\epsilon_{t+1} \longrightarrow N(0,1)$ y v_t es la log-volatilidad. Podemos modelar cambios en la varianza:

- A través de procesos de volatilidad estocástica (un AR(1) en la log-volatilidad con su propio choque u_t)

$$v_{t+1} = (1-\rho_v)v + \rho_v v_t + (1-\rho_v^2)^{\frac{1}{2}} \eta u_t$$

- A través de procesos de heterocedasticidad condicional autorregresiva generalizados, escritos sobre la desviación estándar condicional $\sigma_t \equiv e^{v_t}$

$$\sigma_{t+1}^2 = \omega_\sigma + \alpha_\sigma \left(\sigma_t \epsilon_t\right)^2 + \beta_\sigma \sigma_t^2$$

- A través de cambios de régimen discretos, gobernados por una cadena de Markov y que no vamos a tratar en este curso

El RBC con volatilidad estocástica: la incertidumbre como choque propio

Vamos a estudiar este tipo de procesos en un modelo relativamente sencillo:

$$\max_{c_t, l_t, k_t} E_0 \left\{ \sum_{t=0}^{\infty} \beta^t \left[\frac{c_t^{1-\sigma}}{1-\sigma} + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

sujeto a la restricción:

$$c_t + (1+g)k_t - (1-\delta)k_{t-1} = e^{a_t} k_{t-1}^{\alpha} l_t^{1-\alpha}$$

donde:

$$a_{t+1} = \rho_a a_t + e^{v_{t+1}} \epsilon_{t+1}$$

donde ϵ_{t+1} es i.i.d. $N(0,1)$ y la log-volatilidad v_{t+1} sigue

$$v_{t+1} = (1-\rho_v)v + \rho_v v_t + (1-\rho_v^2)^{\frac{1}{2}} \eta u_t$$

con u_t i.i.d. $N(0,1)$: el logaritmo de la productividad pasa a ser un proceso de **volatilidad estocástica**, con la log-volatilidad en su propio AR(1) y su propio choque.

- En modelos suaves, una perturbación de tercer orden permite medir respuestas a choques de volatilidad; con irreversibilidad resolveremos el Bellman estocástico con puremacro
- En un modelo no lineal la respuesta depende del estado: se reporta la **GIRF** de Koop, Pesaran y Potter (1996), $\mathrm{GIRF}_h = E\left[y_{t+h} \mid \text{choque, estado}\right] - E\left[y_{t+h} \mid \text{estado}\right]$
- El efecto teórico de la incertidumbre no está claro: operan varios mecanismos a la vez

Tres mecanismos, signos opuestos: prudencia, Oi–Hartman–Abel y opciones reales

- La **prudencia** de los hogares ($u''' > 0$): por Jensen, más incertidumbre eleva la utilidad marginal esperada del consumo futuro $E_t\left[u'(c_{t+1})\right]$ e induce ahorro precautorio que deprime el consumo presente. La aversión al riesgo no basta: la utilidad cuadrática es aversa al riesgo pero, con $u''' = 0$, no genera ahorro precautorio (la desigualdad de Jensen sobre u' lo muestra gráficamente)

- El efecto **Oi–Hartman–Abel**: una empresa puede contratar más trabajo cuando la productividad es alta y menos cuando es baja, aun con capital predeterminado. Esa flexibilidad vuelve convexo su beneficio operativo en la productividad: una dispersión que conserva la media **eleva** el beneficio esperado y puede estimular la inversión. Derivemos este canal antes de combinarlo con los demás

- Las **opciones reales** (*wait-and-see*): con inversión irreversible o costos de ajuste no convexos, esperar tiene valor — más incertidumbre puede deprimir inversión y contratación (Bernanke, 1983; es el canal por el que apuesta Bloom, 2009); las fricciones financieras (restricciones de liquidez, requerimientos de capital) refuerzan este signo contractivo

Oi–Hartman–Abel: capital instalado, trabajo flexible

La pregunta: ¿por qué una empresa podría querer más capital si aumenta el riesgo sobre su productividad futura? Tomemos el bloque productivo del RBC, con $A = e^a > 0$ y $0 < \alpha < 1$.

1. Antes de conocer A, la empresa instala $k > 0$.
2. Observa A y elige el trabajo $l \geq 0$, sin costos de ajuste.

Fijamos el salario $w > 0$ y el precio del producto en uno: es un ejercicio de **equilibrio parcial**. El beneficio operativo, antes del costo del capital, es

$$\Pi(A, k) = \max_{l \geq 0} \left\{ A k^{\alpha} l^{1-\alpha} - w l \right\}.$$

La condición de primer orden y la demanda de trabajo son

$$(1-\alpha) A k^{\alpha} l^{-\alpha} = w \quad \Longrightarrow \quad l^*(A, k) = k \left(\frac{(1-\alpha) A}{w} \right)^{1/\alpha}.$$

El margen clave: con las mismas máquinas, la empresa expande el empleo en el estado favorable y lo reduce en el desfavorable.

Versión didáctica con riesgo de productividad del argumento de flexibilidad: Oi (1961); Hartman (1972); Abel (1983).

De la flexibilidad a la convexidad del beneficio

La condición óptima implica $wl^* = (1-\alpha)Ak^\alpha (l^*)^{1-\alpha}$. Al sustituirla:

$$\Pi(A,k) = \alpha A k^\alpha (l^*)^{1-\alpha} = BkA^{1/\alpha}, \qquad B \equiv \alpha \left(\frac{1-\alpha}{w}\right)^{(1-\alpha)/\alpha} > 0.$$

Como $1/\alpha > 1$, el beneficio es **estrictamente convexo en** A:

$$\Pi_{AA}(A,k) = Bk\,\frac{1}{\alpha}\left(\frac{1}{\alpha}-1\right)A^{1/\alpha-2} > 0.$$

El efecto Oi–Hartman–Abel

Una dispersión de A que conserva su media eleva $E[\Pi(A,k)]$. En particular, por Jensen, $E[\Pi(A,k)] > \Pi(E[A],k)$ si A no es constante y las expectativas son finitas.

Si el trabajo también estuviera fijado, $\Pi(A,k;\bar{l}) = Ak^\alpha \bar{l}^{1-\alpha} - w\bar{l}$ sería lineal en A: a igual $E[A]$, su beneficio esperado no cambiaría.

Comparamos riesgo con la misma media en **niveles**. Fijar $E[a]$ y aumentar la varianza de un a normal eleva $E[e^a]$: ese cambio también altera la productividad media.

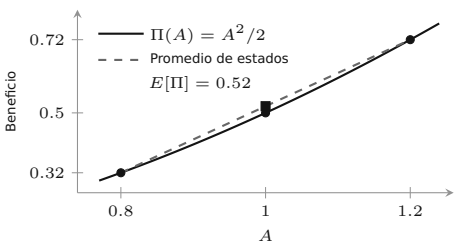
Dos estados: la ganancia supera a la pérdida

Con $\alpha = 1/2$, $k = 1$ y $w = 1/2$, tenemos $l^*(A) = A^2$ y $\Pi(A) = A^2/2$. Comparamos $A = 1$ seguro con $A \in \{0.8, 1.2\}$, cada valor con probabilidad $1/2$.

	Bajo	Seguro	Alto
A	0.8	1	1.2
$l^*(A)$	0.64	1	1.44
$\Pi(A)$	0.32	0.50	0.72

La pérdida es 0.18; la ganancia, 0.22.

$$E[A] = 1, \qquad E[\Pi] = \frac{0.32 + 0.72}{2} = 0.52.$$



El beneficio esperado sube de 0.50 a 0.52 (**4 %**), con la misma productividad media.

Control: con $\bar{l} = 1$ fijo, $\Pi = A - 0.5$; los beneficios serían 0.30 y 0.70, cuyo promedio sigue siendo 0.50. La diferencia proviene de poder ajustar el trabajo.

Volvamos al RBC: ¿qué cambia si no se puede desinvertir?

Ahora salarios, consumo y trabajo se determinan en **equilibrio general**. Sin crecimiento tendencial, añadimos irreversibilidad al problema del planificador:

$$\max E_0 \sum_{t=0}^{\infty} \beta^t \left[\frac{c_t^{1-\sigma}}{1-\sigma} + \mu \frac{(1-l_t)^{1-\nu}}{1-\nu} \right]$$

$$y_t = e^{a_t} k_{t-1}^{\alpha} l_t^{1-\alpha}, \qquad c_t + i_t = y_t, \qquad k_t = (1-\delta)k_{t-1} + i_t, \qquad \boxed{i_t \geq 0}.$$

- El capital instalado puede depreciarse, pero no puede convertirse de nuevo en consumo: la restricción es sobre la **inversión bruta**, no sobre $k_t - k_{t-1}$.
- El trabajo sigue siendo flexible. La convexidad de Oi–Hartman–Abel sigue siendo una intuición parcial; aquí también cambian el salario y la valoración del consumo entre estados.
- Para estudiar la frontera usamos $a_t = \rho_a a_{t-1} + \varepsilon_t$: primero un choque **realizado** de productividad. Un cambio de volatilidad es otro experimento.

En el estado estacionario, $\bar{i} = \delta \bar{k} > 0$: la restricción está inactiva. El caso $\sigma = 1$ usa utilidad logarítmica. Laboratorio: T02_D, §8.

Irreversibilidad: la Euler incluye el multiplicador futuro

Sean $\lambda_t = c_t^{-\sigma}$ y $\eta_t \geq 0$ los multiplicadores de recursos e irreversibilidad. La condición intratemporal sigue siendo

$$\mu(1-l_t)^{-\nu} = \lambda_t(1-\alpha)\frac{y_t}{l_t}.$$

Al derivar respecto al capital de fin de periodo k_t obtenemos

$$\boxed{\lambda_t - \eta_t = \beta E_t\left[\lambda_{t+1}\left(\alpha\frac{y_{t+1}}{k_t} + 1 - \delta\right) - (1-\delta)\eta_{t+1}\right]}.$$

$$i_t \geq 0, \qquad \eta_t \geq 0, \qquad \eta_t i_t = 0.$$

Por qué aparece η_{t+1}: una unidad adicional de capital hoy deja $1-\delta$ unidades que tampoco se podrán vender mañana si vuelve a activarse la restricción.

El valor sombra del capital: $q_t^K = 1 - \eta_t/\lambda_t$

Con inversión positiva, $q_t^K = 1$, su costo de reposición. Si $q_t^K < 1$, el hogar querría desinvertir, pero debe mantener $i_t = 0$. Incluso con $\eta_t = 0$, la Euler depende de una restricción futura anticipada.

OccBin: la inversión en cero define un segundo régimen

Linealizamos alrededor del mismo estado estacionario libre. Usamos desviaciones proporcionales en niveles para c, k, l, y, y definimos

$$j_t \equiv \frac{i_t - \bar{i}}{\bar{k}}, \qquad \xi_t \equiv \frac{\eta_t}{\lambda_t}, \qquad i_t \geq 0 \iff j_t \geq -\delta.$$

Régimen	Ecuación que lo cierra	Condición de validez
Libre	$\xi_t = 0$	$j_t \geq -\delta$
Restringido	$j_t = -\delta$	$\xi_t \geq 0$; salir si $\xi_t < 0$

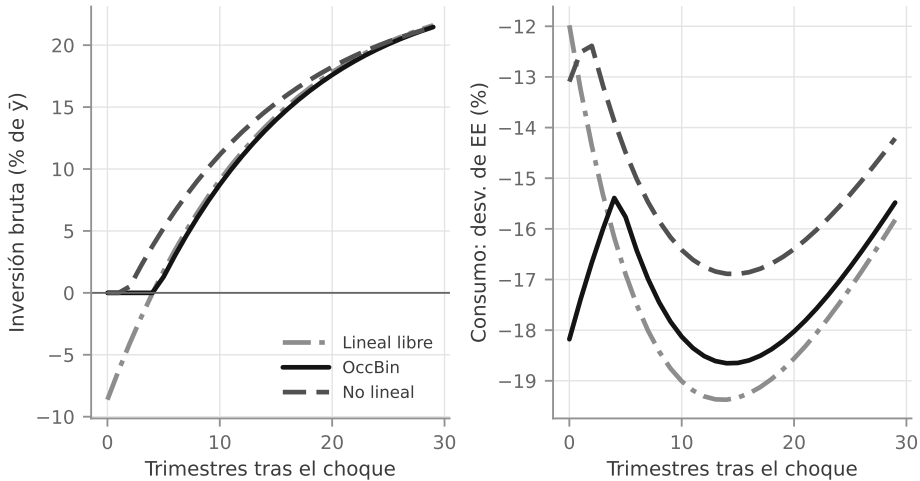
Las ecuaciones de recursos, trabajo, capital y Euler son comunes. En particular, con $\bar{r} = 1/\beta - 1 + \delta$, la Euler linealizada es

$$\sigma(E_t\hat{c}_{t+1} - \hat{c}_t) - \xi_t + \beta(1-\delta)E_t\xi_{t+1} - \beta\bar{r}(E_t\hat{y}_{t+1} - \hat{k}_t) = 0.$$

Alcance: OccBin anticipa cambios de régimen a lo largo de la senda, suponiendo innovaciones futuras nulas. No incorpora el efecto de Jensen ni la opción de esperar por **riesgo futuro aún no realizado**.

No usamos $\log i_t$, que no existe en cero. Cuaderno `T02_D_occbin_zlb_regimes_es`, §8. Guerrieri e Iacoviello (2015).

RBC irreversible: el piso importa, y la aproximación también



Choque de estrés: $\varepsilon_0 = -0.30$ en log-PTF ($-25.9\,\%$ en niveles), $\rho_a = 0.95$, $\delta = 0.025$. Inversión cero durante cinco trimestres con OccBin y dos con las condiciones no lineales de previsión perfecta. El choque habitual de -0.007 no activa el piso.

Ahora sí: más riesgo sobre la productividad futura

Mantenemos fijos k_{-1} y $A_0 = e^{a_0}$. El choque eleva v_0, la log-desviación estándar de la **próxima** innovación de productividad:

$$a_{t+1} = \rho_a a_t - \tfrac{1}{2} e^{2v_t} + e^{v_t}\epsilon_{t+1}, \qquad \epsilon_{t+1} \sim N(0,1),$$
$$v_{t+1} = (1-\rho_v)\bar{v} + \rho_v v_t + \tau_v u_{t+1}, \qquad u_{t+1} \sim N(0,1), \quad u \perp \epsilon.$$

El ajuste $-e^{2v_t}/2$ conserva la **media condicional a un periodo en niveles**:

$$E_t[A_{t+1}] = e^{\rho_a a_t}, \qquad \mathrm{Var}_t(A_{t+1}) = e^{2\rho_a a_t}\left(e^{e^{2v_t}} - 1\right).$$

- Comparamos $v_0 = \bar{v}$ con $v_0 = \bar{v} + \log 2$: la desviación estándar pasa de 0.02 a 0.04; la varianza se cuadruplica.
- Se observa más riesgo **antes de elegir consumo e inversión**. Hoy no ha caído la productividad.

Calibración didáctica: $\rho_v = 0.8$, $\tau_v = 0.15$; el salto equivale a 4.62 d.e. de u, no a un choque habitual. A diferencia del GARCH convencional, u es una innovación propia de la volatilidad. Cuaderno T02_D, §9.

puremacro: riesgo futuro e inversión irreversible

Con k como capital disponible y k' como decisión, resolvemos

$$V(k,a,v) = \max_{c,l,k'} \left\{ u(c,l) + \beta E[V(k',a',v') \mid a,v] \right\},$$

$$c + k' = e^a k^\alpha l^{1-\alpha} + (1-\delta)k, \qquad k' \geq (1-\delta)k.$$

`Case2Problem.solve()` resuelve V por iteración de valor y pasos de Howard. Para recuperar decisiones continuas usamos $m = V_k$:

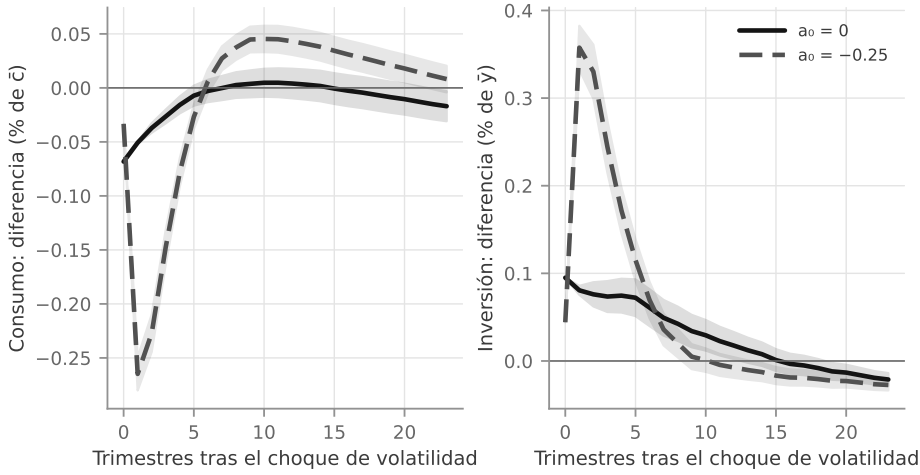
$$\lambda - \eta = \beta E[m(k',a',v')], \qquad m(k,a,v) = \lambda\alpha\frac{y}{k} + (1-\delta)(\lambda - \eta),$$

con $\lambda = c^{-\sigma}$, $\eta \geq 0$, $i \geq 0$ y $\eta i = 0$.

- **Cadena conjunta**: cuadratura para (a', v'); las decisiones incorporan el riesgo futuro. El retorno de invertir menos de cero es $-\infty$.
- **Precisión**: diferenciamos e interpolamos V para evaluar la Euler. Verificamos Bellman, complementariedad, residuos fuera de nodos y refinamiento.

Motor dinámico: `puremacro.vfi.Case2Problem`, probado con 5.9.0. El cuaderno especifica el RBC y recupera políticas continuas a partir del valor discreto. Esta recuperación añade error de aproximación: se audita por separado. T02_D, §9.1–9.2.

Más incertidumbre: la respuesta depende del estado inicial



GIRF ante el mismo aumento de volatilidad, con $k_{-1} = \bar{k}$. En $a_0 = 0$, consumo inicial ≈ -0.07 puntos de $\bar{c}$ e inversión $\approx +0.10$ puntos de $\bar{y}$. El caso $a_0 = -0.25$ ya está deprimido antes del impulso. Bandas: error Monte Carlo de los promedios, no incertidumbre sobre parámetros.

Tres canales de incertidumbre: ¿qué signo esperan?

Canal	Condición que lo activa	Predicción parcial
Precaución	$u^{(3)} > 0$ y riesgo no asegurable	Menos consumo hoy
Oi–Hartman–Abel	Trabajo flexible tras observar A; $\Pi_{AA} > 0$	Mayor beneficio esperado; incentivo a invertir
Opción de esperar	Irreversibilidad o costo fijo	Menos inversión hoy

Ejercicio: un aumento de riesgo reduce consumo e inversión en los datos. ¿Basta la prudencia para reproducir ambos signos? Escriban qué margen adicional necesitan y qué dato lo respaldaría.

Dispersión que conserva la media. Los signos son parciales: el equilibrio general combina los tres canales. Kimball (1990); Hartman (1972); Abel (1983); Bloom (2009).

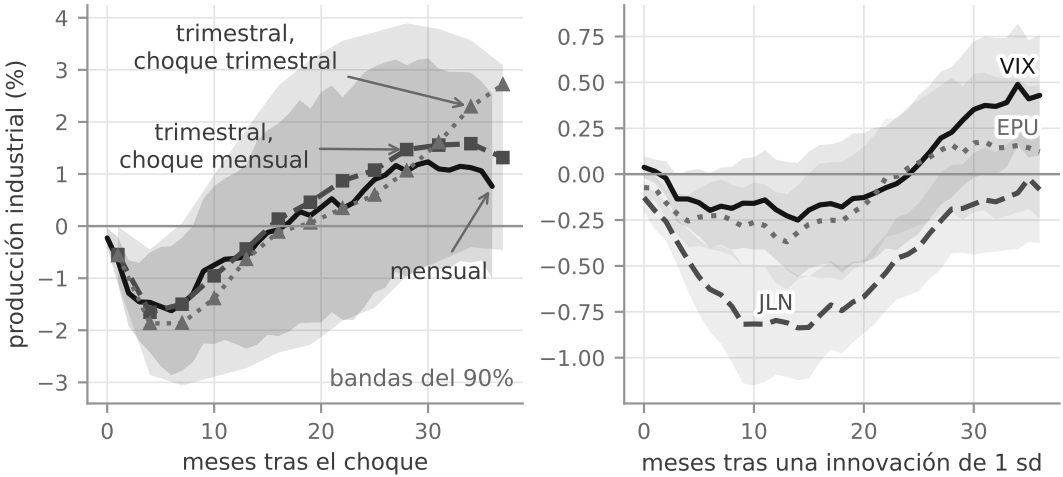
Bloom (2009) contra el RBC con volatilidad estocástica

En nuestro RBC irreversible, el choque de volatilidad reduce el consumo pero eleva la inversión. Contrastemos ese mecanismo con la respuesta estimada de la producción industrial; el resultado depende de la medida de incertidumbre y de los supuestos de identificación.

```
from puremacro.lp import lp_hac
import numpy as np, pandas as pd
from pathlib import Path;  DATA = Path('data_curso')   # el bundle de las lecciones
fred = lambda s: pd.read_csv(DATA/f'{s}.csv', index_col=0, parse_dates=True)[s]
epu = pd.read_csv(DATA/'epu_usa_mensual.csv', index_col='date', parse_dates=True)
m = pd.DataFrame({'ip': 100*np.log(fred('INDPRO')), 'ff': fred('FEDFUNDS'),
                  'infl': 100*np.log(fred('CPIAUCSL')).diff(12),
                  'epu': np.log(epu['epu'])}).loc['1990':'2019']
m['ff_1'], m['infl_1'] = m['ff'].shift(), m['infl'].shift()   # orden recursivo
m = m.dropna()
X = np.column_stack([np.ones(len(m)-6)] + [m['epu'].shift(k)[6:] for k in range(1, 7)])
e = m['epu'][6:] - X @ np.linalg.lstsq(X, m['epu'][6:], rcond=None)[0]  # AR(6)
m['sh'] = e / e.std()                              # la innovacion, en d.e.
irf = lp_hac(m.dropna(), y='ip', x='sh', horizons=range(37), n_lags=6,
             controls=['ff_1', 'infl_1'])
print(irf.loc[[13, 31], 'beta'].round(2))         # -0.37 en h=13, +0.18 en h=31
```

`lp_hac` es por ahora una receta — la teoría de proyecciones locales llega en el bloque econométrico del curso.

Los datos: la producción industrial ante un choque de incertidumbre



EUA, 1990–2019, mensual: proyecciones locales de Jordà de la producción industrial con bandas al 90 %. Izquierda, la respuesta al indicador de episodios de Bloom (VIX), a frecuencia mensual y trimestral; derecha, la respuesta a una innovación de 1 d.e. en tres medidas. El EPU —el de la receta— toca -0.37 en el mes 13 y rebota a $+0.18$ en el 31 con una banda que cruza el cero: el rebote **no** es significativo. El JLN cae -0.84 y no rebota.

Modelo y datos: primero hagan comparables los experimentos

	Proyección local	RBC no lineal
Innovación	Medida de incertidumbre depurada	Log-volatilidad del proceso de productividad
Resultado	Producción industrial	Producto del modelo
Unidad del impulso	Depende de la normalización empírica	Cambio declarado de volatilidad
Interpretación	Causal bajo supuestos de identificación	Contrafactual dentro de la calibración

La GIRF de T02_D, §9, corresponde al RBC irreversible resuelto con puremacro. Antes de comparar magnitudes, alineen el impulso, la frecuencia y el resultado observado. La innovación de EPU no es el choque estructural de volatilidad del modelo.

Bloom (2009) contra el RBC: el veredicto

- **Modelo:** T02_D, §9, resuelve el Bellman estocástico con `puremacro.vfi.Case2Problem`. Integra productividad y volatilidad futuras e impone inversión bruta no negativa.
- **Resultado:** duplicar la desviación estándar de la próxima innovación reduce el consumo, pero eleva inversión y producto en esta calibración. La irreversibilidad por sí sola no genera una recesión de incertidumbre.
- **Datos:** la proyección local muestra una caída de producción industrial. EPU, log-volatilidad y producto del modelo son objetos distintos; esta comparación no identifica por separado prudencia, Oi–Hartman–Abel ni el valor de esperar.
- **Pregunta abierta:** ¿qué fricción o calibración puede producir una caída conjunta de consumo e inversión? Propongan un margen y una prueba con datos. Una solución lineal con certeza equivalente no mide esta respuesta al riesgo.

Bloom (2009); Fernández-Villaverde, Guerrón-Quintana, Rubio-Ramírez y Uribe (2011); Baker, Bloom y Davis (2016); Basu y Bundick (2017).

Una economía con fricciones detalladas tiene un gemelo neoclásico con cuñas

Chari, Kehoe y McGrattan (2007) demuestran **equivalencia** para una lista corta y explícita de fricciones: dada una de esas economías detalladas, construyen un **prototipo** —el modelo neoclásico ya derivado, con cuatro cuñas que varían en el tiempo— cuyas asignaciones coinciden con las de ella. La fricción se lee en el precio o la restricción que distorsiona.

Las cuatro equivalencias efectivamente demostradas

- **Eficiencia** A_t: financiamiento de insumos —la empresa pide prestado para pagar insumos intermedios y el costo del crédito entra como pérdida de eficiencia
- **Trabajo** $1 - \tau_{\ell,t}$: salarios rígidos con choques monetarios, y poder monopólico de un sindicato sobre el salario
- **Inversión** $1 + \tau_{x,t}$: fricciones de financiamiento de la inversión con costos de verificación del estado
- **Gasto** g_t: economía abierta —las exportaciones netas, junto con las compras públicas

Lo demás que suele leerse en las cuñas es analogía, no teorema: la mala asignación entre unidades heterogéneas se lee en A_t (Restuccia y Rogerson; Hsieh y Klenow) y las fricciones de búsqueda y emparejamiento en $1 - \tau_{\ell,t}$ (Shimer), pero ninguna viene con equivalencia probada en el artículo. El mapa es de muchos a uno: la cuña que se mueve **nombra una familia** de modelos; no elige uno dentro de ella.

Chari, Kehoe y McGrattan (2007); Carlstrom y Fuerst (1997); Bernanke, Gertler y Gilchrist (1999); Cole y Ohanian (2004); Restuccia y Rogerson (2008); Hsieh y Klenow (2009); Shimer (2009); Brinca, Chari, Kehoe y McGrattan (2016).

Las cuatro cuñas entran una por ecuación, en las condiciones ya derivadas

El hogar descentralizado resuelve el problema de siempre con dos precios distorsionados: el salario neto $(1-\tau_{\ell,t})w_t$ y el costo de la inversión $(1+\tau_{x,t})$,

$$c_t + (1+\tau_{x,t})\left[(1+g)k_t - (1-\delta)k_{t-1}\right] = (1-\tau_{\ell,t})w_t l_t + r_t k_{t-1} + T_t$$

con $w_t = (1-\alpha)e^{a_t}k_{t-1}^{\alpha}l_t^{-\alpha}$ y $r_t = \alpha e^{a_t}k_{t-1}^{\alpha-1}l_t^{1-\alpha}$. El cociente de las condiciones de primer orden en c_t y l_t da la **intratemporal**; la condición en k_t, la **Euler**:

$$\mu(1-l_t^*)^{-\nu}c_t^* = (1-\tau_{\ell,t})(1-\alpha)e^{a_t}(k_{t-1}^*)^{\alpha}(l_t^*)^{-\alpha}$$

$$E_t\left\{\left[\alpha e^{a_{t+1}}(k_t^*)^{\alpha-1}(l_{t+1}^*)^{1-\alpha} + (1-\delta)(1+\tau_{x,t+1})\right]\frac{\beta c_t^*}{c_{t+1}^*}\right\} = (1+\tilde{g})(1+\tau_{x,t})$$

$$c_t^* + (1+g)k_t^* - (1-\delta)k_{t-1}^* + g_t = e^{a_t}(k_{t-1}^*)^{\alpha}(l_t^*)^{1-\alpha}$$

Con $\tau_{\ell,t} = \tau_{x,t} = g_t = 0$ se recuperan exactamente las tres condiciones de equilibrio del modelo deflactado. La cuña de eficiencia es e^{a_t}, ahora sin imponerle un AR(1).

Notación: $(1+g)$ es el factor de crecimiento de la senda balanceada y $(1+\tilde{g}) = (1+g)/(1+\hat{N})$ su versión por habitante; g_t, con subíndice temporal, es la cuña de gasto: un nivel ($g_t = y_t - c_t - x_t$), a diferencia del g_t del bloque fiscal, que es una participación del PIB. $\tau_{\ell,t}$ distorsiona solo el margen trabajo–ocio, mientras que el τ_t del bloque fiscal grava por igual a los dos factores.

Las cuñas se despejan como residuos; solo una necesita un pronóstico

Dados $\alpha, \delta, \beta, \nu, \mu$, una serie de capital por inventario permanente y los datos $\{y_t, c_t, x_t, l_t\}$, tres cuñas salen despejando directamente:

$$A_t = \frac{y_t}{k_{t-1}^{\alpha} l_t^{1-\alpha}}, \qquad 1 - \tau_{\ell,t} = \frac{\mu (1 - l_t)^{-\nu} c_t \, l_t}{(1-\alpha) y_t}, \qquad g_t = y_t - c_t - x_t$$

La segunda es el cociente entre la relación marginal de sustitución ocio–consumo y el producto marginal del trabajo $(1-\alpha) y_t / l_t$: mide cuánto se aparta el dato de la igualdad que el modelo impone. Su forma depende de las preferencias: con desutilidad del trabajo $\psi \, l_t^{1+\nu}/(1+\nu)$ en vez de curvatura del ocio, el numerador cambia y el número medido también.

La cuña de inversión es la única que vive dentro de una esperanza condicional. Chari, Kehoe y McGrattan tratan al vector $s_t = (\log A_t, \ \tau_{\ell,t}, \ \tau_{x,t}, \ \log g_t)$ como un VAR(1), $s_{t+1} = P s_t + Q \varepsilon_{t+1}$, estimado por máxima verosimilitud junto con el prototipo; con P y Q en la mano, E_t queda determinada y $\tau_{x,t}$ se despeja de la Euler.

> **Advertencia**: por construcción las cuatro cuñas reproducen los datos **exactamente**. Que el prototipo "ajuste" no es evidencia a favor de nada; el contenido está en el reparto, no en el ajuste.

Mini-ejercicio: ¿qué le pasa a la A_t medida si la utilización del capital es variable y no se observa? ¿Y a $1 - \tau_{\ell,t}$ si el ajuste del empleo es extensivo pero l_t solo recoge horas por trabajador?

Una cuña a la vez: el experimento reparte el ciclo, no lo explica

El experimento central alimenta al prototipo con **una** cuña medida y deja a las otras tres en su valor de la senda balanceada, manteniendo las expectativas gobernadas por el mismo P. La serie simulada se compara con el dato.

- Resultado canónico para la Gran Depresión y la recesión de 1982 en EUA: las cuñas de **eficiencia** y de **trabajo** reproducen casi todo el movimiento del producto; la de **inversión** casi nada, y a veces lo empuja en la dirección equivocada
- Es contabilidad porque el mapa fricción $\rightarrow$ cuña es de muchos a uno: la cuña de trabajo es compatible con impuestos, sindicatos, salarios rígidos o fricciones de emparejamiento, y el ejercicio no puede escoger entre ellos
- Todo lo que el prototipo no tiene (utilización variable, capital humano, error de medición, informalidad) reaparece disfrazado de cuña: la cuña mide la distancia al modelo, no una fricción de la economía
- Las componentes solo suman en la aproximación lineal; fuera de ella la descomposición no es aditiva y hay que reportar también la simulación con las cuatro cuñas juntas

La lectura honesta: el ejercicio **descarta** familias enteras de modelos. Una cuña de inversión pequeña cuestiona las fricciones que entran por ese margen en el prototipo. No descarta todas las fricciones financieras: algunas aparecen como cuñas de eficiencia o trabajo.

El panel del curso mide las cuñas con dos atajos que hay que declarar

Atajo 1, en las preferencias. La fórmula del pizarrón supone $U = \log c_t + \mu(1-l_t)^{1-\nu}/(1-\nu)$, con ν como curvatura del ocio. El panel usa la forma alternativa $U = c_t^{1-\sigma}/(1-\sigma) - \psi\, l_t^{1+\nu}/(1+\nu)$, con $\sigma = 1$, $\nu = 2$ (inversa de la elasticidad de Frisch), $c_t = C_t/E_t$, $y_t = Y_t/E_t$ y $l_t = (H_t/E_t)/1152$. Igualar relación marginal de sustitución y producto marginal del trabajo cancela el empleo E_t ($\sigma = 1$):

$$1 - \tau_{\ell,t} = \frac{1}{\texttt{tau_stat}_t} = \frac{\psi_c\, l_t^{1+\nu} c_t^{\sigma}}{(1-\alpha_c) y_t} \implies \log(1-\tau_{\ell,t}) = -\texttt{logS}_t = \log\frac{C_t}{Y_t} + (1+\nu)\log\frac{H_t}{E_t} + \text{cte}_i$$

En 7 países sin horas propias ($*$, donde el panel impone $H_t = 480\,E_t$), la cuña es $\log(C_t/Y_t) + \text{cte}_i$.

Atajo 2, en la Euler. El panel no estima P ni Q: quita E_t (previsión perfecta) e impone $\tau_{x,t} = \tau_{x,t-1}$. En la datación del panel ($K_t = (1-\delta)K_{t-1} + I_{t-1}$ es el capital predeterminado al inicio de t),

$$\frac{1}{1+\tau_{x,t}} \;\simeq\; \texttt{tau_dyn}_t \;\propto\; D_t = \frac{\beta_c^{-1}(C_t/C_{t-1}) - (1-\delta)}{\alpha_c\, Y_t/K_t}, \qquad \text{normalizada a media 1 en 2000–2006}$$

Es un residuo de Euler ex post: hereda entera la sorpresa de C_t/C_{t-1} (y no existe si $C_t/C_{t-1} \le \beta_c(1-\delta)$, como en 2020T2 en 25 de 33 países). Ancla: en EUA (1995–2019, sin COVID-19, desvíos respecto a la BGP), su σ es de **7.3** puntos logarítmicos (7.2 en 2000–2019; 6.7 sin quitar tendencia), contra **1.9** de eficiencia y **1.5** de trabajo; por eso se lee con media móvil de cuatro trimestres (MA4).

Pregunta: si el consumo cae por confinamiento y no por la tasa de interés, ¿de qué signo es el error que este atajo mete en $\tau_{x,2020}$, y lo corregiría estimar P y Q?

Contabilidad en diez economías: 1995–2019, Gran Recesión/Depresión y COVID-19

	Ciclo normal (1995–2019, σ)					Gran Recesión / Depresión (2008–13)						COVID-19 (19T4→20T2)				
País	$\hat{y}$	$\hat{a}$	$\hat{\tau}_\ell$	$\hat{\tau}_x$	$\hat{g}$	Pico–Valle	$\Delta\hat{y}$	$\Delta\hat{a}$	$\Delta\hat{\tau}_\ell$	$\Delta\hat{\tau}_x$	$\Delta\hat{g}$	$\Delta\hat{y}$	$\Delta\hat{a}$	$\Delta\hat{\tau}_\ell$	$\Delta\hat{\tau}_x$	$\Delta\hat{g}$
USA*	3.1	1.9	1.5	7.3	1.2	08T2–09T2	−6.3	−3.3	+3.0	−4.3	+1.1	−10.6	−2.9	+1.3	+20.0	+0.1
DEU	1.8	1.8	2.1	15.9	1.4	08T1–09T1	−8.6	−7.3	−0.7	−2.2	−4.8	−12.0	−7.3	−23.5	+64.4	−2.8
ESP	6.3	2.2	4.9	13.5	2.9	08T2–13T3	−18.8	−0.4	−12.9	−17.6	+8.3	−25.8	−7.8	−78.4	+26.7	−2.6
GBR*	3.5	2.8	1.1	11.7	1.1	08T1–09T2	−9.0	−7.3	+2.8	−15.2	+0.7	−25.9	−24.8	−2.1	+47.5	+1.6
FRA	2.8	2.0	2.9	6.0	0.6	08T1–09T1	−5.7	−4.8	+2.4	−0.3	−1.1	−19.0	−4.0	−76.6	+76.1	−2.2
ITA	4.1	2.4	3.0	8.3	1.5	08T1–13T2	−12.2	−5.4	−10.7	−11.6	+2.5	−19.4	−7.7	−73.8	+17.8	−3.3
GRC	13.0	7.0	4.3	19.8	3.5	07T2–13T1	−35.6	−26.6	+13.8	−48.9	+8.8	−17.0	−4.5	−84.7	+28.2	−5.6
JPN*	1.9	1.7	1.7	23.5	1.0	08T1–09T1	−10.0	−9.7	+6.7	−5.3	−3.9	−7.7	−6.9	+1.9	+20.2	−2.9
CAN	3.2	2.4	4.7	6.0	2.4	08T3–09T2	−6.2	−3.0	−5.7	−1.4	+0.8	−14.7	+2.1	−23.8	+31.8	+2.2
KOR*	4.4	4.4	2.0	21.2	3.4	08T3–08T4	−4.5	−4.4	+1.7	−3.7	+4.5	−6.2	−4.5	−0.8	−13.4	−3.0
Mediana	3.3	2.3	2.5	12.6	1.5	—	−8.8	−5.1	+2.1	−4.8	+0.9	−15.9	−5.7	−23.7	+27.5	−2.7

Desvíos respecto a la senda de crecimiento balanceado (BGP) de cada país (tendencia lineal estimada en el ciclo normal pre-pandemia 1995T1–2019T4, excluyendo COVID-19), orientados para que caer = frenar: $\hat{y}_t = 100(\log Y_t - \log \hat{Y}^{\text{BGP}}_{i,t})$, $\hat{a}_t = 100(\log A_t - \log \hat{A}^{\text{BGP}}_{i,t})$, $\hat{\tau}_{\ell,t} = \text{detrend}(100\log(1-\tau_{\ell,t}))$, $\hat{\tau}_{x,t} = \text{detrend}(-100\log(1+\tau_{x,t}))$ y $\hat{g}_t = \text{detrend}(100\, G_t/\hat{Y}^{\text{BGP}}_{i,t})$. En los episodios (pico a valle de $\log Y_t$ en 2007–13), $\Delta\hat{\tau}_x$ usa media móvil centrada de 4 trimestres (caída mínima frente al pico en 2008–13; sin suavizar, $\log D_{20T2}$ no existe en 9 de los 10 países). *País con $H_t = 480\, E_t$ impuesto (`use_hours=0`): el ajuste de horas por trabajador pasa a $\hat{a}_t$. En 2008–13 dominan $\hat{a}$ (DEU, GRC) y $\hat{\tau}_\ell$ (ESP, ITA); en 2020 se desploma $\hat{\tau}_\ell$ donde hay ERTE/*Kurzarbeit*.

Laboratorio: midan las cuñas de su país y digan qué familia acusan

Python (puremacro) — desvíos respecto a la BGP pre-COVID (1995–2019), en orientación común (caer = frenar)

```
import numpy as np, pandas as pd
from pathlib import Path;  DATA = Path('data_curso')   # el bundle de las lecciones
# panel extendido a 1995T1-2025T2 (empalme QNA 1995-99 + inventario permanente hacia atras)
cu = pd.read_csv(DATA / 'wedges_bca_1995_2025.csv', parse_dates=['date'])
u = cu[cu['code'] == 'ESP'].sort_values('date').set_index('date')
def bgp(s):  # desvio respecto a la senda balanceada pre-COVID (1995T1-2019T4)
    t, m = np.arange(len(s)), (s.index >= '1995-01-01') & (s.index <= '2019-12-31')
    v = m & s.notna();  b = np.polyfit(t[v], s[v], 1)
    return s - (b[0]*t + b[1])
y_bgp = np.exp((100*np.log(u.Y) - bgp(100*np.log(u.Y))) / 100)
w = pd.DataFrame({'y': bgp(100*np.log(u.Y)), 'a': bgp(100*u.logA),
                  'l': bgp(-100*u.logS),     'x': bgp(100*u.logD),
                  'g': bgp(100*(u.Y - u.C - u.I) / y_bgp)})
print('sigma 95-19:', w.loc['1995':'2019'].std().round(1).to_dict())
# ESP -> sigma 95-19: y 6.3, a 2.2, l 4.9, x 13.5, g 2.9 | COVID 19T4->20T2: l -78.4
```

Elijan uno de los países del panel y un episodio, midan la caída de cada cuña frente a su senda balanceada y contesten: ¿qué familia de modelos acusa ese episodio? Trampa deliberada: el salto de la cuña de inversión (MA4) en 2020 hereda el desplome y rebote del consumo en el residuo de la Euler. ¿Fricción financiera, o una Euler que no gobernó al consumo confinado?

Las mismas cuñas, medidas: contabilidad del ciclo en Python

Python (puremacro) — las cuatro cuñas, despejadas de las condiciones ya derivadas

```
import pandas as pd
from pathlib import Path;  DATA = Path('data_curso')  # el bundle de las lecciones
DELTA, NU = 0.015, 2.0  # depreciacion trimestral (0.059 anual) e inversa de Frisch
# el panel de investigacion: 33 economias de la OCDE, 2000T1-2025T2; alpha_c,
# beta_c y psi_c vienen calibrados pais por pais; K_t = (1-DELTA)*K_{t-1} + I_{t-1}
cu = pd.read_csv(DATA / 'wedges_panel_BGP_clean_nu2.csv',
                 parse_dates=['qdate'], date_format='%d-%b-%Y')  # 01-Jan-2000
u = cu[cu['code'] == 'USA'].sort_values('qdate').set_index('qdate').loc['2000':'2019']
l = (u.H / u.EMP) / 1152.0                          # horas por ocupado normalizadas
A = u.Y / (u.K**u.alpha_c * u.H**(1 - u.alpha_c))   # eficiencia (u.K en t es k_{t-1})
S = (1 - u.alpha_c)*u.Y / (u.psi_c * l**(1+NU)*u.C) # trabajo: tau_stat = 1/(1 - tau_l)
G = u.Y - u.C - u.I                                 # absorcion residual (nivel)
D = ((u.C / u.C.shift(1)) / u.beta_c - (1 - DELTA)) / ( # inversion: residuo de
     u.alpha_c * u.Y / u.K)                             # la Euler ex post (tau_dyn)
```

La cuña $G = Y - C - I$ es absorción residual, no gasto público observado: en el panel C proviene del consumo final total menos durables (incluye consumo público), por lo que G recoge exportaciones netas más el residuo de encadenamiento. El experimento del cuaderno trata este residuo como cierre del prototipo; esa decisión debe declararse.

Cuaderno acompañante: `T04_C_business_cycle_accounting` (medición de las cuatro cuñas sobre el panel de 33 economías y el experimento de una cuña a la vez; no es una réplica de Chari, Kehoe y McGrattan 2007).

Las cuñas son un diagnóstico, no una explicación

- **Christiano y Davis (2006)**: la lectura de las cuñas no es robusta a dos decisiones que parecen inocuas. Primera, cómo se representa la fricción dentro del prototipo —la misma fricción financiera acaba en la cuña de inversión o dentro de la ecuación de acumulación de capital según cómo se escriba, y el veredicto cambia con ella. Segunda, cómo se especifica y estima el proceso conjunto de las cuñas: las restricciones sobre P y Q afectan al reparto

- La equivalencia va en una dirección cómoda: **dado** un modelo detallado se construye su prototipo, pero de la cuña medida no se recupera el modelo. Diagnóstico, no explicación

- El puente natural es escribir la fricción de forma explícita y dejar que los datos la disciplinen: verosimilitud por filtro de Kalman, priors y MCMC sobre el modelo estructural, en vez de residuos sobre el prototipo

La pregunta que ordena todo el bloque —qué choque o qué fricción importa— se contesta primero con cuñas, que descartan familias, y después con estimación, que pone números a la familia superviviente.

Chari, Kehoe y McGrattan (2007); Christiano y Davis (2006); Brinca, Chari, Kehoe y McGrattan (2016); Smets y Wouters (2007).

Qué debe salir de aquí para el parcial

- **La tabla de momentos**: volatilidades relativas y correlaciones con el PIB, y cómo cambian por regímenes — es la vara contra la que se mide cualquier modelo del ciclo
- **El mecanismo de suavizamiento intertemporal del consumo**: por qué el RBC entrega $\sigma_c/\sigma_y < 1$, por qué el suyo (≈ 0.33) queda muy por debajo tanto de EUA (0.79) como de México (0.96) —OCDE, 1995–2019, HP—, y por qué el fallo es de magnitud y no de signo — con la ficha de medición que hace comparables esas tres cifras
- **El signo de las horas**: el modelo las sube tras un choque tecnológico y Galí (1999) las baja — con la sensibilidad a ν y el trabajo indivisible de Hansen–Rogerson como piezas del veredicto
- **La taxonomía de choques**: neutrales (a_t), específicos a la inversión (q_t), fiscales (τ_t, g_t), de demanda (ζ_t, θ_t) e incertidumbre (v_t) — y qué observable distingue a cada uno
- **Las cuatro cuñas**: dónde entra cada una en las condiciones de equilibrio, cómo se despeja como residuo y por qué el reparto entre cuñas descarta familias de modelos pero no identifica una fricción

Apéndice

Material de apoyo: la galería histórica del ciclo y la receta del acertijo de Slutsky, el modelo con choques de demanda, la motivación y el cierre presupuestario del bloque fiscal, las IRFs con cuatro choques y las sensibilidades completas por parámetro.

Apéndice (lectura): el ciclo en cinco nombres, 1862–1933

- Clément Juglar (1862) es la primera persona en observar un patrón de **prosperidad** → **crisis** → **liquidación** y observa una duración promedio de 7 a 11 años, atribuyendo ese patrón al sistema de crédito
- William Stanley Jevons (1875) atribuye el patrón cíclico de actividad económica a las manchas solares (que se intensifican cada 11 años) y su impacto sobre la producción agrícola
- Nikolái Kondrátiev (1925) argumenta que existen ciclos de 60 años, asociados a grandes cambios tecnológicos, idea que también es barajada por Joseph Schumpeter. Kondrátiev fue ejecutado por sus ideas en 1938, ya que contradecían la visión marxista del ciclo
- Eugene Slutsky (1927) y Ragnar Frisch (1933) presentan una visión moderna del ciclo como un conjunto de **choques** y **mecanismos de transmisión**, donde el ciclo puede descomponerse matemáticamente como la suma de choques aleatorios
- Wesley Mitchell (1913, 1927) y el National Bureau of Economic Research (NBER) establecen una metodología y un comité para determinar cuándo empiezan y terminan las recesiones

Apéndice: el acertijo de Slutsky, en ocho líneas

```
# Actualizacion en linea: requiere red; registra la anada.
from puremacro import fetch, cycles, data
import numpy as np

y = 100*np.log(fetch.fetch_fred('GDPC1'))
ciclo, _ = cycles.hamilton_filter(y, h=8, p=4)   # el dato (ciclo, tendencia)
ruido = np.convolve(np.random.randn(len(y)), np.ones(8)/8, 'valid')
ruido *= np.nanstd(ciclo) / ruido.std()          # la ilusion, REESCALADA
# alternativa bilateral: data.hp_filter(y, 1600)
```

El reescalado de la última línea no es cosmético: sin él la media móvil tiene una desviación estándar de $\sim$0.34 contra los $\sim$3.2 del ciclo de Hamilton (un factor de 9), y el acertijo se resuelve mirando el eje. Y `mode='same'` rellenaría los bordes con ceros, otra pista gratis: por eso `'valid'`.

Pregunta de fondo: ¿qué evidencia distinguiría choques identificables de una ilusión estadística?

Slutsky (1927); Frisch (1933); Cogley y Nason (1995); Hamilton (2018).

Apéndice: el modelo con choques de demanda

Aumentamos el modelo de choques tecnológicos con dos tipos de choques de demanda: choques al descuento intertemporal del consumo ζ_t y a la demanda de ocio θ_t

$$\max_{c_t, l_t, k_t} E_0 \left\{ \sum_{t=0}^{\infty} \left(\prod_{s=0}^{t-1} e^{\zeta_s} \right) \left[\frac{c_t^{1-\sigma}}{1-\sigma} + e^{\theta_t} \frac{(1-l_t)^{1-\nu}}{1-\nu} \right] \right\}$$

sujeto a:

$$c_t + \frac{k_t - (1-\delta)k_{t-1}}{q_t} = e^{a_t} k_{t-1}^{\alpha} l_t^{1-\alpha}$$

donde

$$a_{t+1} = (1-\rho_a)a + \rho_a a_t + \epsilon_{at+1}$$
$$q_{t+1} = (1-\rho_q)q + \rho_q q_t + \epsilon_{qt+1}$$
$$\zeta_{t+1} = (1-\rho_\zeta)\zeta + \rho_\zeta \zeta_t + \epsilon_{\zeta t+1}$$
$$\theta_{t+1} = (1-\rho_\theta)\theta + \rho_\theta \theta_t + \epsilon_{\theta t+1}$$

En medias, e^{ζ} juega el papel del factor de descuento β y e^{θ} el del peso del ocio μ de la calibración (reservamos β y μ para esos parámetros).

Aquí escribimos q_t en niveles con media $q > 0$ como aproximación local; la versión en logaritmos de la lámina de choques no neutrales es la que garantiza $q_t > 0$ globalmente.

Apéndice: por qué los choques fiscales cambian el modelo

Hemos documentado que los choques a los impuestos y al gasto público son fuentes estructurales de volatilidad y podemos estudiar cómo se transmiten a lo largo del ciclo económico a través del suavizamiento intertemporal del consumo y la sustitución intertemporal del trabajo.

Además, los choques a impuestos y a gastos nos obligan a escribir el modelo de forma descentralizada, ya que no se cumplen los teoremas fundamentales de la economía del bienestar y, sobre todo, nos fuerzan a pensar en cómo caracterizar una tasa marginal en el modelo cuando solo tenemos información sobre las recaudaciones promedio. Nos obligan a pensar en cómo deberíamos introducir el gasto público en las preferencias de los hogares o en la tecnología.

Apéndice: la restricción presupuestaria del gobierno

Siempre que introducimos la actividad del gobierno en modelos **DSGE** tenemos que expresar el equilibrio entre ingreso y gasto.

- Presupuesto balanceado periodo a periodo: requiere introducir Ω_t^* para cubrir la diferencia entre ingresos y gastos

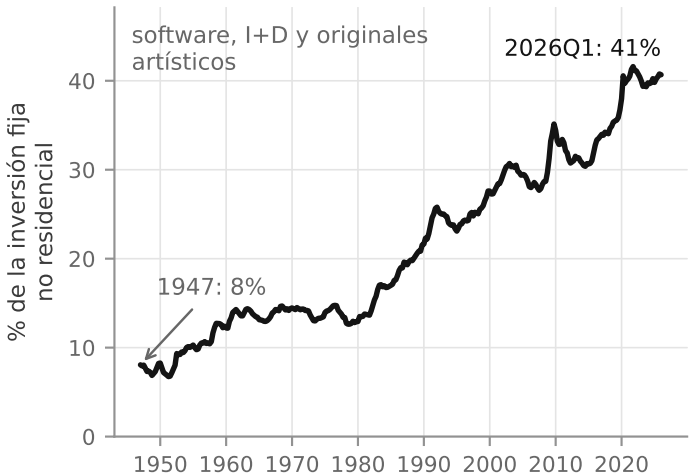
$$\Omega_t^* + g_t y_t = \tau_t y_t$$

- Deuda pública (que puede incluir un Ω_t exógeno): el gobierno recibe b_t al emitir deuda nueva y paga el servicio $(1 + r_{t-1})b_{t-1}$ de la deuda vieja

$$\Omega_t + g_t y_t + (1 + r_{t-1})b_{t-1} = \tau_t y_t + b_t$$

Este último enfoque es particularmente útil si queremos estudiar el efecto sobre la acumulación de deuda de choques tecnológicos y fiscales; solo hay que tener en cuenta que surge una relación de arbitraje entre la rentabilidad esperada de la deuda pública y del capital. Comprueben que, sumando la restricción del hogar (con ingreso factorial $w_t l_t + p_{kt} k_{t-1} = y_t$ y con la transferencia del cierre elegido en el lugar de Ω_t^*) y la del gobierno, se recupera la restricción de recursos de la economía.

Apéndice: la inversión que se vuelve intangible

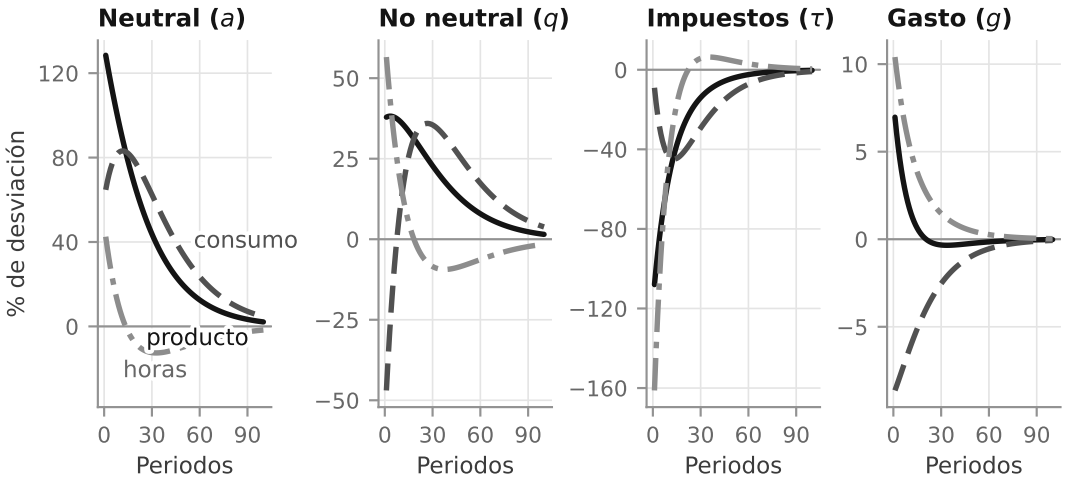


Dos de cada cinco dólares del capital que compra hoy una empresa estadounidense —el $41\,\%$ de la inversión fija no residencial en 2026Q1, contra el $8\,\%$ de 1947— van a software, investigación y desarrollo y originales artísticos. El máximo fue el $41.6\,\%$ de 2021Q4. Ojo con la añada: la figura usa la serie congelada del curso; con los datos revisados que hoy da FRED, 2026Q1 baja a $39.9\,\%$, empatada con el equipo ($40\,\%$) y al doble de las estructuras ($20\,\%$), y en 2026Q2 el equipo ya la rebasa ($40.6\,\%$ contra $39.7\,\%$). No es la mayor parte del total, pero ya pesa lo mismo que el equipo.

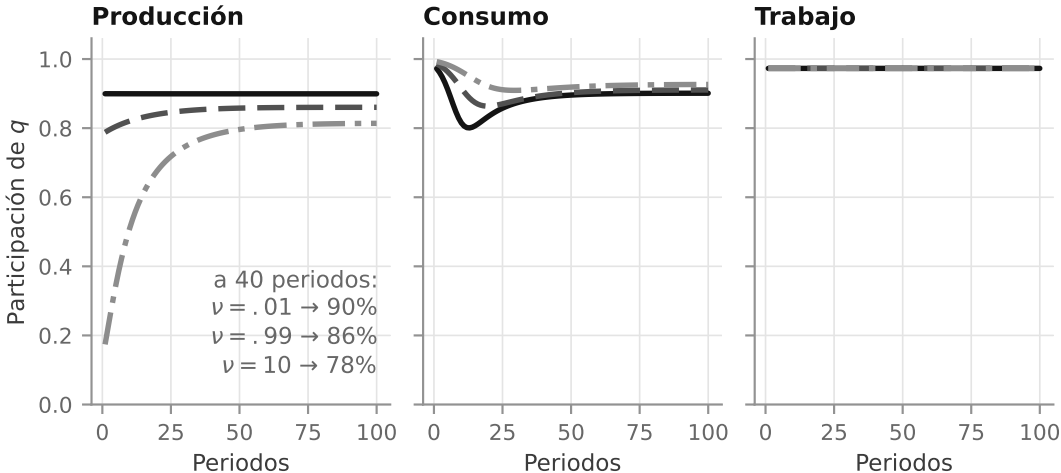
Pregunta para el modelo ya escrito: si buena parte de la inversión es intangible y se deprecia rápido, ¿qué le pasa a δ y al acervo k_t que se mide por inventario permanente, y en qué dirección se sesga la cuña de eficiencia?

Apéndice: las IRFs con cuatro choques

Esta versión del modelo, resuelta en Dynare con impuestos del 30 % y gasto público del 20 % del PIB:



Apéndice: sensibilidad a ν — descomposición de la varianza



El efecto de un cambio en ν es importante en las funciones de impulso respuesta, pero modesto en la descomposición de la varianza.

Apéndice: sensibilidad a σ_q — funciones de impulso respuesta

Al revés que con ν: a primer orden —Klein— la IRF a un choque **unitario** no se mueve; la de una d.e. escala con σ_q.

