Identificación empírica: SVAR, evidencia narrativa y proyecciones locales

Macroeconomía avanzada

ITAM, Otoño 2026

Semanas 9–10

El problema rector: tecnología, horas trabajadas y el ciclo

El modelo de ciclos reales (RBC) predice que una mejora tecnológica eleva la productividad marginal del trabajo y aumenta las horas trabajadas en impacto ($dh_t/d\varepsilon_t^{\text{tech}} > 0$). En cambio, en modelos neokeynesianos con rigideces nominales y demanda agregada acotada a corto plazo, la empresa produce lo mismo con *menos* trabajo ($dh_t/d\varepsilon_t^{\text{tech}} < 0$).

Ruta metodológica (Semanas 9–10)

1. **Fundamentos dinámicos:** qué es un VAR(p), qué es un VECM($p-1$) y cómo se relacionan vía el rango de $\Pi = -A(1)$.
2. **Del VAR al SVAR:** el problema de identificación ($u_t = B\varepsilon_t$), el grupo ortogonal $O(n)$ y los esquemas de identificación.
3. **Ejemplo rector:** de **Galí (1999)** (1 choque tecnológico) a **Fisher (2006)** (2 choques: específico a la inversión $\varepsilon_t^{\text{IST}}$ y neutro ε_t^{N}).

Laboratorio 100 % en `puremacro`

Toda la econometría del bloque se ejecuta con `puremacro`:

- **Integración y VECM:** `adf_test`, `kpss_test`, `engle_granger`, `johansen`, `fit_vecm`.
- **VAR reducido:** `fit_var`, `lag_select`, `companion`, `is_stable`, `irf`, `fevd`, `historical_decomp`.
- **Identificación SVAR:** `cholesky_svar`, `bq_svar`, `identify_maxshare`, `sign_restrictions`, `proxy_svar`, `hetero`.

Referencias rectoras: Galí (1999, *AER*); Christiano, Eichenbaum y Vigfusson (2003, *NBER Macro Annual*); Fisher (2006, *JPE*). Cuadernos: `T02_B` (Galí) y `T05_A` (identificación sobre un VAR monetario); Fisher (2006) se hace en clase: no tiene cuaderno.

Organización del tema: semanas 9 y 10

Los modelos de ciclo generan IRFs teóricas ante choques —tecnológicos, fiscales, monetarios— y descomposiciones de varianza que les atribuyen la volatilidad del PIB. Toca preguntar si esos choques **existen en los datos** y cuánto explican del ciclo:

1. **Fundamentos técnicos: VAR(p), VECM$(p-1)$ y su relación** (Sección 1.1): representación autorregresiva, matriz compañera, representación MA(∞) de Wold, derivación exacta del VECM, Teorema de Representación de Granger y tricotomía del rango $r = \text{rank}(\Pi)$.
2. **Vectores Autorregresivos Estructurales (SVAR) y esquemas de identificación** (Sección 1.2): el problema de identificación ($n(n-1)/2$ grados de libertad), rotaciones ortogonales $B = PQ$, y taxonomía completa de esquemas (corto plazo recursivo y no recursivo, largo plazo de Blanchard–Quah, *Max-Share*, restricciones de signo y narrativas, *Proxy-SVAR* e identificación estadística).
3. **Ejemplo rector: de Galí (1999) a Fisher (2006) con** `puremacro` (Secciones 1.3 y 1.4): pretests de raíz unitaria y cointegración, estimaciones VECM y VAR, IRFs, FEVDs, rotación explícita $Q(\psi)$, controversia niveles vs. diferencias (CEV 2003) y descomposición entre progreso técnico específico a la inversión (IST) y neutro.
4. **Narrativa, proxy-IV, choques monetarios y proyecciones locales** (Sección 2, Semana 10): multiplicadores fiscales (Blanchard–Perotti, Romer–Romer, Mertens–Ravn), alta frecuencia monetaria (Gertler–Karadi, Banxico), proyecciones locales (Jordà 2005; Plagborg-Møller y Wolf 2021) y multiplicadores dependientes del régimen (Auerbach–Gorodnichenko; Ramey–Zubairy).
5. **¿Qué mueve el ciclo?** (Sección 3, cierre): la descomposición por choques, de Kydland–Prescott y Galí a Angeletos–Collard–Dellas y los HANK estimados.

Lecturas marco: Kilian y Lütkepohl (2017), *Structural Vector Autoregressive Analysis*; Nakamura y Steinsson (2018, *JEP*); Stock y Watson (2018, *EJ*).

VAR, VECM y SVAR

Fundamentos técnicos, esquemas de identificación y ejemplo rector

De Galí (1999) a Fisher (2006) con `puremacro`

Semana 9 · Macroeconomía Avanzada

1.1 ¿Qué es un VAR(p) en forma reducida?

Sea $y_t \in \mathbb{R}^n$ un vector de variables macroeconómicas observadas en $t = 1, \ldots, T$. Un **Vector Autorregresivo de orden** p, VAR(p), modela cada variable como función lineal de p rezagos de **todas** las variables del sistema:

$$y_t = \nu + A_1 y_{t-1} + \cdots + A_p y_{t-p} + u_t \quad \Longleftrightarrow \quad A(L)\, y_t = \nu + u_t, \qquad u_t \sim \text{RB}(0, \Sigma_u),$$

donde $A(L) \equiv I_n - A_1 L - \cdots - A_p L^p$ y $\Sigma_u = \mathbb{E}[u_t u_t']$ es simétrica y definida positiva, pero en general **no diagonal** ($\text{Cov}(u_{it}, u_{jt}) \neq 0$).

Propiedades de la forma reducida

- **Innovaciones correlacionadas:** $u_t = y_t - \mathbb{E}[y_t \mid \mathcal{F}_{t-1}]$ es el error de pronóstico un paso adelante, pero mezcla contemporáneamente todos los choques estructurales.
- **MCO ecuación por ecuación:** como las n ecuaciones comparten exactamente los mismos $np + 1$ regresores, MCO ecuación por ecuación coincide con GLS (SUR) y con máxima verosimilitud gaussiana condicional.

Python (puremacro) — Ajuste reducido en `puremacro.var`

```
from puremacro.var import fit_var, lag_select

# 1. Seleccion de rezagos ("aic", "bic", "hqic")
p_opt = lag_select(Y, maxlags=8, ic="bic")

# 2. Estimacion MCO ecuacion por ecuacion
res = fit_var(Y, p=p_opt)
# res.A_list = [A_1, ..., A_p], res.c = nu
# res.Sigma = Sigma_u, res.resid = U (T-p x n)
```

1.1 Matriz compañera $\mathbf{F}$, estabilidad y MA(∞) de Wold

Apilando el estado $\xi_t = [y_t', y_{t-1}', \ldots, y_{t-p+1}']' \in \mathbb{R}^{np}$, todo VAR$(p)$ se escribe como un VAR(1) en forma compañera $\xi_t = \tilde{\nu} + \mathbf{F}\,\xi_{t-1} + \tilde{u}_t$, donde $\mathbf{F} = \begin{bmatrix} A_1 & A_2 & \cdots & A_p \\ I_{n(p-1)} & & \mathbf{0} & \end{bmatrix} \in \mathbb{R}^{np \times np}$.

Condición de estabilidad y MA(∞) de Wold

- **Estabilidad:** el proceso es estacionario en covarianza si y solo si $\det A(z) \neq 0$ para todo $|z| \leq 1 \iff \max_i |\lambda_i(\mathbf{F})| < 1$.
- **Representación de Wold:** bajo estabilidad, $A(L)$ es invertible:

$$y_t = \mu + \Psi(L)\,u_t = \mu + \sum_{h=0}^{\infty} \Psi_h u_{t-h}, \quad \mu = A(1)^{-1}\nu,$$

con $\Psi_0 = I_n$, $\Psi_h = \sum_{j=1}^{\min(h,p)} A_j \Psi_{h-j} = (\mathbf{F}^h)_{[1:n,1:n]}$, y multiplicador acumulado de largo plazo $\Psi(1) = \sum_{h=0}^{\infty} \Psi_h = A(1)^{-1}$.

Python (puremacro) — Estabilidad y Wold en `puremacro.var`

```
import numpy as np
from puremacro.var import (
    companion, is_stable, irf
)

F = companion(res.A_list)
estable = is_stable(res.A_list) # max|eig(F)|<1

# Multiplicadores de Wold Psi_h y LP Psi(1)
n = res.Sigma.shape[0]
Psi = irf(res.A_list, np.eye(n), horizon=20)
Psi_1 = np.linalg.inv(np.eye(n) - sum(res.A_list))
```

1.1 ¿Qué es un VECM$(p-1)$ y cómo se deriva de un VAR(p)?

Cuando $y_t \sim I(1)$, la representación en niveles y la representación en diferencias se conectan mediante una **identidad algebraica exacta**. Restando y_{t-1} en el VAR(p) y sustituyendo $y_{t-j} \equiv y_{t-1} - \sum_{i=1}^{j-1} \Delta y_{t-i}$ $(j = 2, \ldots, p)$:

$$\Delta y_t = \nu + (A_1 - I_n) y_{t-1} + \sum_{j=2}^{p} A_j \left(y_{t-1} - \sum_{i=1}^{j-1} \Delta y_{t-i} \right) + u_t.$$

Agrupando los términos en y_{t-1} y en Δy_{t-i} se obtiene el **Modelo Vectorial de Corrección de Error**, VECM$(p-1)$:

$$\Delta y_t = \nu + \Pi\, y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i\, \Delta y_{t-i} + u_t, \qquad \Pi \equiv \sum_{j=1}^{p} A_j - I_n = -A(1), \qquad \Gamma_i \equiv -\sum_{j=i+1}^{p} A_j.$$

Equivalencia VAR(p) $\leftrightarrow$ VECM$(p-1)$

No se añaden ni quitan parámetros; la inversa recupera unívocamente A_j: $A_1 = I_n + \Pi + \Gamma_1$, $A_i = \Gamma_i - \Gamma_{i-1}$ $(2 \le i \le p-1)$ y $A_p = -\Gamma_{p-1}$.

Por qué Π concentra el largo plazo

Como $\Delta y_t, \Delta y_{t-i} \sim I(0)$, la ecuación solo está balanceada si $\Pi\, y_{t-1} \sim I(0)$. Toda la memoria de largo plazo reside en el **rango de** $\Pi = -A(1)$.

1.1 Teorema de Representación de Granger y tricotomía del rango de Π

El rango $r = \text{rank}(\Pi)$ clasifica exhaustivamente la relación entre un VAR en niveles, un VECM y un VAR en diferencias (Engle y Granger 1987; Johansen 1991):

Caso de rango	Propiedad de y_t y $A(1)$	Modelo bien especificado	Tendencias e impulsos de LP
1. Rango completo $r = n$	$y_t \sim I(0)$ estacionario; $\Pi = -A(1)$ invertible	VAR(p) en **niveles** ($\Psi(1) = -\Pi^{-1}$ finito)	0 tendencias estocásticas; todo choque es transitorio en niveles ($\Psi_h \to 0$)
2. Rango nulo $r = 0$	$y_t \sim I(1)$ sin cointegración; $\Pi = \mathbf{0}_{n\times n}$ ($A(1) = \mathbf{0}$, es decir, $\sum_j A_j = I_n$)	VAR($p-1$) en **primeras diferencias** Δy_t	n tendencias estocásticas independientes; $y_t = y_0 + C(1)\sum_{s=1}^{t} u_s + C^*(L)u_t$
3. Rango reducido $0 < r < n$	$y_t \sim I(1)$ con r relaciones de cointegración $\beta' y_t \sim I(0)$	VECM($p-1$) con $\Pi = \alpha\beta'$, $\alpha, \beta \in \mathbb{R}^{n\times r}$ de rango r	$k = n - r$ tendencias comunes de Stock–Watson: $C(1) = \beta_\perp(\alpha_\perp'\Gamma\beta_\perp)^{-1}\alpha_\perp'$ con $\beta' C(1) = 0$

Donde $\Gamma \equiv I_n - \sum_{i=1}^{p-1}\Gamma_i$ y $\alpha_\perp, \beta_\perp \in \mathbb{R}^{n\times(n-r)}$ son los complementos ortogonales ($\alpha'\alpha_\perp = 0$, $\beta'\beta_\perp = 0$). La condición $\beta' C(1) = 0$ garantiza que las combinaciones estacionarias $z_t = \beta' y_t \sim I(0)$ tienen respuesta acumulada de largo plazo idénticamente nula ante cualquier choque.

1.1 Consecuencias de mala especificación y diagnóstico en puremacro

¿Qué ocurre si nos equivocamos de especificación?

- **Diferenciar cuando hay cointegración ($r > 0$):** estimar un VAR solo en Δy_t impone $\Pi = 0$ y **omite el regresor relevante** $z_{t-1} = \beta' y_{t-1} \sim I(0)$, correlacionado con Δy_{t-i}. Esto sesga los coeficientes e impone artificialmente $\text{rank}(C(1)) = n$ en vez de $n - r$.
- **Estimar en niveles cuando $r = 0$:** MCO en niveles es consistente a horizonte fijo h, pero como $A(1)$ es casi singular ($\hat{\rho} \approx 1$), invertir $\widehat{A}(1)$ en muestras finitas contamina severamente las restricciones de largo plazo de Blanchard–Quah (el corazón del debate Galí 1999 vs. CEV 2003).

Python (puremacro) — Pretests y VECM en puremacro

```
from puremacro.teaching.integration_checks import (
    adf_test, kpss_test, unit_root_table
)
from puremacro.var.vecm import (
    engle_granger, johansen, fit_vecm
)

# 1. Raiz unitaria (ADF H0: I(1); KPSS H0: I(0))
adf_test(df["x"], regression="ct")
kpss_test(df["x"], regression="c")

# 2. Cointegracion de Johansen y ajuste VECM(p-1)
jo   = johansen(df[["x", "h"]], p=3)
vecm = fit_vecm(df[["x", "h"]].values, p=3, r=1)
# vecm["alpha"], vecm["beta"], vecm["Pi"]
```

1.2 ¿Qué es un SVAR? De las innovaciones u_t a los choques ε_t

El sistema simultáneo estructural es $A_0\, y_t = \tilde{\nu} + A_1^s y_{t-1} + \cdots + A_p^s y_{t-p} + B_0\, \varepsilon_t$, donde los choques primitivos $\varepsilon_t \sim \text{RB}(0, I_n)$ son **mutuamente ortogonales** y de varianza unitaria. Premultiplicando por A_0^{-1} se obtiene la forma reducida con $A_j = A_0^{-1} A_j^s$ y el puente entre innovaciones reducidas u_t y choques estructurales ε_t:

$$u_t = A_0^{-1} B_0\, \varepsilon_t \equiv B\, \varepsilon_t \quad \Longleftrightarrow \quad \varepsilon_t = B^{-1} u_t, \qquad \Sigma_u = \mathbb{E}[u_t u_t'] = B\, \mathbb{E}[\varepsilon_t \varepsilon_t']\, B' = BB'.$$

Interpretación económica de B

- La columna j de B ($b_j \in \mathbb{R}^n$) mide el **efecto contemporáneo ($h = 0$)** de un choque estructural $\varepsilon_{jt} = 1$ sobre las n variables.
- Los residuos reducidos u_t son combinaciones lineales contemporáneas de todos los choques estructurales.

El problema de identificación: grados de libertad

- $B \in \mathbb{R}^{n \times n}$ tiene n^2 **parámetros desconocidos**, mientras que $\widehat{\Sigma}_u$ simétrica solo aporta $\frac{n(n+1)}{2}$ **momentos únicos**.
- Faltan exactamente $\frac{\mathbf{n(n-1)}}{\mathbf{2}}$ restricciones: $\mathbf{1}$ para $n = 2$ (Galí 1999) y $\mathbf{3}$ para $n = 3$ (Fisher 2006; Kilian 2009).

1.2 El grupo ortogonal $O(n)$ y los objetos estructurales del SVAR

Sea $P = \mathrm{chol}(\Sigma_u)$ el factor de Cholesky triangular inferior ($PP' = \Sigma_u$). Toda matriz B que satisface $BB' = \Sigma_u$ se escribe como $B = PQ$ con $Q \in O(n)$ ortogonal ($QQ' = I_n$). Como toda $Q \in O(n)$ genera la misma Σ_u, **identificar un SVAR equivale a elegir una rotación** $Q \in O(n)$.

Los tres objetos derivados de $(A_1, \ldots, A_p, B)$

Sustituyendo $u_{t-h} = B\varepsilon_{t-h}$ en $y_t = \mu + \sum_{h=0}^{\infty} \Psi_h u_{t-h}$:

1. **IRF:** $\Theta_h \equiv \frac{\partial y_{t+h}}{\partial \varepsilon_t'} = \Psi_h B = \Psi_h PQ$, y acumulada $\Theta_H^{\text{cum}} = \sum_{h=0}^{H} \Theta_h \to \Theta(1) = \Psi(1)B$.
2. **FEVD:** cuota de varianza a H pasos explicada por ε_{jt}: $\text{FEVD}_{i,j}(H) = \frac{\sum_{h=0}^{H-1} (\Theta_{h,ij})^2}{\sum_{k=1}^{n} \sum_{h=0}^{H-1} (\Theta_{h,ik})^2} \in [0,1]$.
3. **Descomposición Histórica (HD):** contribución de ε_j en la fecha t: $\text{HD}_{i,j,t} = \sum_{h=0}^{t-1} \Theta_{h,ij}\, \varepsilon_{j,t-h}$.

Python (puremacro) — IRF, FEVD y HD en `puremacro.var`

```
from puremacro.var import (
    fit_var, irf, fevd, historical_decomp
)
res = fit_var(Y, p=4)
Theta = irf(res.A_list, B, horizon=20)
W_fevd = fevd(res.A_list, B, horizon=20)
hd_res = historical_decomp(
    res.A_list, B, res.resid,
    init_y=Y[:4], intercept=res.c
)
```

Para $n = 2$ ($\det Q = +1$), $Q(\psi) = \begin{bmatrix} \cos\psi & -\sin\psi \\ \sin\psi & \cos\psi \end{bmatrix}$.

1.2 Esquemas de identificación SVAR (I): restricciones de corto plazo

Los esquemas de corto plazo imponen las $n(n-1)/2$ restricciones directamente sobre $B = \Theta_0$ (o sobre A_0, B_0), especificando **qué variables no responden dentro del mismo periodo** a determinados choques:

1. Identificación recursiva / Cholesky (Sims 1980)

Elige $Q = I_n \implies B = P = \text{chol}(\Sigma_u)$ triangular inferior ($b_{ij} = 0$ para $j > i$):

- Impone una **cadena causal contemporánea** según el ordenamiento: y_{1t} no responde en t a $(\varepsilon_{2t}, \ldots, \varepsilon_{nt})$; y_{2t} responde en t a ε_{1t} pero no a $(\varepsilon_{3t}, \ldots, \varepsilon_{nt})$.
- **Kilian (2009, *AER*):** mercado petrolero mensual $[\Delta\text{prod}_t, \text{rea}_t, \text{rpoil}_t]'$ ($b_{12} = b_{13} = b_{23} = 0$).
- **Corto plazo no recursivo y ceros + signos:** Blanchard y Perotti (2002); Arias, Rubio-Ramírez y Waggoner (2018).

Python (puremacro) — Corto plazo en `puremacro.var.identify`

```
from puremacro.var.identify import (
    cholesky_svar, sign_zero
)

# 1. Cholesky con bandas bootstrap al 90%
res_chol = cholesky_svar(
    Y, p=4, horizon=20, n_boot=500, ci=0.90, seed=42
)
# 2. Ceros + signos (Arias et al. 2018)
res_sz = sign_zero(
    res.A_list, res.Sigma,
    zero_constraints=[(0, 1)],    # B[0, 1] = 0
    sign_constraints={(0, 0): +1} # B[0, 0] > 0
)
```

1.2 Esquemas de identificación SVAR (II): largo plazo (Blanchard y Quah 1989)

En macroeconomía rara vez es creíble que la productividad o el PIB no reaccionen contemporáneamente a un choque de demanda, pero la teoría predice que **los choques de demanda son neutros a largo plazo sobre la productividad**.

Álgebra matricial de Blanchard y Quah (1989)

Sea $\Theta(1) \equiv \sum_{h=0}^{\infty} \Theta_h = \Psi(1)B$ el multiplicador acumulado de largo plazo sobre Δy_t, donde $\Psi(1) = (I_n - \sum_{j=1}^{p} A_j)^{-1}$. Suponemos que $\Theta(1)$ **es triangular inferior** (para $n = 2$, $\Theta(1)_{12} = 0$: el segundo choque no tiene efecto permanente sobre el *nivel* de la primera variable). Como $\Omega \equiv \Psi(1)\Sigma_u\Psi(1)' = \Theta(1)\Theta(1)'$:

$$\boxed{\widehat{\Theta}(1) = \mathrm{chol}\big(\widehat{\Psi}(1)\widehat{\Sigma}_u\widehat{\Psi}(1)'\big), \quad \widehat{B}_{\mathsf{BQ}} = \widehat{\Psi}(1)^{-1}\widehat{\Theta}(1).}$$

Equivalencia vía rotación $Q(\psi)$

Partiendo de $P = \mathrm{chol}(\Sigma_u)$ y definiendo $\widetilde{\Theta}(1) \equiv \Psi(1)P$, para $n = 2$ el ángulo ψ de $Q(\psi) \in SO(2)$ que anula $(\widetilde{\Theta}(1)Q(\psi))_{12} = -\tilde{\theta}_{11}\sin\psi + \tilde{\theta}_{12}\cos\psi = 0$ es:

$$\boxed{\psi = \arctan\left(\frac{\tilde{\theta}_{12}}{\tilde{\theta}_{11}}\right), \quad \widehat{B}_{\mathsf{BQ}} = P\,Q(\psi).}$$

Si $\tilde{\theta}_{12} < 0$, la rotación gira el impacto en sentido negativo ($\psi < 0$).

1.2 Esquemas de identificación SVAR (III): *Max-Share* y choques de noticias

Estimar $\Psi(1) = A(1)^{-1}$ en muestras finitas tiene alto sesgo y varianza (Faust y Leeper 1997). Los esquemas *Max-Share* (Uhlig 2004; Francis et al. 2014) identifican el choque tecnológico como la dirección $q_1 \in \mathbb{R}^n$ ($\|q_1\| = 1$, $b_1 = Pq_1$) que **maximiza la FEVD del nivel de productividad** en un horizonte finito largo H^* (p. ej. $H^* = 40$):

$$\max_{q_1' q_1 = 1} \; q_1' M_1(H^*) q_1, \qquad M_1(H^*) \equiv \frac{\sum_{h=0}^{H^*} (\Psi_h P)'_{1,\bullet} (\Psi_h P)_{1,\bullet}}{\sum_{h=0}^{H^*} (\Psi_h \Sigma_u \Psi_h')_{11}}.$$

Autovector principal y choques *News*

- **Solución exacta:** q_1^* es el **autovector asociado al mayor autovalor** de la matriz simétrica $M_1(H^*)$.
- **Choques de noticias (*News*, Barsky y Sims 2011):** maximiza la FEVD de la PTF en $[0, H^*]$ sujeto a impacto nulo hoy ($e_1' P q_{\text{news}} = 0$). `news_maxshare` omite ese cero.

Python (puremacro) — Largo plazo y *Max-Share* en `puremacro`

```
from puremacro.var.identify import (
    bq_svar, identify_maxshare, news_maxshare
)
res_bq = bq_svar(Y_diff, p=4, horizon=40)
# Y_lvl_x tiene el NIVEL de x_t en col 0:
res_ms = identify_maxshare(Y_lvl_x, p=4,
    target_idx=0, max_fev_at=40, horizon=40)
res_nw = news_maxshare(  # res = fit_var(...)
    res.A_list, res.Sigma, target_var=0, horizon=40)
```

1.2 Esquemas de identificación SVAR (IV): signos, narrativa, *Proxy-SVAR* y varianza

5. Signos y narrativa (Uhlig 2005; RWZ 2010; ADRR 2018)

- **Restricciones de signo:** se sortean matrices ortogonales $Q \sim \text{Haar}(O(n))$ vía factorización QR de $Z \in \mathbb{R}^{n\times n}$ con entradas $\mathcal{N}(0,1)$ i.i.d. (con $\text{diag}(R) > 0$) (Rubio-Ramírez, Waggoner y Zha 2010) y se retienen las Q cuyas IRFs $\Theta_h(Q) = \Psi_h P Q$ cumplen los signos teóricos (identificación por conjuntos).
- **Narrativa de signos (Antolín-Díaz y Rubio-Ramírez 2018, *AER*):** acota el conjunto exigiendo que en fechas históricas clave el choque $\varepsilon_{jt}(Q)$ tenga el signo o la contribución dominante en la descomposición histórica (p. ej. Volcker en 1979Q4).

6. Proxy-SVAR (Mertens–Ravn 2013) y Heterocedasticidad

- **Instrumentos externos (z_t):** si $\mathbb{E}[z_t \varepsilon_{1t}] = \phi \neq 0$ y $\mathbb{E}[z_t \varepsilon_{2:n,t}] = 0$, entonces $\mathbb{E}[u_t z_t] = \phi\, b_1$, identificando el impacto relativo sin imponer ceros:

$$\frac{b_{i1}}{b_{11}} = \frac{\text{Cov}(u_{it}, z_t)}{\text{Cov}(u_{1t}, z_t)}, \qquad b_{11}^2 = (\beta_{\text{IV}}' \Sigma_u^{-1} \beta_{\text{IV}})^{-1}.$$

- **Heterocedasticidad (Rigobon 2003):** dos regímenes de volatilidad $\Sigma_u^{(1)} = BB'$ y $\Sigma_u^{(2)} = B\Lambda B'$ ($\lambda_i \neq \lambda_j$) identifican B puntualmente mediante autovalores generalizados.

1.2 Taxonomía comparativa de esquemas SVAR en `puremacro.var.identify`

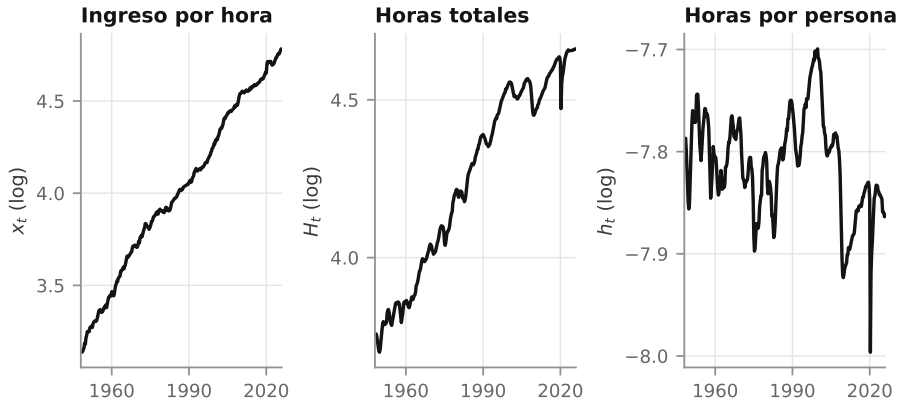
Esquema	**Restricción sobre $B = PQ$**	**Función** `puremacro`
Corto plazo recursivo	$B = P = \text{chol}(\Sigma_u)$	`cholesky_svar`
Corto plazo + signos	Ceros y signos en Θ_h	`sign_zero`
Largo plazo (BQ 1989)	$\Theta(1) = \Psi(1)B$ triang. inf.	`bq_svar`
Max-Share FEVD	$\max_{\|q\|=1} q' M_{i*}(H^*)q$	`identify_maxshare`
Noticias (*News*)	Max FEVD a H^* largo (sin cero)	`news_maxshare`
Signos (RWZ 2010)	$\text{sgn}(\Theta_h(Q)) \in \mathcal{S}$	`sign_restrictions`
Narrativa (ADRR 2018)	Signos en Θ_h, ε_t y HD	`identify_narrative_sign`
Proxy-SVAR / IV	$\mathbb{E}[z_t \varepsilon_{1t}] \neq 0,\ \mathbb{E}[z_t \varepsilon_{-1,t}] = 0$	`proxy_svar`
Heterocedasticidad	$\Sigma_u^{(1)} = BB',\ \Sigma_u^{(2)} = B\Lambda B'$	`hetero`
No-gaussianidad (ICA)	Independencia no gaussiana	`non_gaussian_svar`

Python (puremacro) — Signos, Proxy y Rigobon en `puremacro`

```
from puremacro.var.identify import (
    sign_restrictions, identify_narrative_sign,
    NarrativeRestriction, proxy_svar, hetero
)
# 1. Restricciones de signo (RWZ 2010)
res_sr = sign_restrictions(  # y1(0)>0, y2(0)<0
    Y, p=4, restrictions={0: [+1, -1]}
)
# 2. Proxy-SVAR con instrumento externo z
res_iv = proxy_svar(
    Y, z=proxy, p=4, shock_target_idx=0
)
# 3. Heterocedasticidad en dos regimenes
reg = (np.arange(len(Y)) >= 140).astype(int)
res_het = hetero(Y, p=4, regime_indicator=reg)
```

1.3 Ejemplo rector (I): Galí (1999) — datos y medición de las horas

Estimamos la respuesta del producto por hora trabajada $x_t = \log(\text{OPHNFB}_t)$ y de las horas trabajadas —totales $H_t = \log(\text{HOANBS}_t)$ o por persona en edad de trabajar $h_t = \log(\text{HOANBS}_t/\text{CNP16OV}_t)$— ante un choque tecnológico en EE. UU. (`data_curso/gali1999.csv`, 1948Q1–2026Q1):



Inspección visual: la productividad x_t y las horas totales H_t exhiben tendencias seculares crecientes claras; las horas per cápita h_t muestran ondas demográficas de muy baja frecuencia (caída en 1948–1962, ascenso en 1965–2000, caída en 2000–2010 y desplome COVID en 2020).

1.3 Diagnóstico de integración y cointegración en Galí con `puremacro`

Aplicamos el protocolo de la Sección 1.1: contrastamos raíces unitarias (ADF y KPSS) y el rango de cointegración $r = \text{rank}(\Pi)$ de Johansen para (x_t, H_t) y (x_t, h_t) en cuatro ventanas muestrales:

Python (puremacro) — Pretests en `puremacro`

```
import numpy as np, pandas as pd
from puremacro.teaching.integration_checks import (
    adf_test, kpss_test
)
from puremacro.var.vecm import johansen

g = pd.read_csv("data_curso/gali1999.csv",
                index_col="date", parse_dates=True)
g = g.loc[:"2019-12-31"]              # 1948-2019
df = pd.DataFrame({
    "x": np.log(g["ophnfb"]),
    "H": np.log(g["hoanbs"]),
    "h": np.log(g["hoanbs"] / g["cnp16ov"]),
})
adf_test(df["x"], regression="ct")   # p = 0.21
kpss_test(df["x"], regression="c")   # p = 0.005
jo_H = johansen(df[["x", "H"]], p=3) # r = 0
jo_h = johansen(df[["x", "h"]], p=3) # r = 1
```

Muestra	p-val ADF			Traza ($r = 0$)		Rango
	x_t	H_t	h_t	(x, H)	(x, h)	$\hat{r}_H / \hat{r}_h$
1948–1998 ($T = 204$)	0.25	<0.01	0.09	13.02	13.08	0 / 0
1948–2007 ($T = 240$)	0.22	<0.01	0.03	9.07	13.62	0 / 0
1948–2019 ($T = 288$)	0.21	0.16	0.05	10.87	**16.48***	0 / **1**
1948–2026 ($T = 313$)	0.18	0.26	0.14	8.86	13.08	0 / 0

Crítico 5 % (Caso III): 15.49 ($r = 0$) y 3.84 ($r \leq 1$). En Δ, ADF $p < 0.001$.

Dos lecciones empíricas del pretest

1. Con **horas totales** (x_t, H_t) nunca se rechaza $r = 0$, pero la raíz unitaria de H_t depende de la ventana (ADF la rechaza al 1 % hasta 2007; desde 2019, no): en la muestra completa el sistema se estima en diferencias $(\Delta x_t, \Delta H_t)$.
2. Con **horas per cápita** (x_t, h_t), la raíz unitaria de h_t ($p \in [0.03, 0.14]$) y la cointegración (16.48 vs. 15.49) están en la frontera estadística: de ahí nace el debate Galí (1999) vs. CEV (2003).

1.3 Estimación del VECM(2) sobre (x_t, h_t) y lectura de $\Pi = \alpha\beta'$

Cuando Johansen sobre (x_t, h_t) (1948Q1–2019Q4) selecciona $r = 1$, estimamos el VECM(2) ($\Delta y_t = \alpha(\beta' y_{t-1} + c_0) + \Gamma_1 \Delta y_{t-1} + \Gamma_2 \Delta y_{t-2} + u_t$) con $y_t = [\text{INCPW}_t, \text{HRSPW}_t]'$. La tabla es el Caso II (constante c_0 dentro de β; `VECM` de `statsmodels`, `det='ci'`):

	Coef.	EE	z	p-val
(A) Velocidades de ajuste α				
$ec_{t-1} \to \Delta\text{INCPW}_t$ (α_1)	-0.0016^{***}	0.000	-7.897	0.000
$ec_{t-1} \to \Delta\text{HRSPW}_t$ (α_2)	0.0006^{***}	0.000	3.465	0.001
(B) Vector de cointegración β (norm. $\beta_1 = 1$)				
β_1 (INCPW$_{t-1}$)	1.0000	0.000	0.000	0.000
β_2 (HRSPW$_{t-1}$)	-10.7302^{*}	5.320	-2.017	0.044
Constante (c_0)	-90.7069^{*}	41.541	-2.184	0.029

Python (puremacro) — `fit_vecm`: Caso III

```
from puremacro.var.vecm import fit_vecm
vecm = fit_vecm(df[["x", "h"]].values, p=3, r=1)
# constante libre (Caso III), sin c0 ni EE:
# beta = [1, -57.69], alpha = (-0.0002, +0.0005)
# beta'alpha = -0.028 -> vida media ~25 trim.
```

Anatomía del término de corrección de error

El desequilibrio estimado es $ec_t = \text{INCPW}_t - 10.73\,\text{HRSPW}_t - 90.71$:

- **Ajuste estabilizador:** cuando $ec_{t-1} > 0$, el ingreso por hora se desacelera ($\alpha_1 = -0.0016 < 0$) y las horas por persona suben ($\alpha_2 = +0.0006 > 0$).
- **Convergencia y vida media:** la tasa de contracción por trimestre es $\beta'\alpha = \alpha_1 - 10.73\,\alpha_2 = -0.0080 < 0$, lo que implica una **vida media de** $\ln(0.5)/\ln(0.992) \approx 86$ **trimestres (**≈ 21.5 **años)**.
- Esta reversión **ultralenta** refleja las ondas demográficas de h_t; por ello la literatura modela h_t como $I(0)$ o en diferencias $(\Delta x_t, \Delta h_t)$.

1.3 Estimación del VAR(3) reducido sobre $(\Delta x_t, \Delta H_t)$ en puremacro

Para las horas totales H_t y la productividad x_t ($\hat{r} = 0$), estimamos un VAR(3) en diferencias sobre $y_t = [\text{INCPW}_t, \text{HRS}_t]' = [100\Delta \log \text{OPHNFB}_t, 100\Delta \log \text{HOANBS}_t]'$ (1948Q2–2026Q1, $T = 312$):

Ec. 1: INCPW$_t$ (Δx_t)

	Coef.	EE	p-val
const	0.616	0.073	0.000
L1.INCPW	-0.064	0.057	0.261
L1.HRS	**-0.123**	0.039	**0.001**
L2.INCPW	0.074	0.058	0.203
L2.HRS	-0.056	0.039	0.151
L3.INCPW	-0.009	0.058	0.881
L3.HRS	**-0.115**	0.038	**0.003**

Ec. 2: HRS$_t$ (ΔH_t)

	Coef.	EE	p-val
const	-0.139	0.110	0.208
L1.INCPW	**0.391**	0.086	**0.000**
L1.HRS	**0.137**	0.058	**0.017**
L2.INCPW	0.149	0.088	0.089
L2.HRS	**0.135**	0.059	**0.021**
L3.INCPW	0.081	0.087	0.349
L3.HRS	0.082	0.058	0.157

Matrices reducidas

- $\max_i |\lambda_i(\mathbf{F})| = 0.611 < 1.$
- $\widehat{\Sigma}_u = \begin{bmatrix} 0.684 & -0.126 \\ -0.126 & 1.539 \end{bmatrix}$ ($\hat{\rho}_u = -0.123$).
- $\widehat{\Psi}(1) = \begin{bmatrix} 0.780 & -0.355 \\ 0.751 & 1.207 \end{bmatrix}.$
- $\widehat{B}_{\text{Chol}} = \begin{bmatrix} 0.827 & 0 \\ -0.152 & 1.231 \end{bmatrix}.$

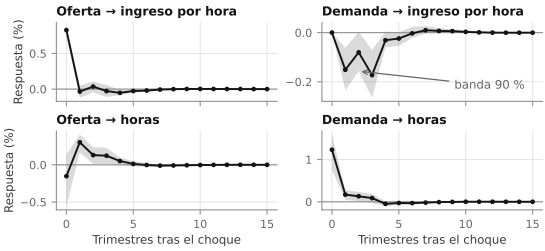
Python (puremacro) — Estimación del VAR(3) reducido en puremacro

```
from puremacro.var import fit_var, irf, fevd
from puremacro.var.identify.cholesky import cholesky_factor
res = fit_var(df[["d_incpw", "d_hrs"]].values, p=3)
B_chol = cholesky_factor(res.Sigma)
irf_mat, fevd_mat = irf(res.A_list, B_chol, 20), fevd(res.A_list, B_chol, 20)
```

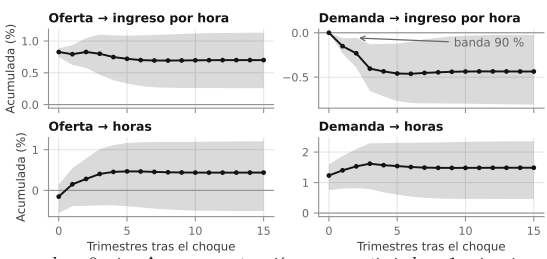
1.3 Identificación recursiva (Cholesky) en Galí: IRFs por periodo y acumuladas

Ordenando primero la productividad y segundo las horas ($y_t = [\Delta x_t, \Delta H_t]'$), la identificación de Cholesky impone $b_{12} = 0$: el segundo choque ("demanda") no afecta a la productividad en $h = 0$, dando $\widehat{B}_{\text{Chol}} = \left[\begin{smallmatrix} 0.827 & 0 \\ -0.152 & 1.231 \end{smallmatrix}\right]$.

(A) IRFs por periodo ($\Theta_h = \Psi_h B_{\text{Chol}}$ sobre tasas de crecimiento)

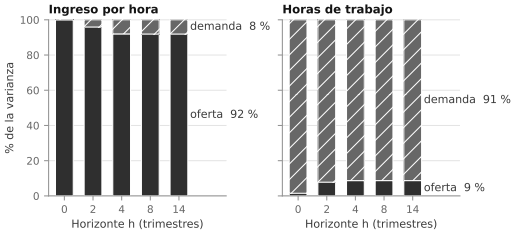


(B) IRFs acumuladas ($\Theta_H^{\text{cum}} = \sum_{h=0}^{H} \Theta_h$ sobre niveles x_t, H_t)



Nota crítica: bajo Cholesky, el "choque de demanda" (columna derecha) tiene impacto cero en $h = 0$ sobre Δx_t por construcción, pero a partir de $h = 1$ reduce la tasa de crecimiento de la productividad (porque L1.HRS $= -0.123 < 0$), generando un **efecto permanente negativo sobre el nivel de la productividad** ($\widehat{\Theta}(1)_{12} = (\widehat{\Psi}(1)\widehat{B}_{\text{Chol}})_{12} = -0.437 \neq 0$).

1.3 FEVD bajo Cholesky y por qué falla el cero de corto plazo



Crítica a la identificación de Cholesky en $(\Delta x_t, \Delta H_t)$

1. **En impacto ($h = 0$):** imponer $b_{12} = 0$ exige que los choques de demanda no muevan la productividad dentro del trimestre. Con *labor hoarding*, utilización variable del capital o costos fijos, un auge de demanda altera Y_t / H_t de inmediato.
2. **En el largo plazo ($h \to \infty$):** como los rezagos de ΔH_t entran con signo negativo en la ecuación de Δx_t, el choque $\varepsilon_{2t}^{\text{Chol}}$ desplaza **permanentemente** el nivel de la productividad ($\widetilde{\Theta}(1)_{12} = -0.437 \neq 0$).
3. **Paso a Blanchard y Quah (1989):** Galí (1999) traslada el cero de $h = 0$ ($B_{12} = 0$) a $h = \infty$: $\Theta(1)_{12} = (\Psi(1)B)_{12} = 0$.

1.3 Corto plazo (Cholesky) vs. largo plazo (BQ) y rotación $Q(\psi)$

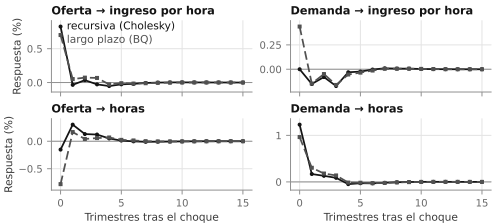


Figura: VAR(3) en $(\Delta x_t, \Delta H_t)$ con horas **totales**, 1948–2026. El recuadro usa otra especificación: horas per cápita, 1948–2007, $p = 4$.

Rotación $Q(\psi)$ en Galí (1948–2007, $p = 4$, Δh_t)

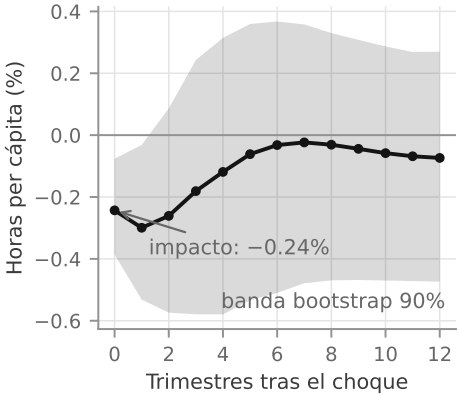
En el sistema con horas per cápita en diferencias $y_t = [\Delta x_t, \Delta h_t]'$:

- **Cholesky ($Q = I_2$):** $P = \left[\begin{smallmatrix} 0.829 & 0 \\ +\mathbf{0.104} & 0.697 \end{smallmatrix}\right]$, pero a largo plazo $\widetilde{\Theta}(1) = \widehat{\Psi}(1)P = \left[\begin{smallmatrix} 0.663 & -\mathbf{0.362} \\ 0.558 & 1.159 \end{smallmatrix}\right]$ no es triangular.
- **Ángulo de Blanchard–Quah:** para anular $\tilde{\theta}_{12} = -0.362$, el ángulo es $\psi = \arctan(-0.362/0.663) = -\mathbf{28.65}^\circ$, con matriz $Q(\psi) = \left[\begin{smallmatrix} 0.878 & 0.480 \\ -0.480 & 0.878 \end{smallmatrix}\right]$.
- **Impacto y LP rotados ($\widehat{B}_{\text{BQ}} = P\,Q(\psi)$):**

$$\widehat{B}_{\text{BQ}} = \left[\begin{smallmatrix} 0.727 & 0.397 \\ -\mathbf{0.243} & 0.662 \end{smallmatrix}\right], \quad \widehat{\Theta}(1)_{\text{BQ}} = \left[\begin{smallmatrix} 0.756 & \mathbf{0} \\ -0.066 & 1.285 \end{smallmatrix}\right].$$

La rotación de -28.65° invierte el impacto sobre las horas: de $+0.104\,\%$ (Cholesky) a $-\mathbf{0.243}\,\%$ (Blanchard–Quah).

1.3 El resultado de Galí (1999) y la réplica frente a CEV (2003)



Python (puremacro) — Galí (1999) vs. CEV (2003) en `puremacro`

```
from puremacro.var.identify.bq import bq_svar
import numpy as np, pandas as pd
df = pd.read_csv("data_curso/gali1999.csv")
df = df[pd.to_datetime(df["date"]) <= "2007-12-31"]
dx = 100 * np.log(df["ophnfb"]).diff()
h  = 100 * np.log(df["hoanbs"] / df["cnp16ov"])
# 1. Gali (1999): horas en DIFERENCIAS (dh_t)
Y_d = np.column_stack([dx-dx.mean(), h.diff()-h.diff().
      mean()])[1:]
gali = bq_svar(Y_d, p=4, horizon=20, permanent_var_idx=0)
# gali.irf_point[0, 1, 0] -> -0.243 % (IC 90 %: [-0.386,
      -0.076])
# 2. CEV (2003): horas en NIVELES (h_t), cumulate=[0]
Y_l = np.column_stack([dx - dx.mean(), h - h.mean()])[1:]
cev = bq_svar(Y_l, p=4, horizon=20, cumulate=[0])
# cev.irf_point[0, 1, 0]  -> +0.112 % (IC 90 %: [-0.315,
      +0.367])
```

Cuando h_t entra en niveles pasamos `cumulate=[0]` para acumular solo Δx_t.

1.3 ¿Por qué cambia el signo entre diferencias y niveles? Galí vs. CEV

Anatomía algebraica del cambio de signo (1948–2007, $p = 4$)

1. **La innovación de corto plazo es casi idéntica:** $P_{\text{diff}} = \left[\begin{smallmatrix} 0.829 & 0 \\ +0.104 & 0.697 \end{smallmatrix}\right]$ y $P_{\text{niv}} = \left[\begin{smallmatrix} 0.829 & 0 \\ +0.104 & 0.685 \end{smallmatrix}\right]$. En ambos casos, la correlación contemporánea reducida entre Δx_t y la innovación de horas es **levemente positiva** ($+0.104\,\%$).
2. **Lo que cambia radicalmente es el multiplicador de largo plazo $\widehat{\Psi}(1)$:**
   - En **diferencias** $[\Delta x_t, \Delta h_t]'$: la suma de coeficientes de Δh_{t-j} sobre Δx_t es negativa ($\widehat{\Psi}(1)_{12} = -0.520 \implies \tilde{\theta}_{12} = -0.362 \implies \psi = -28.65^\circ \implies \mathbf{h(0) = -0.243\,\%}$).
   - En **niveles** $[\Delta x_t, h_t]'$: como h_t tiene raíz ≈ 0.96, la suma de rezagos de h_{t-j} sobre Δx_t casi se cancela ($\sum_{j=1}^{4} \hat{A}_{12,j} \approx 0 \implies \widehat{\Psi}(1)_{12} = +0.016 \implies \psi = +0.73^\circ \implies \mathbf{h(0) = +0.112\,\%}$).

Moraleja econométrica del debate

- El pretest de raíz unitaria sobre h_t **decide el ángulo de rotación ψ y el signo de impacto de las horas**.
- Si h_t tiene raíz cercana a 1 pero se estima en niveles, $\sum_{j=1}^{p} \hat{A}_{12,j} \approx 0$ apaga mecánicamente la rotación de largo plazo ($\psi \approx 0^\circ$).
- Si $h_t \sim I(0)$ y se sobrediferencia (Δh_t), se introduce una raíz unitaria MA no invertible en frecuencia cero (CEV 2003).

1.3 Laboratorio en `puremacro`: cinco esquemas de identificación sobre Galí

Comparamos sobre el mismo conjunto de datos (`gali1999.csv`, 1948–2007, $p = 4$) cinco esquemas de identificación de `puremacro.var.identify`:

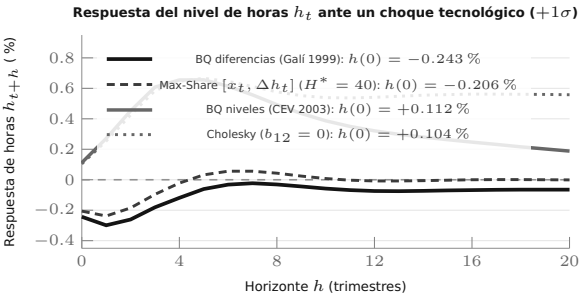
Esquema	$x(0)$	$h(0)$ **[IC 90 %]**	$h(4)$	$x(20)$
1. `cholesky_svar` (Δh_t)	$+0.829$	$+0.104$ $[+0.03, +0.19]$	$+0.646$	$+0.662$
2. `bq_svar` (Galí, Δh_t)	$+0.727$	$\mathbf{-0.243}$ $[-0.39, -0.08]$	-0.119	$+0.755$
3. `bq_svar` (CEV, h_t niv.)	$+0.829$	$\mathbf{+0.112}$ $[-0.32, +0.37]$	$+0.655$	$+0.763$
4. `identify_maxshare` ($[x, \Delta h]$)	$+0.746$	$\mathbf{-0.206}$ (FEV 97.9 %)	-0.022	$+0.687$
5. `identify_maxshare` ($[x, h]$)	$+0.824$	$+0.058$ (FEV 97.0 %)	$+0.577$	$+0.732$
6. `sign_restrictions` ($h(0) \gtrless 0$)	$+0.608$	$+0.101$ $[-0.66, +0.70]$	$+0.614$	$+0.460$
7. `sign_restrictions` ($h(0) < 0$)	$+0.554$	-0.450 $[-0.69, -0.06]$	-0.633	$+0.707$

Python (puremacro) — Triangulación en `puremacro`

```
from puremacro.var.identify import (
    cholesky_svar, bq_svar,
    identify_maxshare, sign_restrictions
)
r_c  = cholesky_svar(Y_d, p=4, horizon=20)
r_bq = bq_svar(Y_d, p=4, horizon=20)
r_ms = identify_maxshare(
    Y_x_dh, p=4, target_idx=0,
    max_fev_at=40, horizon=40
)
r_sr = sign_restrictions(  # fila 7
    Y_d, p=4, horizon=20,
    restrictions={0: [+1, -1]}
)
```

Nota sobre `identify_maxshare`: para maximizar la FEVD a 40 trimestres del **nivel** de productividad como en Francis et al. (2014), la columna 0 debe ser el nivel x_t ($Y_{\text{x_dh}} = [x_t, \Delta h_t]'$ o $Y_{\text{x_h}} = [x_t, h_t]'$).

1.3 Comparación de IRFs de las horas bajo cuatro esquemas de identificación



Tres conclusiones de la triangulación

1. **Robustez del horizonte finito:** con Δh_t, sustituir $h = \infty$ (`bq_svar`) por $H^* = 40$ (`identify_maxshare`) preserva la caída de impacto de las horas ($-0.243\,\%$ vs. $-0.206\,\%$, explicando el $97.9\,\%$ de la FEVD de x_t a 10 años).
2. **Tratamiento de bajas frecuencias:** tanto en BQ como en *Max-Share*, pasar de Δh_t a h_t en niveles desplaza la respuesta a valores positivos ($+0.112\,\%$ y $+0.058\,\%$).
3. **Restricciones de signo:** imponiendo solo $\Theta_{h,11} > 0$ (dejando libre $h(0)$), el conjunto $[-0.66\,\%, +0.70\,\%]$ abarca ambos signos.

1.4 Extensión a Fisher (2006): dos choques tecnológicos (IST y Neutro)

Galí (1999) supone una **única fuente de cambio tecnológico permanente**. Pero la caída secular del precio relativo de los bienes de inversión —especialmente equipo y software— respecto al consumo revela una segunda fuente: el **progreso técnico específico a la inversión (IST)**.

Marco de Greenwood–Hercowitz–Krusell (2000) y Fisher (2006)

- **Tecnología y acumulación:** $Y_t = A_t K_t^{\alpha} H_t^{1-\alpha}$ y $K_{t+1} = (1-\delta)K_t + V_t I_t$, donde A_t es tecnología **neutra** (PTF) y V_t es eficiencia **específica a la inversión (IST)**.
- **Precio relativo de la inversión:** en equilibrio competitivo $p_{I,t} \equiv P_{I,t}/P_{C,t} = V_t^{-1}$, por lo que $\Delta \log p_{I,t} = -\Delta \log V_t +$ ruido transitorio.
- **Fallo del SVAR bivariado:** tanto una mejora en A_t como una mejora en V_t (que induce profundización de capital K_t/H_t) **elevan permanentemente** Y_t/H_t. Un SVAR bivariado mezcla ambos choques.

Literatura sobre tecnología y ciclo

- **Kydland y Prescott (1991):** la PTF explica $\sim 70\,\%$ de la varianza cíclica (Prescott 1986b: $\sim 75\,\%$).
- **Greenwood, Hercowitz y Krusell (2000):** el progreso técnico en equipo explica $\sim 30\,\%$ de las fluctuaciones del producto.
- **Basu, Fernald y Kimball (2006):** depurando el residuo de Solow por utilización y esfuerzo, un choque neutro **contrae** las horas en impacto.
- **Fisher (2006, *JPE*):** separa en un SVAR trivariado el choque IST ($\varepsilon_t^{\mathrm{IST}}$) del choque tecnológico neutro ($\varepsilon_t^{\mathrm{N}}$).

1.4 El SVAR trivariado de Fisher (2006): restricciones y matrices estimadas

Fisher (2006) ordena $y_t = [\Delta \log p_{I,t},\ \Delta \log(Y_t/H_t),\ \Delta \log h_t]'$ frente a los tres choques estructurales $\varepsilon_t = [\varepsilon_t^{\text{IST}},\ \varepsilon_t^{\text{N}},\ \varepsilon_t^{\text{D}}]'$ (IST, tecnológico neutro y no tecnológico/demanda):

Las $\frac{3(3-1)}{2} = 3$ restricciones de largo plazo

La matriz de multiplicadores acumulados de largo plazo $\Theta(1) = \Psi(1)B$ sobre $[\log p_{I,t},\ \log(Y_t/H_t),\ \log h_t]'$ es **triangular inferior**:

$$\Theta(1) = \Psi(1)B = \begin{bmatrix} \theta_{11} & \mathbf{0} & \mathbf{0} \\ \theta_{21} & \theta_{22} & \mathbf{0} \\ \theta_{31} & \theta_{32} & \theta_{33} \end{bmatrix}.$$

1. $\Theta(1)_{12} = \Theta(1)_{13} = 0$: **solo el choque IST ($\varepsilon_t^{\text{IST}}$)** altera permanentemente el precio relativo de la inversión $p_{I,t}$.
2. $\Theta(1)_{23} = 0$: **solo los dos choques tecnológicos ($\varepsilon_t^{\text{IST}}$ y ε_t^{N})** alteran permanentemente la productividad laboral Y_t/H_t.

Matrices estimadas (PIRIC, 1948–2019, $p = 4$)

Estimamos $\widehat{\Theta}(1) = \begin{bmatrix} 0.864 & \mathbf{0.000} & \mathbf{0.000} \\ -0.259 & 0.728 & \mathbf{0.000} \\ 0.189 & -0.269 & 1.368 \end{bmatrix}$ e impacto $\widehat{B} = \widehat{\Psi}(1)^{-1}\widehat{\Theta}(1)$:

$$\widehat{B}_{\text{Fisher}} = \begin{bmatrix} 0.465 & 0.169 & -0.016 \\ -0.287 & 0.608 & 0.418 \\ 0.063 & \mathbf{-0.285} & 0.604 \end{bmatrix}.$$

- **Signo del choque IST:** un **abaratamiento del equipo** es $-\varepsilon_t^{\text{IST}}$: baja $p_{I,\infty}$ en $-0.864\,\%$ y **sube la productividad a LP** en $-\hat{\theta}_{21} = +0.259\,\%$.
- Un choque **neutro** $+\varepsilon_t^{\text{N}}$ sube la productividad ($+0.728\,\%$ a LP) pero **contrae las horas en impacto ($\hat{b}_{32} = -0.285\,\%$)**.

1.4 Implementación del SVAR de Fisher (2006) en `puremacro`

Disponemos de dos deflactores relativos de la inversión: `PIRIC.csv` (inversión fija / consumo) y `PERIC.csv` (equipo real / consumo, Cummins–Violante usada por Fisher 2006; ver `fig_peric_piric.pdf` en la lámina “El equipo se abarata” de las semanas 1–2).

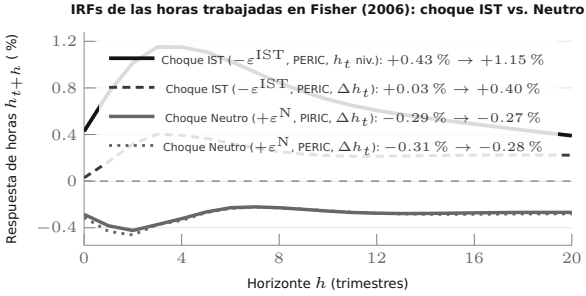
Python (puremacro) — Estimación de Fisher (2006) con `bq_svar`

```
import numpy as np, pandas as pd
from puremacro.var.identify import bq_svar
p_i = pd.read_csv("data_curso/PERIC.csv", index_col=0, parse_dates
      =True)["PERIC"]
g   = pd.read_csv("data_curso/gali1999.csv", index_col=0,
      parse_dates=True)
q   = pd.concat({"p": p_i, "x": g["ophnfb"],
      "h": g["hoanbs"]/g["cnp16ov"]}, axis=1).dropna().loc
      ["1955":"2007"]
Y = (100 * np.log(q)).diff().dropna().to_numpy()
res_diff = bq_svar(Y, p=4, horizon=40, permanent_var_idx=0)
# Horas en niveles (Fisher 2006): cumulate=[0, 1]
h_lvl = 100 * np.log(q["h"]).iloc[1:].to_numpy()
Y_lvl = np.column_stack([Y[:, 0], Y[:, 1], h_lvl - h_lvl.mean()])
res_lvl = bq_svar(Y_lvl, p=4, horizon=40, cumulate=[0, 1])
```

Detalles de implementación

- **Dimensión $n = 3$ en `bq_svar`:** `puremacro` factoriza $\widehat{\Theta}(1) = \mathrm{chol}(\widehat{\Psi}(1)\widehat{\Sigma}_u\widehat{\Psi}(1)')$ para cualquier $n \geq 2$, imponiendo las 3 restricciones triangulares de largo plazo.
- **Acumulación selectiva:** con h_t en niveles, `cumulate=[0, 1]` acumula solo $\Delta \log p_{I,t}$ y Δx_t.
- **PIB per cápita:** h_t son horas por persona, así que $\log(Y_t/N_t) \equiv x_t + h_t$ y su IRF es $\Theta^{\text{nivel}}_{h,x,j} + \Theta^{\text{nivel}}_{h,h,j}$.

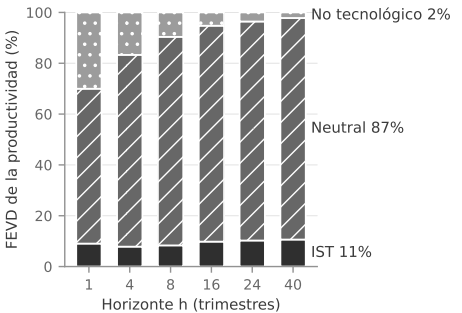
1.4 IRFs de las horas trabajadas en Fisher (2006): choque IST vs. Neutro



Reconciliación entre Galí (1999) y el RBC

- **Choque tecnológico neutro ($+\varepsilon_t^{\mathbf{N}}$):** tanto con PIRIC ($-0.285\,\%$) como con PERIC ($-0.311\,\%$), un choque neutro positivo **contrae las horas trabajadas en impacto**, confirmando el mecanismo de Galí (1999) y Basu et al. (2006).
- **Choque específico a la inversión ($-\varepsilon_t^{\mathbf{IST}}$):** cuando el equipo se abarata permanentemente, las empresas invierten hoy para instalar el nuevo capital; la sustitución intertemporal eleva las horas desde el impacto ($+0.427\,\%$ en niveles con pico de $+1.151\,\%$ en $h = 3$, y hasta $+0.403\,\%$ en diferencias).

1.4 FEVD en Fisher (2006) y síntesis del ejemplo rector



Lectura de la figura: FEVD del **nivel de la productividad** x_t bajo PIRIC en diferencias. Que los dos choques tecnológicos sumen $\mathbf{97.8}\,\%$ a $h = 40$ ($10.6\,\%$ IST $+87.2\,\%$ Neutro) es consecuencia **mecánica** de imponer $\Theta(1)_{13} = \Theta(1)_{23} = 0$: la cuota del choque no tecnológico en el nivel $I(1)$ de x_t converge a $0\,\%$ cuando $h \to \infty$.

Especificación	Variable	h	IST	Neutro	No-tec.
PIRIC, Δh_t	Productividad x_t	8	$8.3\,\%$	$82.1\,\%$	$9.6\,\%$
(1948–2019)	Productividad x_t	40	$10.6\,\%$	$87.2\,\%$	$2.2\,\%$
	Horas h_t	40	$1.6\,\%$	$3.9\,\%$	$94.4\,\%$
	PIB p.c. $x_t + h_t$	40	$0.3\,\%$	$9.4\,\%$	$90.3\,\%$
PERIC, h_t niv.	Productividad x_t	8	$12.1\,\%$	$79.5\,\%$	$8.4\,\%$
(Fisher 2006,	Productividad x_t	40	$22.2\,\%$	$74.6\,\%$	$3.2\,\%$
1955–2007)	Horas h_t	8	$\mathbf{72.0}\,\%$	$0.7\,\%$	$27.2\,\%$
	Horas h_t	40	$\mathbf{73.3}\,\%$	$0.8\,\%$	$25.9\,\%$
	PIB p.c. $x_t + h_t$	8	$\mathbf{68.3}\,\%$	$24.0\,\%$	$7.7\,\%$

Síntesis 2×2: Galí (1999) – CEV (2003) – Fisher (2006)

1. **Especificación (Δh_t vs. h_t):** determina el ángulo de rotación ψ de largo plazo; en diferencias $\widehat{\Psi}(1)_{12} < 0$ gira el impacto hacia $h(0) < 0$.
2. **Desagregación tecnológica (1 vs. 2 choques):** al separar equipo (PERIC) de PTF neutra, el choque neutro explica $< 1\,\%$ de las horas, mientras que el **choque IST explica hasta 72–$73\,\%$ de las horas y $68\,\%$ del PIB per cápita a 2 años**.

Narrativa y proxy-IV

Choques fiscales y monetarios

Semana 10 · Laboratorio: el multiplicador impositivo por tres vías

Identificaciones no triangulares

Un ejemplo que merece especial atención es Blanchard & Perotti (2002), porque adoptan un enfoque no recursivo y porque estudian el papel de los choques estructurales en impuestos y gasto sobre la actividad económica.

$$\begin{bmatrix} 1 & 0 & a_{13} \\ 0 & 1 & a_{23} \\ a_{31} & a_{32} & 1 \end{bmatrix} \begin{pmatrix} u_t^{tax} \\ u_t^{gov} \\ u_t^{gdp} \end{pmatrix} = \begin{bmatrix} 1 & b_{12} & 0 \\ b_{21} & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{pmatrix} \epsilon_t^{tax} \\ \epsilon_t^{gov} \\ \epsilon_t^{gdp} \end{pmatrix}.$$

Asumen $a_{23} = 0$ argumentando rezagos legislativos que impiden que el gasto del gobierno reaccione a la actividad económica en el mismo trimestre, estiman a_{13} (la elasticidad cíclica de los impuestos) usando información institucional externa, e imponen b_{12} o b_{21} iguales a cero.

Los impactos e IRFs bajo este esquema de identificación no pueden estimarse de forma recursiva, por lo que es necesario recurrir a estimadores distintos del OLS. Esta identificación **institucional** prepara el terreno para el enfoque proxy-IV de Mertens & Ravn que veremos con el multiplicador impositivo.

Métodos de identificación narrativos

El enfoque narrativo consiste en buscar evidencia que permita argumentar que una serie de choques es claramente estructural y exógena. No hay otra forma de explicarlo que a través de ejemplos:

- Hamilton (1985) y Hoover & Perez (1994) identifican choques petroleros basados en noticias y eventos geopolíticos
- Ramey & Shapiro (1998) y Ramey (2011) identifican choques al gasto del gobierno usando información del semanario “Business Week” sobre gastos en defensa. Además, se han usado fechas de guerras como instrumentos
- Romer & Romer (2010) construyen choques estructurales a los impuestos leyendo documentos oficiales de EUA: el *Economic Report of the President*, reportes del Congreso y del Tesoro, y discursos presidenciales
- Mertens & Ravn (2012) usan el enfoque narrativo y los rezagos en la ejecución de la legislación desde su anuncio para distinguir entre choques fiscales esperados y sorpresas

Romer & Romer (2010)

Así funcionaría el método narrativo para documentar un recorte impositivo de corto plazo (la documentación de los recortes de largo plazo y las series resultantes siguen la misma lógica; en el laboratorio las veremos como datos):

Tax Reduction Act of 1975

Signed:	3/29/75	
Change in Liabilities (excluding retroactive changes):		
1975:II	−$45.3 billion	(Endogenous; Countercyclical)
1975:III	+$32.5 billion	(Endogenous; Countercyclical)
Change in Liabilities (including retroactive changes):		
1975:II	−$58.1 billion	(Endogenous; Countercyclical)
1975:III	+$45.3 billion	(Endogenous; Countercyclical)
Present Value:		
1975:III	−$13.32 billion	(Endogenous; Countercyclical)

The Tax Reduction Act of 1975 was a change in taxes that was made to try to return economic growth to normal. In early 1975, growth was weak and expected to remain weak in the absence of changes in policy. The 1975 *Economic Report* stated, "As 1975 begins, … production and employment are declining sharply. … It is quite likely … that the contraction of business activity and rising unemployment will continue for several more months" (p. 19). Likewise, the President's Annual Budget Message to the Congress, Fiscal Year 1976 declared: "It must be clearly understood that these problems are serious and that strong remedies are fully justified. The economy is now in a recession" (2/3/75, p. 2).

El multiplicador impositivo por tres vías

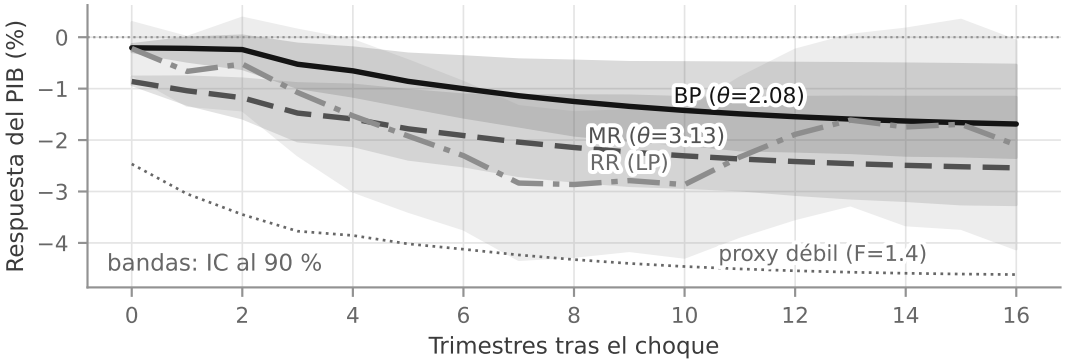
Un mismo objeto —la respuesta del PIB a un cambio impositivo— y tres estrategias de identificación:

1. **Institucional** (Blanchard & Perotti 2002): elasticidades fiscales y rezagos legislativos, con $\theta = 2.08 \Rightarrow$ pico -1.55 en $h = 12$
2. **Narrativa + LP** (Romer & Romer 2010): los choques leídos de documentos oficiales, directamente como regresor — en espíritu, una LP del choque narrativo (RR usan una regresión de rezagos distribuidos) $\Rightarrow$ pico -2.87 en $h = 10$ (-2.86 a dos años)
3. **Proxy-SVAR** (Mertens & Ravn 2013, 2014): la serie narrativa como **instrumento** de los residuos del VAR identifica la elasticidad, $\theta = 3.13$ (Mertens y Ravn 2014); llevada al SVAR de BP da pico -2.42 (el proxy directo sobre ingresos agregados tiene $F = 1.4$ y se hunde a -4.5); MR reportan en su artículo -2 a -3

La discrepancia es la pregunta: ¿atenuación por error de medida en la serie narrativa (el argumento de MR a favor del proxy) o exogeneidad dudosa de los choques narrativos?

Refs.: Romer y Romer (2010); Mertens y Ravn (2013, 2014); Blanchard y Perotti (2002).

Las tres sendas, una al lado de la otra



- Alza impositiva de 1 % del PIB, muestra 1950T1–2006T4; en el punto más bajo de los tres primeros años (BP -1.55, MR -2.42, RR -2.87) BP es la menos negativa y RR la más: ese orden sostiene la discusión de la lámina anterior. Pasado $h = 12$, BP y MR siguen bajando despacio y RR remonta
- La cuarta línea es una **advertencia**, no un resultado: el proxy crudo sobre datos agregados sale con instrumento débil (F efectiva $= 1.4$) y se hunde hasta -4.54 al tercer año

Cuadernos: `T04_A_tax_multiplier_three_ways` (celda 21) y `T05_A_svar_identification` (mecánica de `proxy_svar`, sobre un VAR monetario).

Laboratorio: las tres vías con `puremacro` (Proxy-SVAR)

Todo corre offline: `load_romer_romer_2010()` cae por defecto en el snapshot empaquetado, y los datos fiscales están en `data_curso/tax14_us_fiscal.csv` y `data_curso/tax14_narrative_tax_shocks.csv`.

```
# Esquema: completar datos y argumentos en el cuaderno.
from puremacro import lp, narrative
from puremacro.var.identify.proxy import proxy_svar
import pandas as pd

rr  = narrative.load_romer_romer_2010()        # serie narrativa (offline)
fis = pd.read_csv('data_curso/tax14_us_fiscal.csv')  # PIB, recaudacion, gasto (data_curso/)

irf1 = lp.lp_hac(...)   # (i)  LP directa del choque narrativo
irf2 = lp.lp_iv(...)    # (ii) narrativa como IV de la recaudacion
                        #      reportar fuerza por horizonte e inferencia robusta
irf3 = proxy_svar(...)  # (iii) proxy-SVAR (Mertens-Ravn)
```

- Relacionen cada choque narrativo grande con la legislación que lo motivó.
- Reporten el **F efectivo** y el criterio de referencia de Montiel Olea y Pflueger (2013). Ni 10 ni 23.1 son umbrales universales para cualquier diseño.
- Con instrumentos débiles, usen inferencia robusta, como Anderson–Rubin con una estimación de covarianza adecuada. Su validez también exige exogeneidad y una especificación correcta.

Romer y Romer (2004): la misma navaja narrativa, ahora monetaria

El choque monetario es el ejemplo canónico de la literatura; la estrategia es simétrica a la fiscal de Romer & Romer (2010):

- De las minutas del FOMC extraen el cambio **deseado** de la tasa de fondos federales en cada reunión
- Lo purgan de la respuesta sistemática a la información de la Fed: regresan el cambio deseado sobre los pronósticos internos (Greenbook) de inflación y actividad
- El residuo es el choque monetario narrativo: contractivo, reduce la producción industrial de forma sustancial con un rezago de $\sim$2 años
- La crítica es la misma que a la narrativa fiscal: ¿es el residuo exógeno, o la Fed sabe algo que el Greenbook no recoge?

Refs.: Romer y Romer (2004); Romer y Romer (2010).

Gertler y Karadi (2015): sorpresas de alta frecuencia como proxy

Segundo ejemplo del **mismo** proxy-SVAR: el instrumento ya no se lee, se **mide** en el mercado.

- La sorpresa monetaria es el cambio del futuro de fondos federales en una ventana de 30 minutos alrededor del anuncio del FOMC: una ventana estrecha reduce la exposición a otras noticias; no garantiza exogeneidad ni separa política de información del banco central
- Esa sorpresa instrumenta los residuos de la tasa en un VAR con producción, precios y el diferencial de crédito: el canal crediticio amplifica el choque
- En México: las sorpresas de anuncios de **Banxico** son construibles con el conector `iter_banxico_decision` (las fechas y comunicados ya están disponibles); el instrumento de mercado exige series intradía de TIIE o futuros de tasa

Refs.: Gertler y Karadi (2015); Nakamura y Steinsson (2018); Känzig (2021).

Proyecciones locales

Inferencia HAC, multiplicadores dependientes del estado y diseños de panel

Semana 10, segunda mitad

Laboratorio: Ramey–Zubairy en vivo

La proyección local estima la IRF sin comprometerse con el VAR

La función de impulso respuesta responde a la pregunta central: ¿cuál es el impacto causal de un choque estructural sobre una variable agregada?

$$\frac{\Delta y_{jt+h}}{\Delta \epsilon_{it}} = d_{ijh},$$

con d_{ijh} función de la variable j, del choque i y del horizonte h. Leída desde un VAR, es una combinación no lineal de todos sus coeficientes: **óptima para cualquier h si el VAR captura el verdadero PGD**, y contaminada en todo horizonte si no. Jordà (2005, 2023) propone estimar cada horizonte por separado:

$$y_{jt+h} = \theta^{i}_{jh}\, \epsilon_{it} + \Gamma X_t + \upsilon_{jt+h},$$

donde θ^{i}_{jh} **es** la respuesta al horizonte h y X_t recoge los controles (rezagos, deterministas).

- Un error de dinámica en $h = 1$ no se propaga a $h = 12$: cada horizonte es una regresión distinta
- Admiten datos de panel, variables instrumentales y efectos geográficos
- Admiten cambios de régimen: un mismo choque fiscal con efecto distinto en expansión y en recesión
- En Python, el módulo `puremacro.lp`; MATLAB tiene toolboxes equivalentes

El residuo de una LP a horizonte h es un MA($h-1$): sin HAC, los EE mienten

En la LP $y_{t+h} = \theta_h \, \epsilon_t + \Gamma X_t + \upsilon_{t+h}$, el residuo acumula **por construcción** los h choques que llegan entre $t+1$ y $t+h$:

$$\upsilon_{t+h} = \epsilon_{t+h} + \psi_1 \epsilon_{t+h-1} + \cdots + \psi_{h-1} \epsilon_{t+1},$$

así que dos observaciones consecutivas comparten choques (solapamiento de horizontes) y υ es un proceso MA($h-1$): sus autocovarianzas solo se anulan a partir del rezago h, y los errores estándar de OLS clásicos están mal.

- **Newey–West**: la respuesta estándar es una matriz de covarianzas HAC con ancho de banda (*bandwidth*) $\geq h-1$ — es el "`hac`" de `lp.lp_hac`, que usa $h+1$
- **Lag-augmented LP** (Montiel Olea y Plagborg-Møller 2021, *Econometrica*): si se incluyen los rezagos de todas las variables como controles, la inferencia es válida con errores robustos ordinarios, sin elegir truncamiento — y es lo que justifica el "mismos rezagos como controles" del código
- Regla práctica: rezagos como controles siempre; HAC con ancho de banda $\geq h$ como cinturón adicional cuando el horizonte es largo respecto de la muestra

LP vs. SVAR: mismos datos, ¿misma IRF?

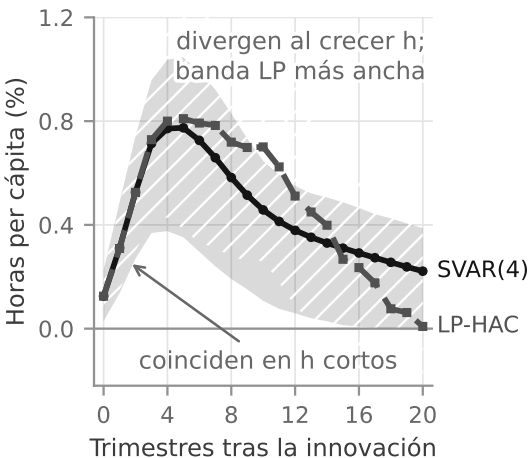
Sobre los datos de Galí, estimamos la IRF por Cholesky-SVAR y por proyección local con los **mismos rezagos**:

```
from puremacro import lp
from puremacro.var.identify.cholesky import cholesky_svar

# df: columnas 'dprod' (100*dlog product.) y 'h' (100*log horas p.c.)
Y = df[['dprod', 'h']].to_numpy()       # cholesky_svar toma el NDARRAY
irf_var = cholesky_svar(Y, p=4, horizon=20)
irf_lp  = lp.lp_hac(df, y='h', x='dprod',   # lp_hac toma el DATAFRAME
                    horizons=range(0, 21), n_lags=4)  # mismos 4 rezagos
```

Las dos IRF, con sus bandas, están en la lámina siguiente.

LP vs. SVAR: coinciden en h pequeños y divergen al crecer h



Coinciden en h pequeños; divergen al crecer h, con bandas LP mucho más anchas.

Las dos líneas salen de los **mismos** datos (`gali1999`, 1948–2007) y los **mismos** cuatro rezagos: lo único que cambia es si la dinámica de horizontes largos la impone el VAR o la estima cada regresión por separado.

En población, LP y VAR estiman la misma IRF: la elección es sesgo–varianza

- En población estiman **la misma** IRF (Plagborg-Møller y Wolf 2021): la elección es sesgo–varianza en muestra finita, no identificación — vacuna contra la guerra de religión LP-vs-VAR

Advertencia Econométrica: Guía de Selección SVAR vs. LP

- **Sesgo vs. Varianza:** LP evita imponer la misma recursión en todos los horizontes, pero puede ser imprecisa en muestras cortas. El VAR impone esa estructura; si es incorrecta, puede sesgar horizontes largos.
- **Regla práctica:** Comparar ambos con igual identificación, muestra y normalización. Elegir horizontes por la pregunta y la información disponible; no hay un corte universal en 12 o 16 periodos.

Refs.: Plagborg-Møller y Wolf (2021); Li, Plagborg-Møller y Wolf (2024); Jordà (2005, 2023); Jordà y Taylor (2025).

El multiplicador es un cociente de respuestas acumuladas, no un coeficiente

La literatura fiscal contesta dos preguntas: ¿puede el gasto público generar una expansión o una contracción? y ¿cuál es el efecto de mover los impuestos? La segunda ya tiene tres respuestas —institucional, narrativa y proxy-SVAR—; la del gasto exige antes definir bien el objeto que se reporta:

$$\mathcal{M}_h = \frac{\sum_{s=0}^{h} d_{ygs}}{\sum_{s=0}^{h} d_{ggs}} \times \frac{\bar{Y}}{\bar{G}}.$$

- Derivación del factor de conversión: si las IRFs vienen en puntos porcentuales, $\Delta Y_s = \bar{Y}\, d_{ygs}$ y $\Delta G_s = \bar{G}\, d_{ggs}$, así que el cociente en unidades de producto es el de arriba. Con $\bar{G}/\bar{Y} \approx 0.2$, el factor **multiplica por cinco** la elasticidad: confundir el sentido del cociente cambia un multiplicador de 1 por uno de 0.04
- Ramey–Zubairy evitan el problema especificando Y y G ya divididos entre el PIB de tendencia (a la Gordon–Krenn): el factor desaparece y el coeficiente **es** el multiplicador
- El “multiplicador pico” (cociente de picos) no es este objeto: los picos ocurren en horizontes distintos. Buena parte de la dispersión entre estudios es de contabilidad, no de economía

Al igual que con los choques a la productividad, todo depende de conseguir choques exógenos al gasto.

Choques al gasto público

- Rotemberg & Woodford (1992) usan el residuo de un $AR(p)$ sobre el gasto militar como choques exógenos al gasto público. Encuentran que choques al gasto público aumentan los salarios reales
- Ramey & Shapiro (1998) emplean un enfoque narrativo leyendo notas en “Business Week” sobre el ejército y fechas de conflictos militares
  - Cuando se usa la variable de fechas de guerras en primer lugar en el orden del vector, surgen los EVAR de Ramey (2011)
  - La literatura encuentra que los choques al gasto público aumentan el PIB y las horas de trabajo, pero reducen el consumo y los salarios reales
- McGrattan (1994) realiza una de las primeras estimaciones de choques estructurales al gasto público
- Blanchard & Perotti (2002): para el choque de gasto, la identificación equivale a una Cholesky con G ordenado primero; la del choque impositivo usa la elasticidad institucional (no recursiva, ver la lámina de identificaciones no triangulares)

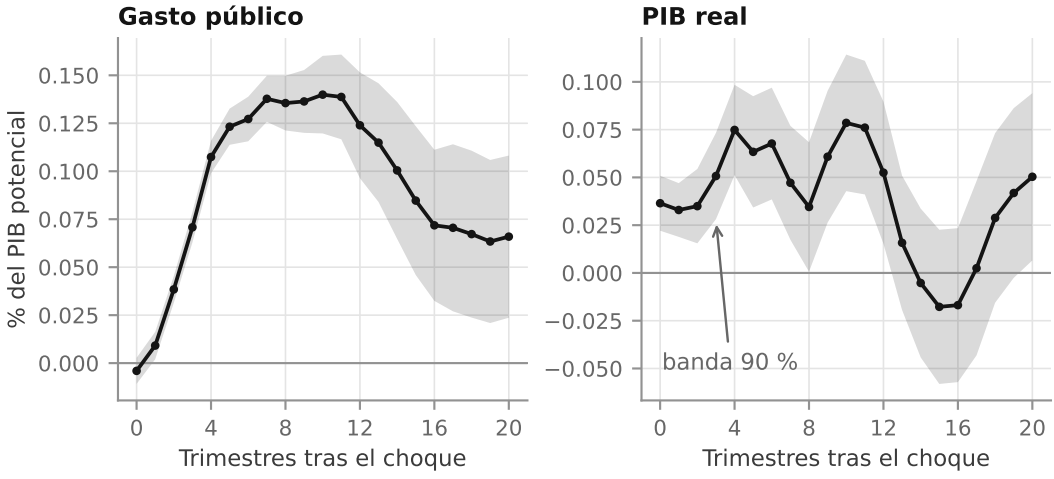
Estimaciones del multiplicador del gasto público

Estudio	Muestra	Identificación	Multiplicador implícito
Barro (1981); Hall (1986, 2009); Barro–Redlick (2011)	Muestras anuales históricas	Gasto militar como instrumento del gasto público	0.6–1
Rotemberg–Woodford (1992)	Trimestral, 1947–1989	Residuo de una regresión del gasto militar sobre sus rezagos y los del empleo militar	1.25
Ramey–Shapiro (1998); Edelberg et al. (1999); Burnside et al. (2004)	Trimestral, 1947–fin. 1990s/2000s	Fechas de Ramey–Shapiro (expansiones militares anticipadas, narrativa)	0.6–1.2, según muestra y método (acum./pico)
Blanchard–Perotti (2002)	Trimestral, 1960–1997	SVAR, Cholesky con G ordenado primero	0.9–1.29, multiplicadores pico
Mountford–Uhlig (2009)	Trimestral, 1955–2000	Restricciones de signo sobre un SVAR	0.65 (aumento financiado con déficit)
Romer y Bernstein (2009)	Trimestral	Promedio de multiplicadores del modelo FRB/US y de un modelo privado de pronósticos	Sube a 1.57 al 8.º trim.
Cogan et al. (2010)	Trimestral, 1966–2004	Modelo Smets–Wouters estimado	0.64 en el pico
Ramey (2011a,b)	Trimestral, 1939–2008 y submuestras	VAR con choques narrativos al valor presente esperado del gasto militar	0.6–1.2, según muestra
Fisher–Peters (2010)	Trimestral, 1960–2007	VAR con choques al exceso de rendimiento bursátil de contratistas militares	1.5, efectos acumulados
Auerbach y Gorodnichenko (2012)	Trimestral, 1947–2008	SVAR con pronósticos profesionales y noticias de Ramey; cambio de régimen	Exp.: -0.3 a 0.8; rec.: 1–3.6
Ben Zeev y Pappa (2017)	Trimestral, 1947–2007	Choque ortogonal al gasto de defensa que mejor explica su dinámica a 5 años	2.1 (multiplicador integral a 6 trim.)

Fuente: Ramey (2016), *Macroeconomic Shocks and Their Propagation*, Handbook of Macroeconomics, vol. 2A, cuadro 3.

Una noticia de gasto militar eleva el gasto y, con él, el PIB

Proyección local de Jordà con 4 rezagos y bandas del 90 % de Newey–West, sobre `rz2018` (EUA, 1947–2015); ambas variables van en % del PIB potencial de Gordon–Krenn.



El multiplicador no es un parámetro: lo fija la senda de la tasa real

En el modelo de Woodford (2011) —sin capital ni sector externo, utilidad separable, impuestos de suma fija— $Y_t = C_t + G_t$, así que $\mathcal{M} = 1 + dC/dG$. La Euler log-lineal, iterada hacia adelante, dice qué mueve a C:

$$\hat{c}_t \;=\; -\sigma \sum_{j=0}^{\infty} \mathbb{E}_t\big(r_{t+j} - r^n\big).$$

Tres respuestas monetarias, tres multiplicadores

- **Regla de Taylor:** $r \uparrow \Rightarrow\ \hat{c} < 0\ \Rightarrow\ \mathcal{M} < 1$.
- **Tasa real constante:** $\hat{c} = 0\ \Rightarrow\ \mathcal{M} = 1$ exactamente.
- **Tasa nominal en su cota inferior:** el gasto sube la inflación esperada, $r \downarrow \Rightarrow\ \hat{c} > 0\ \Rightarrow\ \mathcal{M} > 1$: 2.3 en Eggertsson (2011); 3.7 en el modelo simple de Christiano, Eichenbaum y Rebelo (2011).

Lo que el hogar representativo deja fuera

- **Holgura laboral:** con fricciones de búsqueda, el multiplicador del empleo público se duplica cuando el desempleo pasa de 5 % a 8 % (Michaillat 2014).
- **Quién recibe y cómo se financia:** con tasa real constante, el gasto financiado con deuda tiene multiplicador acumulado 1 con agente representativo y muy por encima de 1 con hogares heterogéneos (Auclert, Rognlie y Straub 2024; mazo 6).
- **Régimen monetario-fiscal y cambiario:** gasto sin respaldo fiscal futuro; tipo de cambio fijo o unión monetaria.

"¿Es mayor en recesión?" es la pregunta de **qué hace la tasa real** en recesión; es también la c que el corte transversal no ve.

Woodford (2011); Eggertsson (2011); Christiano, Eichenbaum y Rebelo (2011); Michaillat (2014); Auclert, Rognlie y Straub (2024).

Por régimen, la evidencia más firme no está en la holgura sino en la respuesta monetaria

Régimen	Evidencia (multiplicador)	Lectura
Holgura, EUA	AG (2012): 2.24 en recesión contra -0.33 en expansión, acumulado a 20 trimestres (2.17 contra -0.80 en su corrección de 2013). RZ (2018): 0.60 contra 0.59 a dos años ($p = 0.95$)	Se separan por la medición (lámina siguiente)
Holgura, otros	Canadá: 1.60 contra 0.44 a dos años (Owyang, Ramey y Zubairy 2013). Metaanálisis: el gasto rinde 0.7–0.9 más en recesión; los impuestos no dependen del régimen (Gechert y Rannenberg 2018)	Señal mixta
Cota inferior o acomodación	RZ: 0.77 contra 0.63 (1.40 contra 0.63 sin la 2GM). Japón: 1.5 contra 0.6 al impacto (Miyamoto, Nguyen y Sergeyev 2018). Historia internacional: hasta 1.5 contra ≈ 0 (Klein y Winkler 2021). De ≈ 0 a ≈ 2 según cuánto acomoda el banco central (Cloyne, Jordà y Taylor 2023)	Lo que predice la lámina anterior
Tipo de cambio y apertura	Largo plazo: fijo 1.4 contra flexible -0.7; cerrada 1.1 contra abierta -0.5 (Ilzetzki, Mendoza y Végh 2013, versión de trabajo)	El banco central propio compensa
Régimen monetario-fiscal	Valor presente a 10 años: $[1.5,\ 1.9]$ en régimen F contra $[0.1,\ 0.4]$ en régimen M (Leeper, Traum y Walker 2017)	Quién respalda la deuda
Deuda	Pública alta: ≈ 0 contra ≈ 0.6 a dos años (Huidrom, Kose, Lim y Ohnsorge 2020). Privada alta: “mucho mayor que uno” (Bernardini y Peersman 2018)	Espacio fiscal y balances

Las cifras no se comparan entre filas (horizonte, muestra, definición). El balance de Ramey (2019): los multiplicadores mayores que 1 con holgura “no suelen ser robustos”; en la cota inferior, 1.5–2.5 en Japón y ≈ 1.5 con datos históricos de EUA.

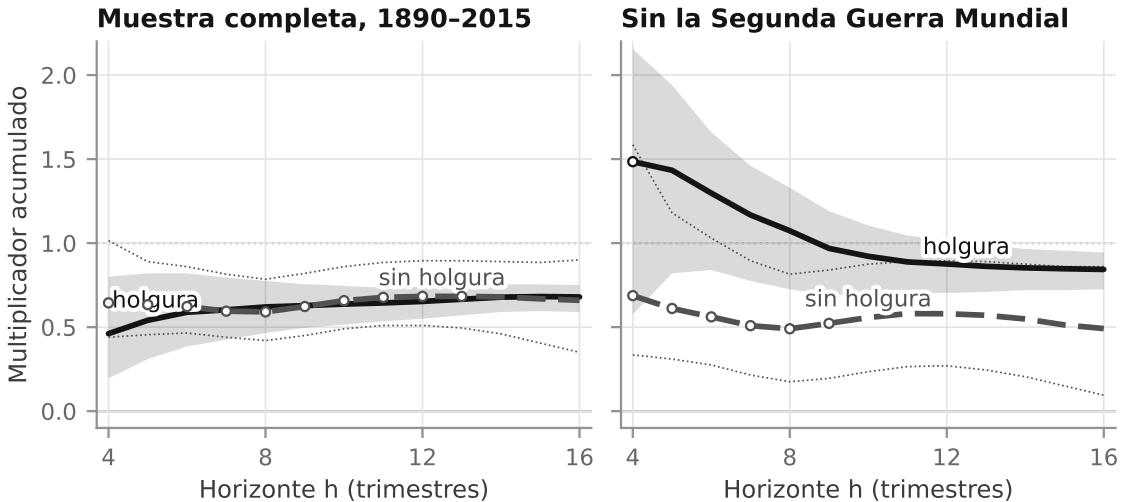
AG (2012) contra RZ (2018): tres decisiones de medición, no dos economías

1. **Congelar el régimen** —la razón principal, según RZ. La IRF del VAR con transición suave supone que la economía **sigue** en recesión los 20 trimestres; las recesiones al estilo AG duran 3.3 trimestres en promedio. Con proyecciones locales sobre los datos de AG, el multiplicador a cinco años es 0.84; si el STVAR deja cambiar el régimen, ≈ 1 en recesiones severas. En los datos de RZ, solo el $57\,\%$ de los trimestres con holgura sigue con holgura 8 trimestres después ($41\,\%$ a 16).
2. **Convertir elasticidades.** Multiplicar por el $\bar{Y}/\bar{G}$ muestral supone Y/G fijo, pero en EUA va de 2.0 (1944) a 23.9 (1891), y las noticias llegan cuando G/Y es alto. Mismos datos, mismo instrumento: $\mathbf{1.40}$ con el atajo, $\mathbf{0.67}$ con Gordon–Krenn (desde 1947: 0.90 contra 0.72).
3. **Definir y fechar el estado.** AG: media móvil de 7 trimestres del crecimiento, logística con $\gamma = 1.5$ calibrada para que $F > 0.8$ el $20\,\%$ del tiempo; RZ: desempleo $> 6.5\,\%$ en $t-1$. Fechar en $t-1$ no basta: si el estado responde a los choques, la LP por estado recupera la respuesta a un choque **infinitesimal**, y las noticias de RZ llegan a 12 desviaciones estándar. El multiplicador puede desviarse hasta un $40\,\%$.

Cada una mueve el número más que la diferencia entre estados que se quería medir.

Auerbach y Gorodnichenko (2012); Ramey y Zubairy (2018, sección VI); Koop, Pesaran y Potter (1996); Gonçalves, Herrera, Kilian y Pesavento (2024, *J. Econometrics*). Cuaderno: `T05_E_regime_girf`, §4 (la falacia del régimen congelado).

Todo interactuado: RZ se reproduce y, sin la guerra, la holgura se separa



Réplica con `rz2018.csv`: LP-IV de un paso, una regresión por régimen (como RZ); estado: desempleo $\geq 6.5\,\%$ en $t-1$; derecha: sin 1941T3–45T4. Banda gris y puntos: Anderson–Rubin HAC al 90 %; círculo hueco: F efectivo < 10. RZ (cuadro 1), a dos años: 0.60 y 0.59.

Cómo leer esa figura: un trimestre de 1940 decide el régimen de holgura

Muestra	Régimen	Réplica	RZ (2018)	F efectivo	De dónde sale la variación del instrumento
1890–2015	holgura	0.62	0.60	270	1941T4 $52\,\%$; 1940T2 $15\,\%$; 1941T2 y 1942T2 $11\,\%$ c/u
	sin holgura	0.59	0.59	8.2	1950T3 (Corea) $36\,\%$; 1917T2 (1GM) $13\,\%$
Sin 1941–45	holgura	$\mathbf{1.03}$–$\mathbf{1.10}$	0.72	43–616	**1940T2:** 80–$87\,\%$
	sin holgura	0.49–0.56	0.56	4–7	1950T3 $48\,\%$; 1917T2 $18\,\%$
Sin 1940–45	holgura	1.48–1.59	—	13	1961T2 $41\,\%$; 2013T1 $14\,\%$ (AR: $[0.2,\ 3.4]$)
1947–2015	holgura	negativo	negativo	3.8	ninguna noticia grande con holgura
	sin holgura	0.78	—	195	1950T3 (Corea): $77\,\%$

- En la muestra completa la réplica coincide con RZ: ningún régimen llega a 1 y no difieren; pero “sin holgura” tiene un instrumento débil y “con holgura” es, sobre todo, la entrada en la guerra.
- Sin la guerra la holgura se separa (también en RZ: 0.72 y 0.89 contra 0.56 y 0.53 a dos y cuatro años). Pero con 1940T2 en la muestra, ese trimestre es el 80–$87\,\%$ de la variación; sin 1940, la cifra sube a 1.5–1.6 con un AR de 0.2 a 3.4.
- Desde 1947 ningún instrumento tiene fuerza con holgura más allá de dos años (RZ): con noticias militares la pregunta no tiene respuesta. Reporten F efectivo y Anderson–Rubin **por régimen**.

Réplica, multiplicador a dos años. “Sin 1941–45”: ventanas de 1941T1, T3 o T4 a 1945T3 o T4; “sin 1940–45”: 1940T1–45T4 y 1939T3–46T4. Variación: peso de cada trimestre en $\sum_t \tilde{z}_t^2$, con $\tilde{z}_t$ las noticias residualizadas dentro del régimen. Ramey y Zubairy (2018, cuadros 1 y 3).

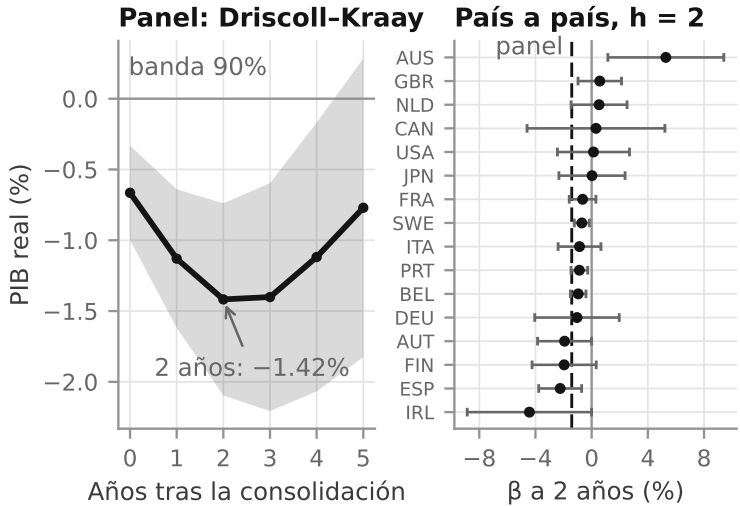
Laboratorio: Ramey–Zubairy por régimen, con todo interactuado

```
import numpy as np, pandas as pd
from puremacro.lp.iv import lp_iv

rz  = pd.read_csv('data_curso/rz2018.csv', parse_dates=['date']).set_index('date')
pot = rz['rgdp_pott6']                                          # PIB potencial (Gordon-Krenn)
d = pd.DataFrame({'y': rz['rgdp']/pot, 'g': rz['ngov']/rz['pgdp']/pot,
                  'news': rz['news']/(pot.shift(1)*rz['pgdp'].shift(1)),
                  'u1': rz['unemp'].shift(1)}).dropna(subset=['y', 'g', 'news'])  # estado en t-1
ctl = [f'{v}_l{k}' for k in range(1, 5) for v in ('y', 'g', 'news')]
for k in range(1, 5):
    for v in ('y', 'g', 'news'):
        d[f'{v}_l{k}'] = d[v].shift(k)                          # controles de RZ: 4 rezagos
d['cy'], d['cg'] = d['y'].cumsum(), d['g'].cumsum()             # cy(t+h)-cy(t-1) = suma t..t+h
h = 8
d['cg_h'] = d['cg'].shift(-h) - d['cg'].shift(1)                # gasto acumulado: la endogena
for nombre, reg in [('holgura', d['u1'] >= 6.5), ('sin holgura', d['u1'] < 6.5)]:
    dr = d.copy()
    dr.loc[~reg, 'news'] = np.nan          # una regresion por regimen = todo interactuado (RZ)
    r = lp_iv(dr, y='cy', x='cg_h', z='news', horizons=[h], n_lags=0, controls=ctl).iloc[0]
    print(f"{nombre:12s} m={r['beta']:+.2f}  F_ef={r['mop_f']:5.1f}")   # +0.62 (270) | +0.59 (8.2)
```

El instrumento se anula fuera del régimen **después** de construir rezagos y sumas: las ventanas siguen siendo trimestres contiguos y cada régimen tiene su constante y sus controles. Sin esa interacción, la LP por régimen puede dar pesos negativos a los efectos dentro del régimen (Kolesár y Plagborg-Møller 2025); `lp_state_dep_iv` de puremacro 5.9.0 no interactúa (issue #217): sin la guerra da 0.70 contra 0.69. **Tareas:** (i) quiten 1941T3–45T4 y luego 1940T1–45T4; (ii) recorran $h = 4, \ldots, 16$ y grafiquen $m(h)$ y $F(h)$ por régimen; (iii) cambien el régimen a la cota inferior de RZ (1932T2–1951T1 y 2008T4–2015T4): deben obtener 0.77 contra 0.61; (iv) pidan `anderson_rubin=True` a `lp_iv`.

La austeridad narrativa es contractiva: $-1.4\,\%$ de PIB a dos años



Ojo: el panel izquierdo usa los 17 países; el *forest plot* lleva 16 (el PIB danés arranca en 1995 y su episodio de 1983–86 queda fuera).

Qué arbitra ese -1.42, y qué no

Consolidaciones fiscales **narrativas** de Devries et al. (2011) para 17 países de la OCDE (panel anual hasta 2019). Una LP de panel con efectos fijos de dos vías y errores Driscoll–Kraay da, ante una consolidación de 1 % del PIB, $\beta_2 = -1.42$ (banda 90 %: -2.10 a -0.74).

- El signo depende de la identificación: con el CAPB (ajuste cíclico) la austeridad parece expansiva (Alesina–Ardagna); con las consolidaciones narrativas es contractiva (Guajardo–Leigh–Pescatori). Este panel, eso sí, no arbitra esa disputa: sin PIB antes de 1995 no contiene los episodios canónicos danés (1983–86) ni irlandés (1982–88)
- Jordà–Taylor dan la segunda vuelta: ni las narrativas son exógenas, son predecibles por el ciclo
- El panel entero es la Parte B del Examen Final Computacional: esta LP contra el mismo panel como *event study* TWFE, con prueba de pre-tendencias (en el apéndice)

Refs.: Guajardo, Leigh y Pescatori (2014); Alesina y Ardagna (2010); Jordà y Taylor (2016).

Cinco técnicas, una sola pregunta: ¿de dónde sale la variación exógena?

Respuesta	Supuesto que la sostiene	Dónde aparece	Por dónde se rompe
Recursiva (corto plazo)	Existe un orden en el que unas variables no responden dentro del periodo	Kilian (2009); EPU $\longrightarrow$ producción industrial	Invertir el orden suele ser igual de defendible y la IRF cambia
Restricción de largo plazo	Solo el primer choque mueve el nivel de la variable ordenada primero cuando $h \to \infty$	Galí (1999); Fisher (2006)	$\Psi(1)$ se estima con un VAR truncado; niveles contra diferencias revierte el signo (CEV 2003)
Narrativa	Los documentos fechan el choque y quien decide no anticipa el ciclo	Romer–Romer (2004, 2010); Ramey–Shapiro; Devries et al.	Si la decisión es predecible por el ciclo, no es choque (Jordà–Taylor 2016)
Instrumento externo	z_t correlaciona con el choque de interés y con ningún otro	Mertens–Ravn (2013); Gertler–Karadi (2015); Känzig (2021)	Instrumento débil (F efectivo) y efecto información: la sorpresa revela lo que el banco central sabe
Variación de corte transversal	Tendencias paralelas; los efectos de tiempo absorben lo común	Panel de austeridad; *event study* de exposición a la IA	Pre-tendencias, tratamientos escalonados heterogéneos y, sobre todo, el estimando no es el agregado

Ninguna columna del medio “gana”. En Galí la variable ordenada primero es la productividad; en Fisher es el precio del equipo, y sobre la productividad actúan los **dos** choques tecnológicos. El artículo bueno no es el que usa la técnica de moda, sino el que dice cuál es su fuente de variación exógena y contra qué evidencia la defiende.

Cuadernos: `T05_C_staggered_did` (estimadores Callaway–Sant’Anna y descomposición de Bacon) y `T05_D_lp_did` (proyecciones locales con DiD de Dube et al. 2023).

El corte transversal estima un efecto relativo, no el multiplicador agregado

Sea $y_{i,t} = a_i + b\,x_{i,t} + c\,X_t + u_{i,t}$, con $X_t = \sum_i \omega_i x_{i,t}$ la variación agregada del mismo tratamiento y $\sum_i \omega_i = 1$.

- Con efectos fijos de tiempo, δ_t absorbe $c\,X_t$ —es idéntico para toda i— y el estimando es b: el efecto de tratar a i en vez de a j
- Agregando con pesos ω_i: $Y_t = \bar{a} + (b + c)X_t + \bar{u}_t$, de modo que el objeto de política es $b + c$, y el corte transversal no puede identificar c porque c es justo lo que se tira con los efectos de tiempo
- En c viven la política monetaria (que reacciona al agregado, no a la diferencia entre regiones), el financiamiento —lo que una región gasta lo pagan todas— y las filtraciones comerciales, que salen de b pero no del agregado. Su signo no está determinado: con la tasa en su límite inferior, $c > 0$ y $b + c > b$

Refs.: Nakamura y Steinsson (2014, *AER*; 2018, *JEP*); Chodorow-Reich (2019, *AEJ: Policy*); Farhi y Werning (2016).

Un efecto regional no es automáticamente un efecto agregado

En el ejemplo de exposición estatal a la IA, la regresión compara estados más y menos expuestos. Los efectos de mes absorben las variaciones comunes a todos.

Descomposición que ya derivamos

Si $y_{it} = a_i + bx_{it} + cX_t + u_{it}$, la comparación regional identifica b bajo sus supuestos; el efecto agregado de mover X_t es $b + c$.

- Un resultado diferencial nulo puede coexistir con un efecto agregado grande.
- Un resultado diferencial positivo puede reflejar traslado de empleo entre estados.
- En el panel internacional, la política monetaria común y los efectos de contagio complican también la agregación; no basta clasificar países por su moneda.

Pregunta: ¿qué dato o estructura adicional permitiría recuperar c?

La figura del proyecto de IA se reserva al mazo 8. Nakamura y Steinsson (2014, 2018); Chodorow-Reich (2019).

Un choque de incertidumbre para México (10 min)

Otro candidato es el choque de incertidumbre (segundo momento; Bloom 2009): en el riesgo se conoce la distribución; en la incertidumbre *knightiana* (ambigüedad), no. El EPU cubre a México desde 1996; la producción industrial, del OECD MEI.

```
# Actualizacion en linea: requiere red; registra la anada.
from puremacro import lp, uncertainty
from puremacro.fetch import epu, oecd_mei  # fetch.epu -> AttributeError
from puremacro.var.identify.cholesky import cholesky_svar
epu_df = epu.fetch()                  # incluye MEX desde 1996
mei    = oecd_mei.fetch(codes=['MEX'], start_period='1993')  # log_ip
Y   = ...                             # [EPU_MEX, 100*log IP]
res = cholesky_svar(Y, p=12, horizon=36)
# incertidumbre PRIMERO (Bloom): caida con rebote de la IP
# fragilidad: reestimar con el EPU ordenado ULTIMO
# via LP: uncertainty.derive_innovation_shock + lp.lp_hac
```

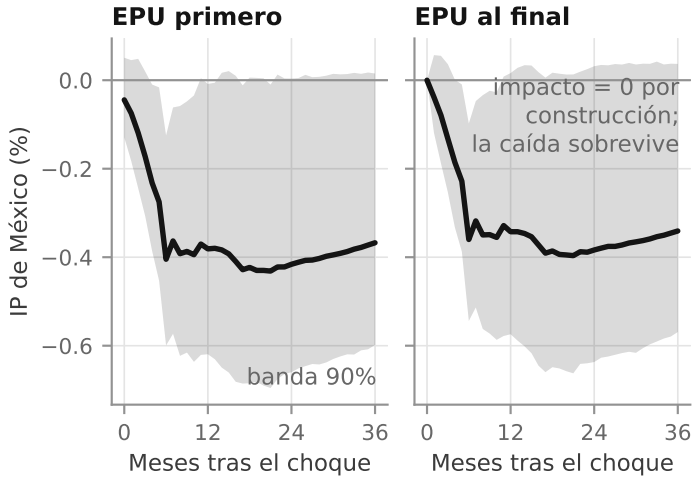
Los dos `fetch` devuelven marcos **largos** (`code, date, variable, value`): filtren `MEX` y la variable, y ordenen por fecha (`oecd_mei` llega desordenado). Sin red: `data_curso/epu_mex_mensual.csv` y `data_curso/oecd_mei_mex_log_ip.csv`.

El resultado de los dos ordenamientos está en la lámina siguiente.

La fragilidad del ordenamiento recursivo atraviesa toda la identificación: ¿qué restricción defenderían y con qué argumento económico?

Refs.: Bloom (2009); Baker, Bloom y Davis (2016); Jurado, Ludvigson y Ng (2015). | Cuaderno: `T05_E_regime_girf` (choques de **condiciones financieras** —ICF simulado y NFCI— dependientes del régimen y GIRFs no lineales).

México: la IP ante un choque de EPU, con los dos ordenamientos



VAR(12) mensual [EPU (z), $100 \cdot \log$ IP], 1996–2019, Cholesky. Con el EPU al final el impacto es cero por construcción, pero la caída de mediano plazo sobrevive.

Identificar un cambio en el emparejamiento exige más que una nube

Una curva de Beveridge desplazada es compatible con varios mecanismos. Conviertan cada explicación en una predicción:

Hipótesis	Dato que ayudaría a distinguirla
Menor eficiencia de búsqueda	Contrataciones por buscador y vacante comparables
Más separaciones	Flujos empleo–desempleo
Cambió la composición	Vacantes y buscadores por sector, ocupación o región
Ajuste transitorio	Orden temporal de los puntos y duración del episodio

Trabajo en parejas: propongan una exclusión o un instrumento. Escriban además una razón por la que podría fallar. La nube aparece en A1; el modelo y los flujos se desarrollan en B2. Shimer (2005); Elsby, Michaels y Ratner (2015).

¿Qué mueve el ciclo?

De identificar un choque a repartir la varianza

Semana 10 · cierre

Repartir la varianza del ciclo: tres métodos que no suman lo mismo

La FEVD de la Sección 1.2, leída en frecuencias: la cuota del choque j en la varianza de y_i en la banda del ciclo $\mathcal{B} = [2\pi/32,\, 2\pi/6]$ (6 a 32 trimestres),

$$s_{ij}(\mathcal{B}) = \frac{\int_{\mathcal{B}} \left|\Theta_{ij}(e^{-i\omega})\right|^2 d\omega}{\sum_k \int_{\mathcal{B}} \left|\Theta_{ik}(e^{-i\omega})\right|^2 d\omega}, \qquad \Theta(L) = \Psi(L)\, B.$$

1. Un choque a la vez

SVAR, proxy, LP. Identifica una columna de Θ; la cuota exige además la varianza total, y sin invertibilidad solo hay cotas. Las cuotas de choques identificados por separado no tienen por qué sumar $100\,\%$.

2. El modelo completo

DSGE o HANK estimados. Las cuotas suman $100\,\%$ por construcción, pero el **nombre** de cada choque lo pone el modelo: la misma varianza cambia de etiqueta si cambia la fricción.

3. Sin etiqueta previa

Las cuñas (mazo 4) descartan familias. El *max-share* en frecuencias busca la dirección que más explica el ciclo y **después** pregunta a qué se parece.

Plagborg-Møller y Wolf (2022); Chari, Kehoe y McGrattan (2007); Angeletos, Collard y Dellas (2020).

Cuatro décadas de respuestas: la PTF neutra perdió el papel protagónico

Estudio	Método	Qué explica el ciclo
Kydland y Prescott (1991)	RBC calibrado	PTF: “cerca del 70 %” de la varianza cíclica de la posguerra (Prescott 1986b: “cerca del 75 %”)
Galí y Rabanal (2004)	Modelo estimado, 6–32 trim.	Tecnología: $7\,\%$ del producto y $5\,\%$ de las horas
Fisher (2006)	SVAR, dos choques tecnológicos	Tecnología, sobre todo IST: $44\,\%$ del producto y $73\,\%$ de las horas antes de 1982; $80\,\%$ y $38\,\%$ después
Chari, Kehoe y McGrattan (2007)	Cuñas	Gran Depresión y 1982: eficiencia y trabajo, “prácticamente todo”; inversión, terciaria; gasto, nada. La posguerra lo confirma (mazo 4)
Schmitt-Grohé y Uribe (2012)	DSGE con noticias	Choques anticipados: “cerca de la mitad”
Angeletos, Collard y Dellas (2020)	*Max-share*, 6–32 trim.	Un solo choque: $74\,\%$ del desempleo, $59\,\%$ del producto, $62\,\%$ de la inversión; $6\,\%$ de la PTF y $7\,\%$ de la inflación
Forni, Gambetti, Granese, Sala y Soccorsi (2025)	Factores, 6–32 trim.	Dos choques suman $76\,\%$ del crecimiento cíclico del PIB: demanda $49\,\%$, oferta $27\,\%$

Las filas no se comparan entre sí: cambian la variable, la banda, la muestra y, sobre todo, la identificación. Es una historia, no un metaanálisis. Lo que se mueve en una sola dirección es el peso de la PTF neutra, y la Sección 1 ya les mostró por qué: con ella, las horas caen.

Prescott (1986b), “Response to a Skeptic”; Kydland y Prescott (1991, *Economic Theory*); Galí y Rabanal (2004, *NBER Macro Annual*); Fisher (2006); Chari, Kehoe y McGrattan (2007); Schmitt-Grohé y Uribe (2012); Angeletos, Collard y Dellas (2020, cuadro 1); Forni et al. (2025, *AEJ: Macro*).

El choque principal del ciclo mueve desempleo y producto, no la PTF ni la inflación

Angeletos, Collard y Dellas (2020): VAR bayesiano de 10 variables, 1955–2017. Buscan la dirección que maximiza la varianza del **desempleo** entre 6 y 32 trimestres —el *max-share* de la Sección 1.2, en frecuencias— y miran qué hace ese choque con todo lo demás.

Lo que encuentran

- Explica $74\,\%$ del desempleo, $59\,\%$ del producto, $62\,\%$ de la inversión y $48\,\%$ de las horas en la banda del ciclo.
- Casi nada de la PTF ajustada por utilización ($6\,\%$) ni de la inflación ($7\,\%$), y casi nada del producto a largo plazo ($5\,\%$).
- El choque que maximiza la inflación explica el $83\,\%$ de ella y solo 4–$8\,\%$ del desempleo, el producto y la inversión: **no es el mismo choque**.

Qué descarta, y qué no

- Descarta un ciclo movido por la PTF y uno movido por la demanda a lo largo de una curva de Phillips empinada. Su lectura: demanda no ligada a la productividad y no inflacionaria.
- Candidatos: confianza, riesgo, curva de Phillips plana. Un choque a la prima de riesgo explica el $51\,\%$ del producto en la misma banda (Basu et al.).
- Advertencia: el *max-share* puede devolver una **mezcla** de choques estructurales (Dieppe, Francis y Kindberg-Hanlon 2026).

Angeletos, Collard y Dellas (2020, *AER*, cuadro 1); Basu, Candian, Chahrour y Valchev (NBER WP 28693); Dieppe, Francis y Kindberg-Hanlon (2026). En `puremacro` 5.9.0, `identify_maxshare` maximiza en un horizonte, no en una banda.

En los modelos estimados manda el margen intertemporal; el nombre lo pone la fricción

Modelo estimado	Choque dominante en el producto	Lo que cambia la etiqueta
Smets y Wouters (2007), NK	Antes de un año: gasto, prima de riesgo e inversión, $> 50\,\%$. A dos años: productividad y *markup* salarial, $> 50\,\%$	Política monetaria: una fracción pequeña a todo horizonte
Justiniano, Primiceri y Tambalotti (2010), NK	Eficiencia marginal de la inversión (MEI): $50\,\%$ del producto, $59\,\%$ de las horas, $83\,\%$ de la inversión (6–32 trim.)	Con los datos de Smets–Wouters, la MEI cae a $19\,\%$ del producto
JPT (2011)	MEI: $60\,\%$, $68\,\%$, $85\,\%$	Si se observa el precio relativo de la inversión, el choque IST explica ≈ 0
Christiano, Motto y Rostagno (2014), con fricción financiera	Choque de riesgo: $62\,\%$ del PIB (8–32 trim.)	Sin las cuatro series financieras: riesgo $1\,\%$, MEI $44\,\%$
Bayer, Born y Luetticke (2024), HANK	MEI: $58\,\%$ del crecimiento del producto (6–32 trim.)	El RANK equivalente da $50\,\%$; la heterogeneidad casi no cambia el reparto agregado

La varianza que JPT llaman “inversión” es la que CMR llaman “riesgo” en cuanto el modelo observa diferenciales de crédito. Lo robusto no es el nombre: es que el choque dominante actúa sobre el margen intertemporal (invertir, financiarse) y no sobre la PTF.

Smets y Wouters (2007, pp. 598–599); Justiniano, Primiceri y Tambalotti (2010, cuadro 1; 2011, cuadro 3); Christiano, Motto y Rostagno (2014, cuadro 5); Bayer, Born y Luetticke (2024, cuadro A.3).

Los choques de política explican poco del ciclo; la política importa por su regla

Cuánto explican los choques de política

- **Monetarios:** menos del $7\,\%$ de la producción industrial a 24 meses (Christiano–Eichenbaum–Evans), $9\,\%$ con Romer–Romer (Ramey 2016).
- Con el instrumento de alta frecuencia de Gertler–Karadi, las bandas al 90 % descartan más del $31\,\%$ del crecimiento de la producción industrial y del $8\,\%$ de la inflación, a cualquier horizonte (Plagborg-Møller y Wolf 2022).
- **Gasto público:** hasta $13\,\%$ del producto (Ramey 2016); menos de $12\,\%$ en el apéndice de este mazo.
- ¿Suman? Los choques que Ramey reúne, ordenados primero en un mismo VAR, explican juntos entre 63 y $79\,\%$ del producto y de las horas a 4–20 trimestres.

Para qué sirven hoy los choques identificados

La pregunta se movió de “cuánto explica el choque” a “qué habría pasado con otra regla”. Con las IRF de varios choques de política se construye la respuesta de la economía bajo una regla sistemática distinta (McKay y Wolf 2023), o la corrección óptima de la política vigente (Barnichon y Mesters 2023).

Un choque de política que explica poca varianza sigue siendo valioso: es el experimento que revela cómo se propaga la regla.

Ramey (2016, cuadros 3.2, 4.3 y 6.1); Plagborg-Møller y Wolf (2022, *JPE*); McKay y Wolf (2023, *Econometrica*); Barnichon y Mesters (2023, *AER*).

2021–2023: la oferta volvió, pero cuánto depende de la identificación

La misma inflación, tres repartos:

- **Shapiro (2022):** signos de precio y cantidad por categoría del gasto; la oferta explica cerca de la **mitad** del repunte y la demanda cerca de un **tercio**.
- **Bernanke y Blanchard (2025):** la mayor parte del repunte viene de choques a los precios dados los salarios (energía, alimentos, escaseces); el apretón del mercado laboral es más persistente pero no domina.
- **Giannone y Primiceri (2024):** más de la mitad del alza y de la caída es demanda. En su DSGE, la demanda explica el $90\,\%$ de la inflación de 2021T1–2023T4, pero entre 34 y $108\,\%$ según la regla monetaria que se suponga.

La lección es de la Sección 1, no del episodio

"Oferta contra demanda" no es un hecho de los datos: es una propiedad de la identificación. El cuaderno `T05_F` reproduce el episodio con restricciones de signo y muestra cómo cambia la descomposición histórica al cambiar las restricciones.

Shapiro (2022, *FRBSF Economic Letter* 2022-15); Bernanke y Blanchard (2025, *AEJ: Macro*); Giannone y Primiceri (2024, NBER WP 32859; versión BPEA, otoño de 2026). Cuaderno: `T05_F_svar_post_covid_inflation`.

Síntesis provisional (2026), y por qué la semana que viene cambia el modelo

1. La PTF neutra no es el motor del ciclo de horas y desempleo: la Sección 1, Galí–Rabanal y ACD llegan ahí por caminos distintos.
2. Los choques de política explican poco de la varianza; la política pesa por su regla.
3. El grueso es un choque al margen intertemporal —inversión, riesgo, confianza— que mueve cantidades y poca inflación.
4. El nombre de ese choque lo ponen el modelo y los datos que observa; el *max-share* puede mezclar varios.
5. En 2021–2023 la oferta volvió a importar para la inflación; cuánto, lo decide la identificación.

Del reparto a la distribución

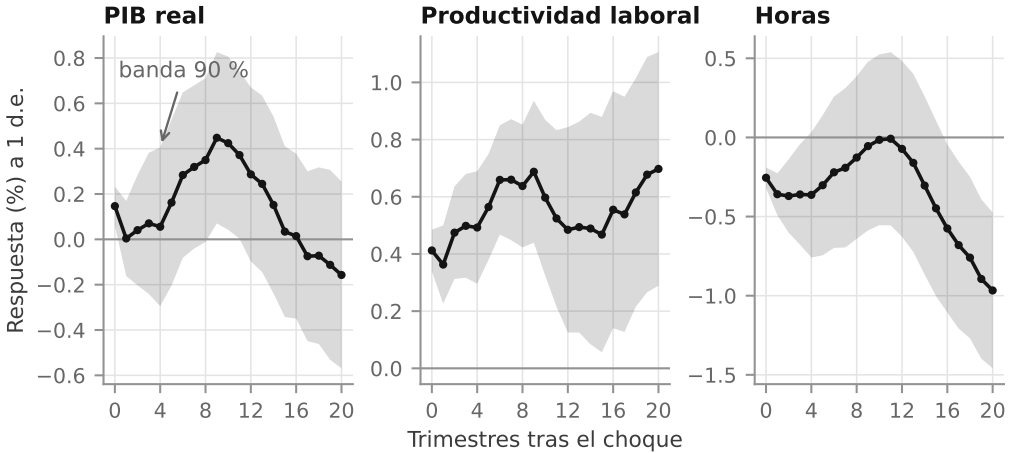
Bayer, Born y Luetticke (2024) estiman un HANK: el reparto agregado casi no cambia (MEI, $50\,\%$ del producto en RANK y $58\,\%$ en HANK), pero los mismos choques mueven la desigualdad (MEI y *markup* de precios explican $50\,\%$ y $35\,\%$ de la participación del 10 % más rico en la riqueza). Todos los modelos que escribimos hasta aquí suponen un **hogar representativo con mercados completos**; la semana que viene rompemos ese supuesto: mercados incompletos, ahorro precautorio, Aiyagari–Huggett, y por qué la política monetaria opera por el **ingreso** y no solo por la sustitución intertemporal.

Para México y los emergentes, la misma pregunta tiene otra respuesta —tendencia contra prima de riesgo país—: mazo 7. Choques mundiales: un tercio del producto en 138 países (Fernández, Schmitt-Grohé y Uribe 2017).

Apéndice

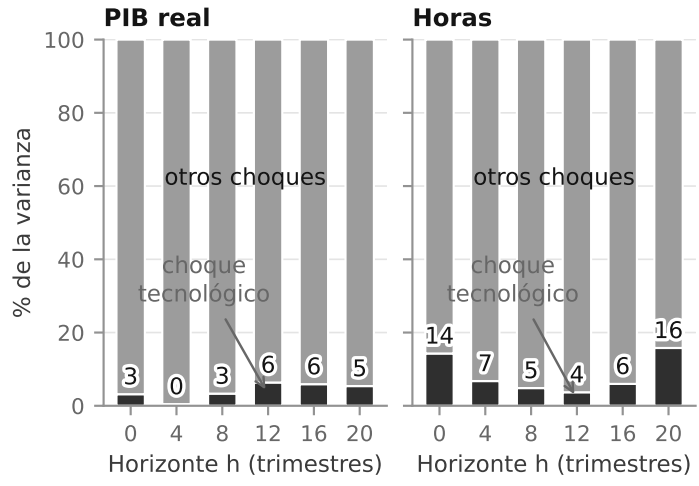
Apéndice: la respuesta al choque tecnológico, por proyección local

Los efectos de los choques tecnológicos estructurales a la productividad también pueden verse con IRFs estimadas por proyección local: una regresión directa de la variable en $t+h$ sobre el choque en t (Jordà 2005).



Apéndice: ¿qué fracción de la varianza del PIB explica el choque tecnológico?

Nota metodológica: la FEVD no sale directamente de una proyección local; la descomposición mostrada usa el enfoque R^2 de Gorodnichenko y Lee (2020, *JBES*).



Apéndice: el 15.49 del pretest y el caso determinista

El valor crítico 15.49 de la traza de Johansen es el del caso con constante **no** restringida (Caso III de MacKinnon–Haug–Michelis), y contra él la traza de x_t y h_t es 16.48: se rechaza $r = 0$ al 5 % por muy poco.

La selección de $r = 1$ es, sin embargo, robusta al caso determinista: con la constante restringida dentro de la relación de cointegración (Caso II), la traza es 81.93 contra un valor crítico de 20.26.

Moraleja de método: cuando un titular cuelga de un pretest que rechaza por décimas, hay que reportar el pretest bajo los casos deterministas alternativos, no solo el que resultó favorable.

Apéndice: VECM(2), rezagos endógenos de corto plazo

	Coef.	EE	z	p-valor
Ecuación INCPW				
L1.INCPW	-0.0487	0.057	-0.852	0.394
L1.HRSPW	0.0386	0.069	0.560	0.575
L2.INCPW	0.1140^{*}	0.057	2.012	0.044
L2.HRSPW	-0.3131^{***}	0.069	-4.517	0.000
Ecuación HRSPW				
L1.INCPW	0.1482^{**}	0.049	3.041	0.002
L1.HRSPW	0.6111^{***}	0.059	10.430	0.000
L2.INCPW	0.1503^{**}	0.048	3.111	0.002
L2.HRSPW	0.0087	0.059	0.147	0.883

Apéndice — Cochrane (1994): un cero de impacto que equivale a uno de largo plazo

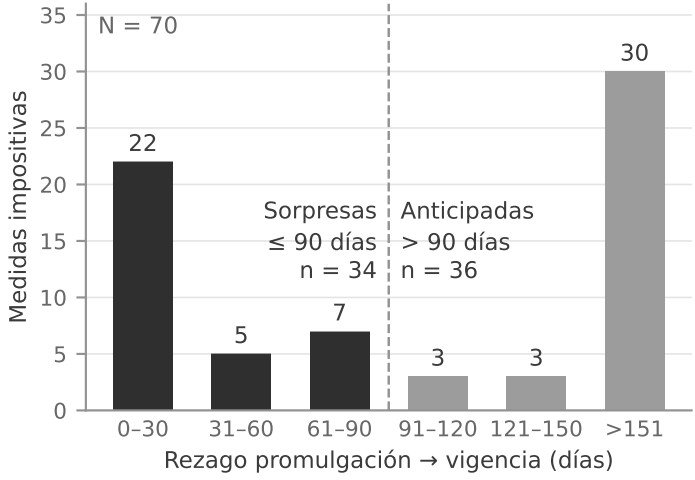
La teoría del ingreso permanente ofrece otra restricción bivariada sobre consumo e ingreso:

$$\begin{pmatrix} u_t^{\Delta c} \\ u_t^{\Delta y} \end{pmatrix} = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix} \begin{pmatrix} \epsilon_t^{permanente} \\ \epsilon_t^{transitorio} \end{pmatrix}$$

- La matriz mostrada es, tal cual, una restricción de **corto plazo**: el cero en $(1, 2)$ dice que el choque transitorio no mueve el consumo **en impacto**
- El puente con la teoría: como el consumo es (casi) un paseo aleatorio, lo que no lo mueve en impacto no lo mueve **a ningún horizonte** — el cero de impacto hereda la interpretación de largo plazo
- Es el ejemplo perfecto para distinguir ambos tipos de restricción: aquí coinciden por una propiedad **económica** del consumo, no por la mecánica del SVAR

Apéndice: Mertens & Ravn (2012)

El rezago entre la aprobación legislativa y la implementación permite separar choques fiscales **anticipados** de **sorpresas**:



Apéndice: choques a los impuestos

Destaca el trabajo de Romer & Romer (2010), que emplea un enfoque narrativo, extrayendo información de los discursos presidenciales y reportes del Congreso para obtener una serie de choques fiscales, en particular aquellos que se financian con déficit frente a los que tienen como motivación el crecimiento económico. Del enfoque narrativo surgen dos líneas de investigación:

- Mertens & Ravn (2011, 2012) usan el enfoque narrativo y el rezago que hay entre legislación y ejecución para distinguir entre choques fiscales esperados y sorpresas

- Mertens & Ravn (2013, AER) desarrollan el método proxy-SVAR para usar los choques obtenidos con el enfoque narrativo como instrumento; Mertens & Ravn (2014, JME) reconcilian con él las estimaciones SVAR y narrativas del multiplicador impositivo

Apéndice: estimaciones del multiplicador impositivo

Los impuestos suelen tener multiplicadores negativos.

Estudio	Muestra principal	Identificación	Multiplicador implícito
Evans (1969)	Trimestral, 1966–1974	Con base en ecuaciones estimadas de los modelos Wharton, Klein–Goldberger y Brookings	-0.5 a -1.7, según horizonte, tipo de impuesto y modelo
Blanchard–Perotti (2002)	Trimestral, 1960–1997	Elasticidades de producto supuestas en un SVAR; los "impuestos" son en realidad impuestos netos de transferencias	-0.78 a -1.33 (pico a impacto)
Mountford–Uhlig (2009)	Trimestral, 1955–2000	Restricciones de signo sobre un VAR; mismas variables que BP	-5 para un aumento impositivo que reduce el déficit
Romer–Romer (2010)	Trimestral, 1947–2007	Cambios impositivos legislados por déficit heredado o para promover crecimiento futuro (narrativa)	-3, con base en el efecto pico; Romer–Romer (2009) muestran que casi no elevan el gasto, por lo que se acercan a choques impositivos puros
Barro–Redlick (2011)	Anual, 1917–2006 y submuestras	Tasa marginal promedio del impuesto sobre la renta	-1.1
Favero y Giavazzi (2012)	Trimestral, 1950–2006	Choques de Romer–Romer incrustados en un SVAR	-0.5
Caldara y Kamps (2012)	Trimestral, 1947–2006	SVAR con elasticidades externas	-0.65 (pico a impacto)
Mertens–Ravn (2014)	Trimestral, 1950–2006	Proxy-SVAR con choques no anticipados de Romer–Romer	-3 a 6 trimestres

Fuente: Ramey (2016), *Macroeconomic Shocks and Their Propagation*, Handbook of Macroeconomics, vol. 2A, cuadro 6.

Apéndice: la curva de especificaciones

La fragilidad del ordenamiento, llevada al extremo con **otro** choque: una demostración en clase estima **seis esquemas de identificación** de un choque de incertidumbre (EPU $\rightarrow$ producción industrial) sobre un dataset mensual congelado y muestra el abanico completo de IRFs resultante.

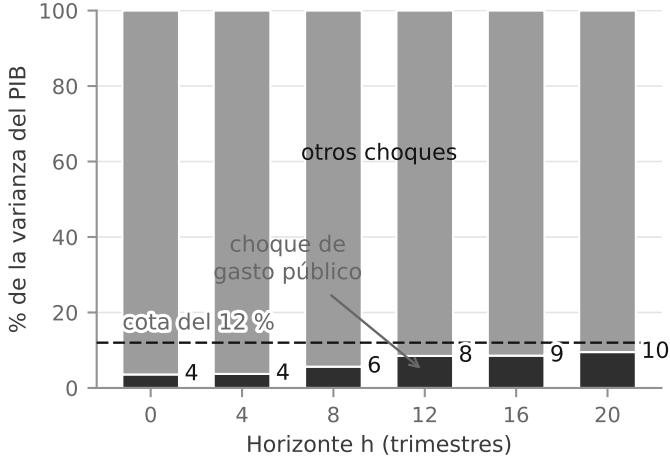
- La “spec curve” no es solo un ejercicio fiscal —la del curso está en `T04_A_tax_multiplier_three_ways`, §4: 24 especificaciones del multiplicador impositivo—: es una vacuna general contra el p-hacking de identificación

- Pregunta de debate: si seis identificaciones defendibles dan respuestas distintas, ¿qué debe reportar un artículo honesto?

Apéndice: FEVD del gasto público

Los choques al gasto del gobierno explican menos del 12 % de la varianza del PIB.

Nota metodológica: la FEVD no sale directamente de una proyección local; la descomposición mostrada usa el enfoque R^2 de Gorodnichenko y Lee (2020, *JBES*).



Apéndice: el mismo panel como *event study* — los *leads* convierten la crítica en hipótesis contrastable

Las consolidaciones de Devries et al. son "tratamientos" fechados en un panel, así que admiten una especificación de **diferencias en diferencias** con efectos fijos de dos vías (TWFE):

$$y_{i,t} = \alpha_i + \delta_t + \sum_{k=-2}^{4} \beta_k \, D_{i,t-k} + \varepsilon_{i,t}, \qquad D_{i,t} = 1 \text{ si } i \text{ anuncia consolidación en } t.$$

- α_i absorbe los niveles medios de cada país; δ_t absorbe lo común a los 17 en ese año (crisis globales, ciclo mundial, precios de materias primas). Lo que **no** absorbe, porque es nacional, es la respuesta del banco central propio y el financiamiento del ajuste. El supuesto es **tendencias paralelas**
- Los *leads* β_{-1}, β_{-2} son la prueba de **pre-tendencias**: si son distintos de cero, la consolidación es predecible por el ciclo — la crítica de Jordà–Taylor, ahora contrastable
- Frente a la LP de panel, que trata la consolidación como choque continuo (% del PIB) y estima un β_h por horizonte con errores Driscoll–Kraay, el TWFE usa tratamiento discreto y permite examinar tendencias previas; no rechazarlas no demuestra exogeneidad
- Salvedad moderna: con tratamientos escalonados y efectos heterogéneos, el coeficiente TWFE mezcla comparaciones "prohibidas" (de Chaisemartin y D'Haultfœuille 2020; Goodman-Bacon 2021). Si ambas versiones difieren, la pregunta es **qué supuesto** falla, no qué estimador "ganó"

Refs.: de Chaisemartin y D'Haultfœuille (2020); Goodman-Bacon (2021); Jordà y Taylor (2016).

Apéndice: el código base del entregable de austeridad

Este esquema requiere preparar las tablas `ancho` y `sub` como en el cuaderno. Con los archivos del examen corre **sin red**: los dos snapshots del examen (consolidaciones de Devries et al. y PIB real de la OCDE QNA) se leen de la carpeta `./data/` (en el repositorio del curso, los mismos dos archivos están en `data_curso/`). Frecuencia **anual** —la del dataset y la de Guajardo–Leigh–Pescatori— y ventana 1978–2019: panel muy desbalanceado, 518 obs de 714 posibles, porque el PIB de casi todos los europeos empieza hacia 1995.

```
import pandas as pd
from puremacro.lp.panel_dk import panel_lp_dk
from puremacro.lp.jorda import lp_hac

# Los DOS csv del examen (Canvas -> ./data/): nada de red, nada de fetch
cons = pd.read_csv('data/dglp_consolidaciones_trimestrales.csv',
                   parse_dates=['date'])  # code, date, x (% del PIB)
qna  = pd.read_csv('data/oecd_qna_dglp17.csv',
                   parse_dates=['date'])  # code, date, variable, value
# x: suma ANUAL del x trimestral; y: 100*log_gdp_real, promedio anual
# ancho: MultiIndex (code, date) con columnas y, x

res = panel_lp_dk(ancho, y='y', x='x', horizons=range(0, 6), n_lags=2)
#   h = 2: beta = -1.42   (banda 90%: -2.10 a -0.74)
irf = lp_hac(sub, 'y', 'x', horizons=[2], n_lags=2)  # forest por pais
```

Dos avisos. (i) En trimestral el $1\,\%$ se reparte en 0.25 por trimestre durante episodios multianuales y el β por unidad se infla: si su número no se parece al -1.42, revisen primero la frecuencia. (ii) El módulo 09 del curso **simula** un panel con la misma estructura, así que sus cifras no tienen por qué coincidir con las de aquí.

Apéndice: incertidumbre desde el texto de Banxico

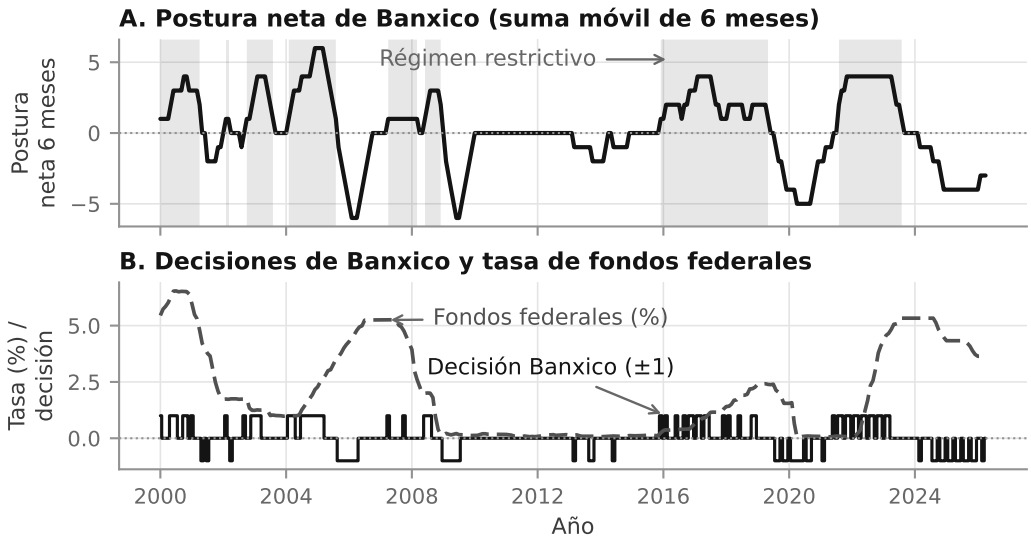
El conector `iter_banxico_decision` entrega los **anuncios de decisiones de política monetaria de Banxico en español** (PDFs del listado oficial), y el paquete trae léxicos LTUI en varios idiomas (es/en/pt/de/fr/it/ja/zh): el corpus se analiza en su idioma original.

```
# Actualizacion en linea: requiere red; registra la anada.
from puremacro import narrative
from puremacro.narrative.sources import iter_banxico_decision

recs = list(iter_banxico_decision())  # anuncios en espanol (1-2 min)
# list(): el conector es un generador; sin ella ltui_down lo recibe vacio
up   = narrative.ltui_up(recs,  country='MEX', language='es')
down = narrative.ltui_down(recs, country='MEX', language='es')
# indice direccional: riesgo al alza vs. a la baja
```

La lámina siguiente **no** es el LTUI: grafica la postura direccional de los anuncios (`data_curso/banxico_stance_monthly.csv`), es decir, la **suma móvil de 6 meses** de la dirección de cada anuncio (± 1), acotada en ± 6. Correr el bloque de arriba sobre el corpus produce otra cosa —los dos índices— y es justo el ejercicio. Lección de fronteras de datos: sigue sin haber medidas de exposición a la IA fuera de EUA; el hueco es real, pero ya no es una excusa lingüística. La figura es la celda 15 del cuaderno `T03_F_narrative_llm_central_banks`; el sombreado marca el régimen restrictivo.

Apéndice: la postura de Banxico, leída de sus anuncios



Apéndice: una tasa de desempleo no identifica dos flujos

En dos estados,

$$u_{t+1} = u_t + s_t(1 - u_t) - f_t u_t.$$

Observar u_t y u_{t+1} deja una ecuación para dos incógnitas: f_t y s_t.

- Para estimar transiciones observadas se necesitan flujos brutos o microdatos enlazados.
- El método de Shimer añade información de duración del desempleo y supuestos de fechado.
- Una función que reconstruye ambos flujos solo desde u_t impone restricciones adicionales: sus salidas no son dos hechos identificados por separado.

Ejercicio: con desempleo constante al $5\,\%$, construyan dos pares (f, s) que satisfagan la ecuación. ¿En cuál duran más los episodios de desempleo? Shimer (2012). Para flujos CPS y ENOE observados: `T08_A`.

Apéndice: acervo constante, experiencias laborales distintas

Con $u = 0.05$, el estado estacionario exige $s(1-u) = fu$.

Economía ilustrativa	f mensual	s mensual	Duración media $1/f$
Alta rotación	0.40	0.0211	2.5 meses
Baja rotación	0.10	0.0053	10 meses

Ambas tienen el mismo desempleo. Difieren en frecuencia de pérdida de empleo, duración y riesgo de ingresos.

Qué dato pedir

Para estudiar bienestar o seguro de desempleo hacen falta los flujos y las duraciones, además del acervo. En B2 los incorporamos a las decisiones de trabajadores y empresas.

Ejemplo numérico, no estimación. Tasas discretas y duración geométrica.

Apéndice: el disenso de los pronosticadores sube en recesiones

La dispersión entre pronosticadores (SPF) mide desacuerdo. Puede aumentar en recesiones, pero no equivale a la incertidumbre subjetiva de cada analista.

Canal empírico 1: Desacuerdo en pronósticos (Survey of Professional Forecasters)

- **Métrica**: Desviación estándar o rango intercuartílico (IQR) de los pronósticos a un año para el crecimiento del PIB real, la inflación y el desempleo.
- **Hecho estilizado**: Durante las contracciones (NBER), el disenso entre expertos sube entre un 40 % y 80 % respecto a expansiones normales (Bloom 2009, 2014).
- **Interpretación**: El desacuerdo refleja una combinación de heterogeneidad de modelos, información imperfecta y mayor varianza en los choques fundamentales agregados.

Refs.: Bloom (2009, 2014); Jurado, Ludvigson y Ng (2015); Baker, Bloom y Davis (2016).

Apéndice: tres medidas de incertidumbre, tres objetos

Medida	Qué resume	Qué no identifica por sí sola
EPU	Frecuencia de noticias con términos de economía, política e incertidumbre	Una innovación exógena de política
JLN	Volatilidad de componentes difíciles de pronosticar	El origen estructural de ese riesgo
VIX	Volatilidad implícita neutral al riesgo	La volatilidad física sin prima de riesgo

Conexión con A3: que las tres medidas suban en una crisis no permite intercambiar sus innovaciones. Normalicen el impulso y expliquen qué variable intentan medir antes de estimar una respuesta. Jurado, Ludvigson y Ng (2015); Baker, Bloom y Davis (2016).

Apéndice: la incertidumbre microeconómica y opciones reales

En las recesiones no solo sube la incertidumbre agregada: la dispersión microeconómica entre empresas (crecimiento de ventas, empleo, productividad) se duplica.

Canal microeconómico: Dispersión entre empresas y opciones reales (Bloom 2009)

- **Evidencia micro (Compustat / Censos)**: El rango intercuartílico del crecimiento de ventas entre empresas pasa de $\sim$15 % en expansiones a más de 30 % durante recesiones profundas.
- **Mecanismo de opciones reales**: Cuando el capital y el empleo enfrentan costos de ajuste cuasi-fijos o irreversibilidades parciales, un aumento en la volatilidad incrementa el valor de la opción de esperar (*wait-and-see*).
- **Efecto macro**: La contratación de empleo y la inversión fija se congelan de inmediato; la recuperación posterior exhibe un rebote cuando la incertidumbre se disipa.

Este mecanismo microeconómico fundamenta la identificación estructural de choques de incertidumbre en SVARs y proyecciones locales (Bloom 2009; Fernández-Villaverde et al. 2015).

Refs.: Bloom (2009, *The Impact of Uncertainty Shocks*, Econometrica); Bloom (2014, JEP).