Identificación empírica: SVAR, evidencia narrativa y proyecciones locales

Macroeconomía avanzada

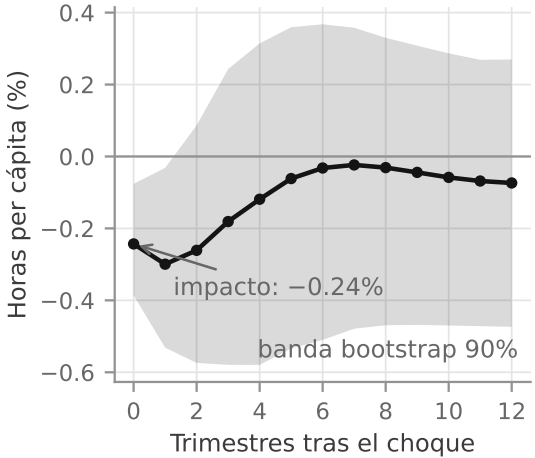
ITAM, Otoño 2026

Semanas 9–10

¿Un avance tecnológico destruye empleo? Las horas caen

Identificado un choque tecnológico con una restricción de largo plazo sobre datos de EUA, **las horas trabajadas caen en impacto** (Galí 1999).

Todo el instrumental empírico que sigue —pruebas de integración y cointegración, VAR, identificación estructural y proyecciones locales— se construye para poder producir y, sobre todo, **defender** esta figura. La pregunta conecta directamente con el debate actual sobre la IA: ¿el progreso técnico expande o contrae el empleo en el corto plazo?



Companion notebooks: `T02_B_rbc_dynare_local` (la réplica de Galí con `bq_svar` sobre `gali1999`) y `T05_F_svar_post_covid_inflation` (descomposición SVAR post-COVID: oferta, demanda y salarios).

Organización del tema: semanas 9 y 10

Los modelos de ciclo generan IRFs teóricas ante choques —tecnológicos, fiscales, de incertidumbre— y descomposiciones de varianza que les atribuyen la volatilidad del PIB. Toca preguntar si esos choques **existen en los datos** y cuánto explican del ciclo. Cada semana: teoría y laboratorio con `puremacro`, $\sim$90 min cada mitad.

1. **VAR, identificación recursiva y restricciones de largo plazo** (semana 9): integración y cointegración deciden la especificación, y con ella la conclusión; el resultado de Galí (1999) y la evidencia tecnológica (Prescott, Basu–Fernald–Kimball, Greenwood–Hercowitz–Krusell, Fisher). Laboratorio: Galí y el SVAR de Fisher
2. **Narrativa, proxy-IV, choques monetarios y proyecciones locales** (semana 10): las tres vías del multiplicador impositivo (Blanchard–Perotti, Romer–Romer 2010, Mertens–Ravn); Romer–Romer (2004), Gertler–Karadi y las sorpresas de anuncios de Banxico; equivalencia poblacional entre LP y SVAR, inferencia HAC y multiplicadores dependientes del estado (Ramey–Zubairy); y el cierre: la identificación como problema, no como catálogo. Laboratorio: las tres vías en vivo y Ramey–Zubairy

Un solo ejemplo —Galí (1999)— atraviesa la primera de las dos semanas. El álgebra del VECM, la curva de especificaciones y el código base del panel quedan en el apéndice; el taller del panel de austeridad —LP de panel contra *event study* TWFE, con prueba de pre-tendencias— se resuelve completo en el Examen Final Computacional. La semana 11 es de mercados incompletos, heterogeneidad y HANK, y en ella salen la Tarea 3 y la auditoría adversarial de código con IA; la 12 es el Segundo Examen Parcial (miércoles 4 de noviembre), que ocupa la sesión completa: el repaso de ciclos reales e identificación corre por su cuenta.

Lecturas marco: Nakamura y Steinsson (2018, *JEP*), “Identification in macroeconomics”; Stock y Watson (2018, *EJ*).

VAR y SVAR

Identificación recursiva y restricciones de largo plazo

Semana 9 · Laboratorio: la réplica de Galí (1999)

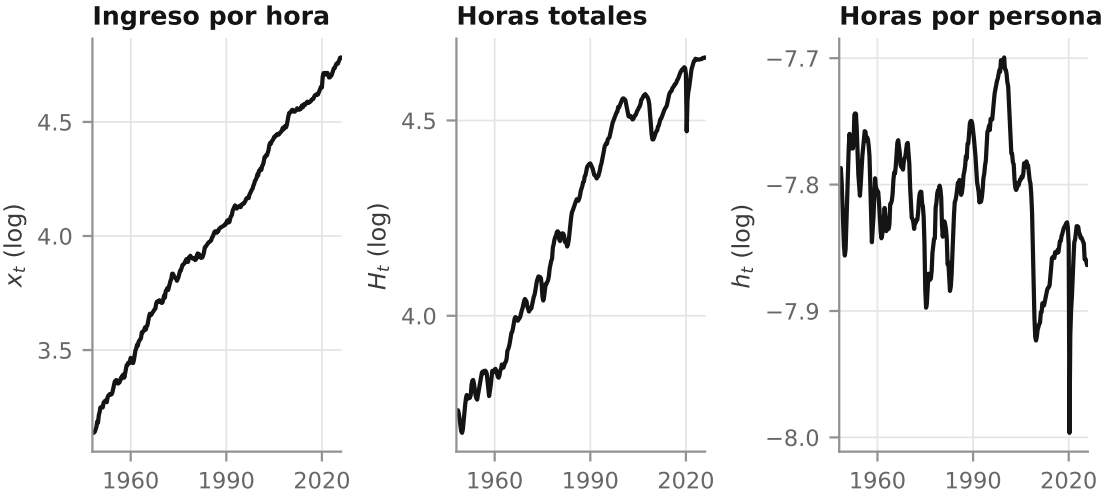
Típicamente usamos tres tipos distintos (aunque relacionados) de modelos econométricos para estudiar relaciones dinámicas y endógenas:

- Vectores autorregresivos (VAR, VARMA) y sus equivalentes univariantes (AR, ARMA)
- Modelos de cointegración y su especificación de corrección de error (VECM), cuyo álgebra y estimación quedan en el apéndice
- Métodos de proyección local, que buscan estimar directamente funciones de impulso respuesta

Vamos a aplicar estas técnicas a un problema sencillo y clásico que busca analizar la relación entre ingreso por hora x_t y horas de trabajo H_t totales o por persona h_t (reservamos y_t para el vector del VAR).

Las tres series de Galí tienen tendencia: son $I(1)$

Snapshot `gali1999` (FRED: OPHNFB, HOANBS, CNP16OV), 1948–hoy; h_t son horas por persona en edad de trabajar.



Necesitamos determinar la especificación econométrica de las series, por lo que utilizamos pruebas de integración de “Dickey–Fuller” y pruebas de cointegración de “Johansen”.

- x_t, H_t y h_t son series integradas de orden uno $I(1)$
- x_t y H_t no están cointegradas
- x_t y h_t están cointegradas

```
import numpy as np, pandas as pd
from puremacro.teaching.integration_checks import adf_test
from puremacro.var.vecm import johansen

g  = pd.read_csv('data_curso/gali1999.csv', parse_dates=['date'])
g  = g.set_index('date').loc[:'2019-12-31']           # sin COVID
df = pd.DataFrame({'incpw': np.log(g['ophnfb']),                # x
                   'hrspw': np.log(g['hoanbs'] / g['cnp16ov'])})  # h
adf_test(df['incpw'], regression='ct')  # H0: raiz unitaria (p = 0.21)
jo = johansen(df, p=3)                  # VAR(3) en niveles
jo['trace_stats'][0], jo['crit_values'][0]  # traza 16.48 vs. 15.49
```

`johansen` usa constante no restringida (Caso III), como `coint_johansen(..., det_order=0, k_ar_diff=2)` de `statsmodels`: `p` es el orden del VAR en **niveles**, uno más que `k_ar_diff`. Con x_t y H_t (horas totales) la traza es 10.87: no cointegran.

La cointegración no es un trámite: decide si el VAR va en niveles o en diferencias

Dos series $I(1)$ están **cointegradas** si alguna combinación lineal $\beta' y_t$ es $I(0)$: comparten la misma tendencia estocástica y no pueden separarse indefinidamente. Reescribiendo el $VAR(p)$ en niveles (el álgebra completa, en el apéndice):

$$\Delta y_t = \Pi\, y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i\, \Delta y_{t-i} + u_t, \qquad \Pi = \left(\textstyle\sum_{i=1}^{p} A_i\right) - I,$$

y todo depende del rango de Π: $\operatorname{rank}(\Pi) = 0$ (VAR en diferencias), $= n$ (VAR en niveles), o $0 < \operatorname{rank}(\Pi) = r < n$, con $\Pi = \alpha\beta'$ y $\beta' y_{t-1}$ estacionario.

- Si $r > 0$ y se estima en diferencias, se omite $\alpha\beta' y_{t-1}$: un regresor $I(0)$ correlacionado con los Δy_{t-i}. No es un detalle de eficiencia — se impone $\Pi = 0$, o sea, se **fija por decreto** la dinámica de largo plazo que la restricción de Blanchard–Quah luego usa para identificar
- Si $r = 0$ y se estima en niveles, la raíz unitaria sobrevive en la muestra pero $\Psi(1)$ se estima con muy poca precisión: el mismo choque puede cambiar de signo en impacto
- En los datos de Galí: x_t y H_t no cointegran (diferencias); x_t y h_t sí, pero el estadístico de traza de Johansen rechaza $r = 0$ al 5 % por poco (16.48 contra 15.49). El resultado que hizo famoso al artículo cuelga de ese pretest

Ejercicio de 3 minutos: reestimen la traza de Johansen recortando la muestra a 1948–1999 y a 1948–2007. Si el rango cambia, ¿qué reportarían? (El valor crítico 15.49 y su sensibilidad al caso determinista, en el apéndice.)

Vectores autorregresivos (VAR)

La especificación correcta para x_t y H_t es un $VAR(p)$ en diferencias. Un **VAR** es la herramienta estándar para estudiar la **forma reducida** de una relación dinámica entre las variables de $y_t \in \mathcal{R}^n$:

$$y_t = \nu(t) + A_1 y_{t-1} + A_2 y_{t-2} + \cdots + A_p y_{t-p} + u_t,$$

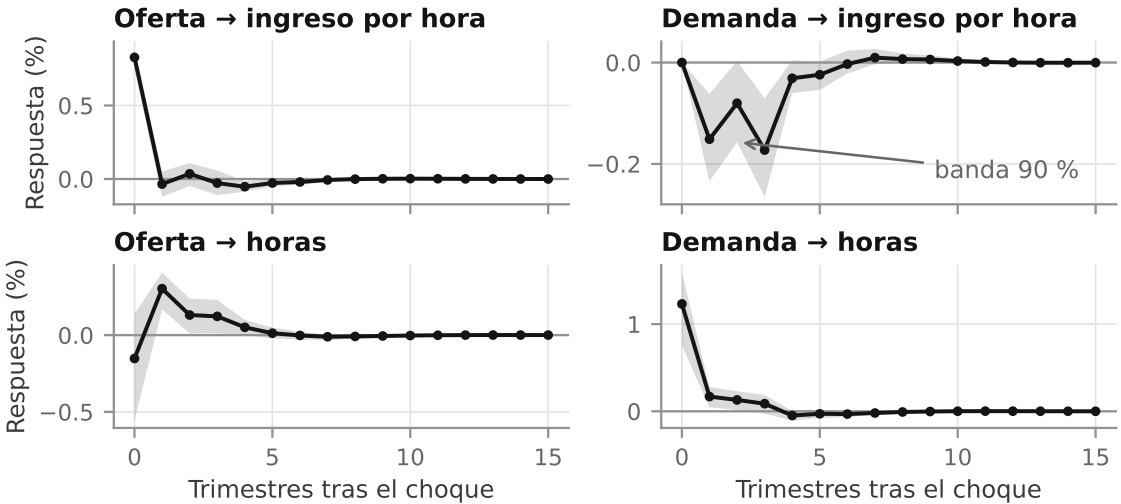
donde $u_t \sim N(0, \Sigma_u)$ es ruido idénticamente distribuido como una normal multivariada. En Python, con el módulo `puremacro.var`:

```
from puremacro.var import fit_var, irf, fevd
from puremacro.var.identify.cholesky import cholesky_factor

# Estimacion OLS de VAR(3) en diferencias con puremacro
res = fit_var(df[['d_incpw', 'd_hrs']].values, p=3)  # OLS VAR(3)
B0  = cholesky_factor(res.Sigma)        # matriz de IMPACTO estructural
irf_mat  = irf(res.A_list, B0, horizon=20)   # impulsos-respuesta
fevd_mat = fevd(res.A_list, B0, horizon=20)  # descomposicion de varianza
```

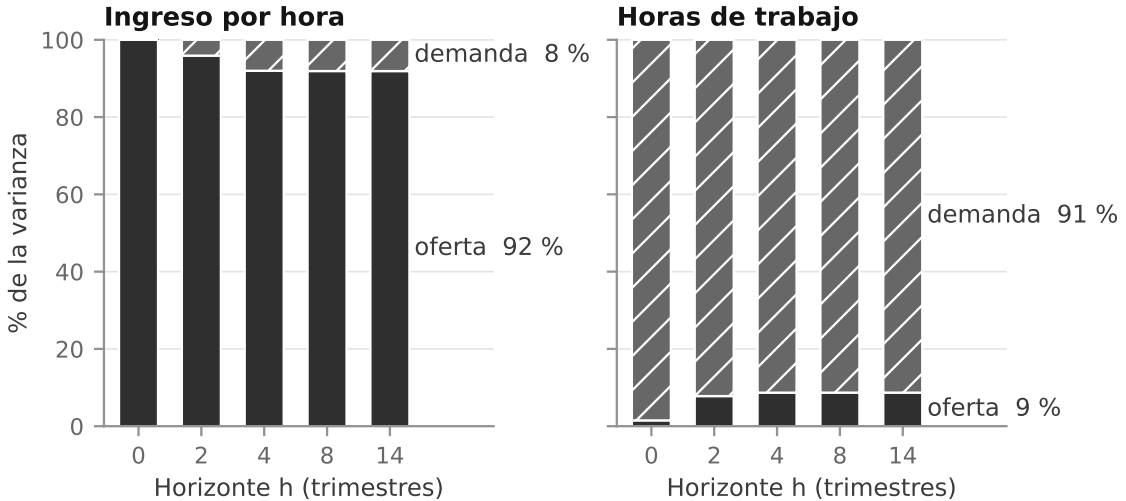
`fit_var` devuelve un objeto con atributos (`res.A_list`, `res.Sigma`), no un diccionario; y el segundo argumento de `irf`/`fevd` es la matriz de **impacto estructural** B, no Σ_u.

Funciones de impulso respuesta



VAR(3) en diferencias, Cholesky con el ingreso primero, 1948T2–2026T1: la misma estimación que la tabla del apéndice.

Descomposición de la varianza



Cuota de la varianza del error de pronóstico por choque: la lectura va escrita junto a la última barra de cada panel.

Choques estructurales

Nada garantiza que u_{xt} sean choques de oferta y que u_{ht} sean choques de demanda: solo son los residuos de la forma reducida, cuya representación estructural puede escribirse como:

$$[I - A(L)]\, y_t = u_t = B\epsilon_t.$$

En dado caso, la matriz de varianzas y covarianzas estimada de la forma reducida $\widehat{\Sigma}_u$ puede escribirse en términos de la **matriz de impactos estructurales** B

$$\widehat{\Sigma}_u = \begin{bmatrix} \hat{\sigma}^2_{xx} & \hat{\sigma}_{xh} \\ \hat{\sigma}_{hx} & \hat{\sigma}^2_{hh} \end{bmatrix} = \begin{bmatrix} b_{ox} & b_{dx} \\ b_{oh} & b_{dh} \end{bmatrix} \begin{bmatrix} b_{ox} & b_{dx} \\ b_{oh} & b_{dh} \end{bmatrix}'.$$

El sistema de ecuaciones no está bien identificado porque una ecuación es redundante debido a la simetría de $\widehat{\Sigma}_u$. Una forma de identificación popular es la triangular o recursiva, asumiendo que los choques de demanda no tienen impacto directo en el ingreso por hora.

$$\begin{bmatrix} b_{ox} & 0 \\ b_{oh} & b_{dh} \end{bmatrix} \begin{bmatrix} b_{ox} & 0 \\ b_{oh} & b_{dh} \end{bmatrix}'.$$

Por lo tanto, B es la descomposición de Cholesky de $\widehat{\Sigma}_u$.

Varios ejemplos de identificación estructural

- Un modelo mensual del mercado global petrolero: Kilian (2009). Ojo: la identificación es **recursiva de corto plazo** (Cholesky sobre Σ_u: qué no responde dentro del mes), no de largo plazo

$$\begin{pmatrix} u_t^{\Delta prod} \\ u_t^{rea} \\ u_t^{rpoil} \end{pmatrix} = \begin{bmatrix} b_{11} & 0 & 0 \\ b_{21} & b_{22} & 0 \\ b_{31} & b_{32} & b_{33} \end{bmatrix} \begin{pmatrix} \epsilon_t^{oil\ supply} \\ \epsilon_t^{agg.\ demand} \\ \epsilon_t^{oil\ demand} \end{pmatrix}$$

- Efectos del precio de la energía sobre el consumo: Edelstein & Kilian (2009) — también recursiva de corto plazo y parcialmente identificada

$$\begin{pmatrix} u_t^{\Delta p} \\ u_t^{\Delta c} \end{pmatrix} = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix} \begin{pmatrix} \epsilon_t^{p} \\ \omega_t \end{pmatrix}$$

- Puente moderno: Känzig (2021, AER) identifica el choque de oferta petrolera con **sorpresas de anuncios de la OPEP** usadas como instrumento externo del precio del petróleo — el mismo mercado de Kilian, pero con la lógica proxy-SVAR que desarrollamos con el multiplicador impositivo

Identificación con restricciones de largo plazo

Es difícil dar buenas razones por las que los choques estructurales de demanda no impacten directamente el ingreso por hora, pero la teoría económica impone ciertas restricciones sobre su comportamiento a largo plazo, que pueden interpretarse de dos formas:

- Los choques de demanda no explican nada de la varianza a largo plazo del ingreso por hora
- La respuesta acumulada del ingreso por hora ante choques de demanda debe ser cero

Empecemos por la primera, recordando que todo $VAR(p)$ tiene una representación en $MA(\infty)$. Por ejemplo, un VAR(1): $y_t = Ay_{t-1} + u_t$, cuya sustitución recursiva nos permite escribir:

$$y_t = \sum_{s=0}^{\infty} A^s u_{t-s} = \left[\sum_{s=0}^{\infty} (AL)^s\right] u_t = \Psi(L)u_t = \Psi(L)B\epsilon_t,$$

y podemos definir los impactos estructurales a largo plazo como:

$$\Theta(1) = \Psi(1)B.$$

Ref.: Blanchard y Quah (1989, *AER*).

El paso clave para entender por qué la identificación a largo plazo es triangular se da al obtener la varianza a largo plazo de y_t

$$\Omega = \Psi(1)\Sigma_u\Psi(1)' = \Psi(1)BB'\Psi(1)',$$

y ver que su descomposición de Cholesky nos da el impacto a largo plazo, con el **supuesto de exclusión** sobre el efecto de los choques de demanda a largo plazo en el ingreso por hora

$$\Omega = \Theta(1)\Theta(1)',$$

finalmente

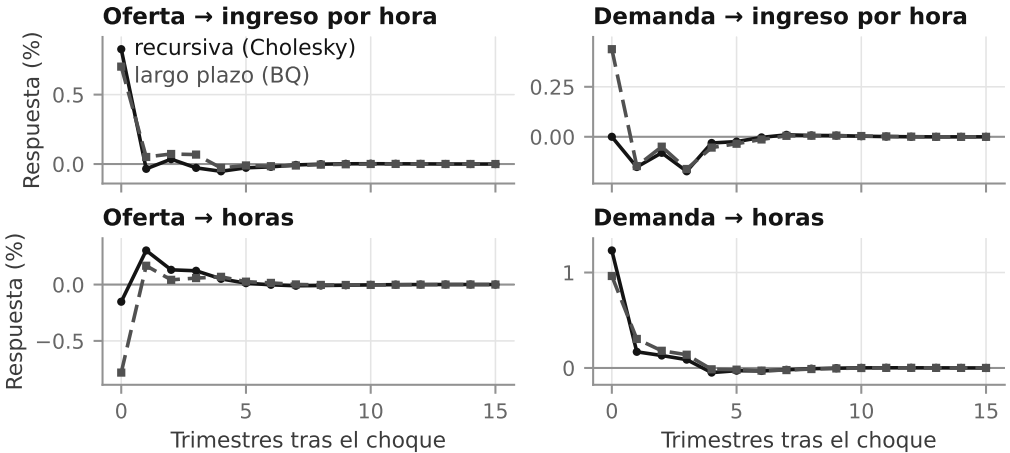
$$\widehat{B} = \Psi(1)^{-1}\,\mathrm{chol}(\widehat{\Omega}).$$

- Toda la identificación estructural de SVAR (Cholesky, Blanchard-Quah y Proxy-SVAR) se ejecuta de forma $100\,\%$ nativa con `puremacro.var.identify` (`cholesky_svar`, `bq_svar`).
- En MATLAB, puede utilizarse el **VAR Toolbox** de Ambrogio Cesa-Bianchi.

Una forma alternativa de imponer la restricción de largo plazo mediante una matriz de rotación $Q(\psi)$ se presenta en el apéndice.

La identificación importa: recursiva contra largo plazo

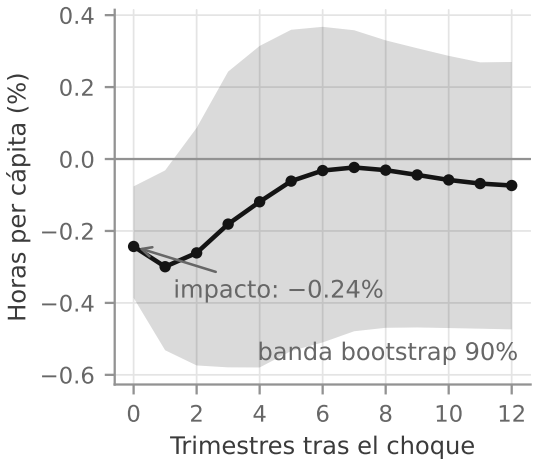
Al comparar las funciones de impulso respuesta, puede apreciarse la importancia de considerar la interacción estructural de diferentes choques sobre una economía:



El resultado de Galí (1999): las horas *caen*

Llevamos todo el tema trabajando con los datos de Galí; ya tenemos las herramientas para producir y defender el resultado que hizo famoso al artículo: identificado el choque tecnológico con la restricción de largo plazo, **las horas trabajadas caen en impacto**.

- ¿Acabamos de refutar el RBC con dos series y una Cholesky?
- Fragilidad: con las horas en **niveles** el resultado se revierte (CEV 2003). La especificación de integración del inicio del tema no era un trámite: era LA decisión



Refs.: Galí (1999); Christiano, Eichenbaum y Vigfusson (2003); Fernald (2007).

Laboratorio (5 min): repliquen el resultado

El snapshot `gali1999.csv` está en `data_curso/` (el mismo que trae el paquete; corre offline); la solución completa es `python -m puremacro.examples.gali_1999_hours`.

```
from puremacro.var.identify.bq import bq_svar
import numpy as np, pandas as pd

df = pd.read_csv('data_curso/gali1999.csv')  # ophnfb, hoanbs, cnp16ov
df = df[pd.to_datetime(df['date']) <= '2007-12-31']  # muestra del debate
dx = 100*np.log(df['ophnfb']).diff()               # productividad
h  = 100*np.log(df['hoanbs']/df['cnp16ov'])        # horas p.c. (log)
Y  = np.column_stack([dx - dx.mean(), h.diff() - h.diff().mean()])[1:]
res = bq_svar(Y, p=4, horizon=20, permanent_var_idx=0)
print(f"{res.irf_point[0, 1, 0]:+.3f}")  # horas en impacto: -0.243
# CEV (2003): horas en NIVELES; solo se acumula la productividad
YL  = np.column_stack([dx - dx.mean(), h - h.mean()])[1:]
cev = bq_svar(YL, p=4, horizon=20, permanent_var_idx=0, cumulate=[0])
print(f"{cev.irf_point[0, 1, 0]:+.3f}")  # mismo choque: +0.112
```

El snapshot llega a 2026; el corte en 2007 es el estándar del debate (pre-Gran Recesión) y es el de la figura. Con la muestra completa el impacto es $-0.84\,\%$: el colapso de horas de 2020 lo cuadruplica.

Debate: ¿esto mata al RBC o mata a la identificación? (diferencias vs. niveles, CEV 2003). La relación de cointegración entre ingreso y horas por persona es la que decide, y decidirla mal cambia el signo del titular.

Companion notebooks: `T02_B_rbc_dynare_local` (celda 11: la misma `bq_svar` sobre `gali1999`, que imprime $-0.233\,\%$ en impacto, contra la IRF de horas del RBC) y `T05_A_svar_identification` (Cholesky, restricciones de signo, narrativas y proxy-SVAR sobre un VAR monetario). El SVAR de Fisher (2006) se hace en clase: no tiene cuaderno.

Evidencia sobre la importancia cíclica de la tecnología

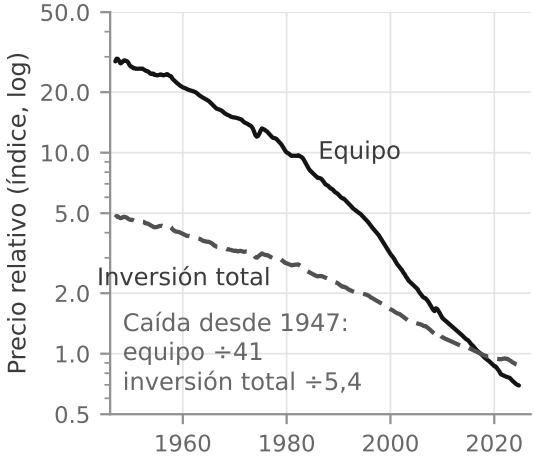
La literatura distingue dos tipos de choques tecnológicos: neutrales o específicos a la inversión (no neutrales)

- Prescott (1986) muestra que una versión del modelo neoclásico de crecimiento con choques a la PTF como los que hemos estimado explica cerca de un 70 % de las fluctuaciones cíclicas del PIB por persona. Además, el empleo es procíclico y correlacionado con la productividad
- Basu, Fernald y Kimball (2006) depuran la PTF de la utilización del capital y del esfuerzo (energía eléctrica, horas por trabajador): el choque tecnológico depurado hace **caer** los insumos en impacto — corrobora el resultado de Galí por una vía completamente distinta
- Greenwood et al. (2000) muestran que el choque tecnológico **específico a la inversión** explica cerca de un tercio ($\sim$30 %) de las fluctuaciones del producto
- Beaudry & Portier (2006) muestran que las noticias sobre descubrimientos tecnológicos generan fluctuaciones cíclicas del PIB por persona
- Justiniano et al. (2010, 2011) obtienen choques resultado de estimar un modelo DSGE con métodos bayesianos

Fisher (2006): el choque específico a la inversión

El precio relativo del equipo cae un factor ≈41 desde 1947 (≈371 puntos log, ≈4.8 % anual — más de un orden y medio de magnitud): el cambio técnico viene **incorporado en las máquinas**, no cae del cielo.

- Si el progreso llega vía equipo más barato, un SVAR con un único choque tecnológico “neutral” está mal especificado
- Enlace IA: el precio del cómputo cae más rápido que el del equipo agregado — ¿una nueva ola de cambio técnico específico a la inversión, y qué predice este SVAR sobre horas y productividad?



Refs.: Fisher (2006); Greenwood, Hercowitz y Krusell (2000); DiCecio (2009).

Laboratorio: el SVAR de Fisher con restricciones de largo plazo

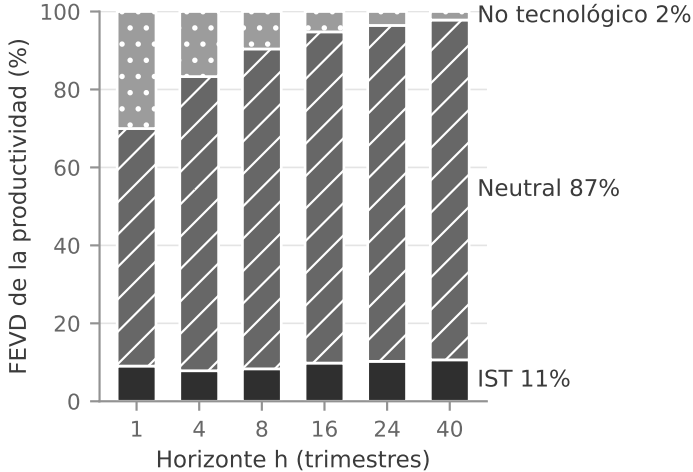
Sistema $[\Delta \log p_I,\ \Delta \log(Y/H),\ \Delta \log h]$ — **todo en diferencias**, así que `bq_svar` acumula las tres IRF (su `cumulate=True` por omisión) y cada una se lee en nivel — con el precio ordenado **primero**: la Cholesky de Ω implementa la triangularidad de largo plazo (solo el choque IST mueve p_I a largo plazo; ambos choques tecnológicos mueven la productividad).

```
import numpy as np, pandas as pd
from puremacro.var.identify.bq import bq_svar
from puremacro import fetch

p_i = fetch.fetch_fred('PIRIC')  # precio relativo de la inversion total
g = pd.read_csv('data_curso/gali1999.csv', parse_dates=['date']).set_index('date')
q = pd.concat({'p': p_i, 'x': g['ophnfb'], 'h': g['hoanbs'] / g['cnp16ov']},
              axis=1).dropna().loc['1948':'2019']
Y = (100*np.log(q)).diff().dropna().to_numpy()  # [dlog p_I, dlog(Y/H), dlog h]
res = bq_svar(Y, p=4, horizon=40, permanent_var_idx=0)  # precio PRIMERO
# bq_svar NO devuelve una FEVD: res.irf_point ya viene ACUMULADA (nivel)
c = np.cumsum(res.irf_point**2, axis=0)[40, 1, :]  # productividad, h = 40
print(f"{(c[0] + c[1]) / c.sum():.3f}")  # dos choques tecnologicos: 0.978
# robustez: identify_maxshare(Y, p=4, target_idx=0, max_fev_at=40, horizon=40)
```

Si se mete `log h` en niveles con el `cumulate=True` por omisión, la "IRF de horas" es la suma acumulada de una respuesta que ya estaba en nivel; `cumulate=[0, 1]` acumula solo precio y productividad. Y `max_fev_at` nunca puede exceder el `horizon` (por omisión 20): de ahí el `horizon=40`.

Fisher (2006): la FEVD de la productividad, y lo que no dice



- Lo que se descompone es el **nivel de la productividad del trabajo**, no el PIB: el PIB ni siquiera está en el sistema

Fisher (2006): por qué ese $\sim$98 % no es el $\sim$30 % de Greenwood et al.

- Sistema trivariado $[\Delta \log p_I,\ \Delta \log(Y/H),\ \Delta \log h]$ estimado con `bq_svar` sobre 1948–2019
- El $\sim$98 % a diez años es en buena medida **mecánico**: la restricción de largo plazo asigna por construcción todo el movimiento permanente de la productividad a los dos choques tecnológicos. El número comparable con el $\sim$30 % de Greenwood et al. es la FEVD del **producto**, que exige construir $\log Y = \log(Y/H) + \log H$ y no sale de `res`
- Extensión multipaís (datos locales, fuera de clase):

```
klems.load_klems_panel(include_investment=True, equip_def='tangible')
```

Refs.: Fisher (2006); Justiniano, Primiceri y Tambalotti (2011).

Narrativa y proxy-IV

Choques fiscales y monetarios

Semana 10 · Laboratorio: el multiplicador impositivo por tres vías

Identificaciones no triangulares

Un ejemplo que merece especial atención es Blanchard & Perotti (2002), porque adoptan un enfoque no recursivo y porque estudian el papel de los choques estructurales en impuestos y gasto sobre la actividad económica.

$$\begin{bmatrix} 1 & 0 & a_{13} \\ 0 & 1 & a_{23} \\ a_{31} & a_{32} & 1 \end{bmatrix} \begin{pmatrix} u_t^{tax} \\ u_t^{gov} \\ u_t^{gdp} \end{pmatrix} = \begin{bmatrix} 1 & b_{12} & 0 \\ b_{21} & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{pmatrix} \epsilon_t^{tax} \\ \epsilon_t^{gov} \\ \epsilon_t^{gdp} \end{pmatrix}.$$

Asumen $a_{23} = 0$ argumentando rezagos legislativos que impiden que el gasto del gobierno reaccione a la actividad económica en el mismo trimestre, estiman a_{13} (la elasticidad cíclica de los impuestos) usando información institucional externa, e imponen b_{12} o b_{21} iguales a cero.

Los impactos e IRFs bajo este esquema de identificación no pueden estimarse de forma recursiva, por lo que es necesario recurrir a estimadores distintos del OLS. Esta identificación **institucional** prepara el terreno para el enfoque proxy-IV de Mertens & Ravn que veremos con el multiplicador impositivo.

Métodos de identificación narrativos

El enfoque narrativo consiste en buscar evidencia que permita argumentar que una serie de choques es claramente estructural y exógena. No hay otra forma de explicarlo que a través de ejemplos:

- Hamilton (1985) y Hoover & Perez (1994) identifican choques petroleros basados en noticias y eventos geopolíticos
- Ramey & Shapiro (1998) y Ramey (2011) identifican choques al gasto del gobierno usando información del semanario “Business Week” sobre gastos en defensa. Además, se han usado fechas de guerras como instrumentos
- Romer & Romer (2010) construyen choques estructurales a los impuestos leyendo documentos oficiales de EUA: el *Economic Report of the President*, reportes del Congreso y del Tesoro, y discursos presidenciales
- Mertens & Ravn (2012) usan el enfoque narrativo y los rezagos en la ejecución de la legislación desde su anuncio para distinguir entre choques fiscales esperados y sorpresas

Romer & Romer (2010)

Así funcionaría el método narrativo para documentar un recorte impositivo de corto plazo (la documentación de los recortes de largo plazo y las series resultantes siguen la misma lógica; en el laboratorio las veremos como datos):

Tax Reduction Act of 1975

Signed:	3/29/75	
Change in Liabilities (excluding retroactive changes):		
1975:II	−$45.3 billion	(Endogenous; Countercyclical)
1975:III	+$32.5 billion	(Endogenous; Countercyclical)
Change in Liabilities (including retroactive changes):		
1975:II	−$58.1 billion	(Endogenous; Countercyclical)
1975:III	+$45.3 billion	(Endogenous; Countercyclical)
Present Value:		
1975:III	−$13.32 billion	(Endogenous; Countercyclical)

The Tax Reduction Act of 1975 was a change in taxes that was made to try to return economic growth to normal. In early 1975, growth was weak and expected to remain weak in the absence of changes in policy. The 1975 *Economic Report* stated, "As 1975 begins, … production and employment are declining sharply. … It is quite likely … that the contraction of business activity and rising unemployment will continue for several more months" (p. 19). Likewise, the President's Annual Budget Message to the Congress, Fiscal Year 1976 declared: "It must be clearly understood that these problems are serious and that strong remedies are fully justified. The economy is now in a recession" (2/3/75, p. 2).

El multiplicador impositivo por tres vías

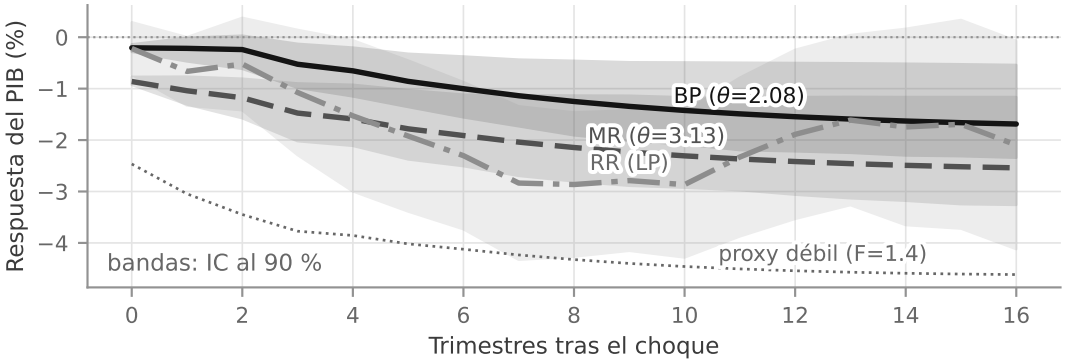
Un mismo objeto —la respuesta del PIB a un cambio impositivo— y tres estrategias de identificación:

1. **Institucional** (Blanchard & Perotti 2002): elasticidades fiscales y rezagos legislativos, con $\theta = 2.08 \Rightarrow$ pico -1.55 en $h = 12$
2. **Narrativa + LP** (Romer & Romer 2010): los choques leídos de documentos oficiales, directamente como regresor — en espíritu, una LP del choque narrativo (RR usan una regresión de rezagos distribuidos) $\Rightarrow$ pico -2.87 en $h = 10$ (-2.86 a dos años)
3. **Proxy-SVAR** (Mertens & Ravn 2013): la serie narrativa como **instrumento** de los residuos del VAR. Reconciliado con $\theta = 3.13$ da pico -2.42; MR reportan en su artículo -2 a -3

La discrepancia es la pregunta: ¿atenuación por error de medida en la serie narrativa (el argumento de MR a favor del proxy) o exogeneidad dudosa de los choques narrativos?

Refs.: Romer y Romer (2010); Mertens y Ravn (2013); Blanchard y Perotti (2002).

Las tres sendas, una al lado de la otra



- Alza impositiva de 1 % del PIB, muestra 1950T1–2006T4; en el punto más bajo de los tres primeros años (BP -1.55, MR -2.42, RR -2.87) BP es la menos negativa y RR la más: ese orden sostiene la discusión de la lámina anterior. Pasado $h = 12$, BP y MR siguen bajando despacio y RR remonta
- La cuarta línea es una **advertencia**, no un resultado: el proxy crudo sobre datos agregados sale con instrumento débil (F efectiva $= 1.4$) y se hunde hasta -4.54 al tercer año

Companion notebooks: `T04_A_tax_multiplier_three_ways` (celda 21) y `T05_A_svar_identification`.

Laboratorio: las tres vías con `puremacro` (Proxy-SVAR)

Todo corre offline: `load_romer_romer_2010()` cae por defecto en el snapshot empaquetado, y los datos fiscales están en `data_curso/tax14_us_fiscal.csv` y `data_curso/tax14_narrative_tax_shocks.csv`.

```
from puremacro import lp, narrative
from puremacro.var.identify.proxy import proxy_svar
import pandas as pd

rr  = narrative.load_romer_romer_2010()        # serie narrativa (offline)
fis = pd.read_csv('data_curso/tax14_us_fiscal.csv')  # PIB, recaudacion, gasto (data_curso/)

irf1 = lp.lp_hac(...)   # (i)  LP directa del choque narrativo
irf2 = lp.lp_iv(...)    # (ii) narrativa como IV de la recaudacion
                        #      verificar irf2.first_stage_f > 10
irf3 = proxy_svar(...)  # (iii) proxy-SVAR (Mertens-Ravn)
```

- Los alumnos **ven** el instrumento como una serie de datos: ¿en qué años hay choques narrativos grandes y qué legislación los motivó?
- Instrumentos débiles: el estadístico correcto es el **F efectivo** de Montiel Olea y Pflueger (2013); $F > 10$ es la regla práctica heredada, sin fundamento; $F > 23.1$ es el umbral que acota el sesgo de peor caso en 10 %
- Si el instrumento es débil, los EE y estadísticos t convencionales del IV no son confiables: la inferencia debe hacerse con métodos **robustos a instrumentos débiles** (p. ej. la prueba de Anderson–Rubin, cuyo tamaño es correcto sin importar la fuerza del instrumento)

Romer y Romer (2004): la misma navaja narrativa, ahora monetaria

El choque monetario es el ejemplo canónico de la literatura; la estrategia es simétrica a la fiscal de Romer & Romer (2010):

- De las minutas del FOMC extraen el cambio **deseado** de la tasa de fondos federales en cada reunión
- Lo purgan de la respuesta sistemática a la información de la Fed: regresan el cambio deseado sobre los pronósticos internos (Greenbook) de inflación y actividad
- El residuo es el choque monetario narrativo: contractivo, reduce la producción industrial de forma sustancial con un rezago de $\sim$2 años
- La crítica es la misma que a la narrativa fiscal: ¿es el residuo exógeno, o la Fed sabe algo que el Greenbook no recoge?

Refs.: Romer y Romer (2004); Romer y Romer (2010).

Gertler y Karadi (2015): sorpresas de alta frecuencia como proxy

Segundo ejemplo del **mismo** proxy-SVAR: el instrumento ya no se lee, se **mide** en el mercado.

- La sorpresa monetaria es el cambio del futuro de fondos federales en una ventana de 30 minutos alrededor del anuncio del FOMC: dentro de la ventana, solo el anuncio mueve el precio
- Esa sorpresa instrumenta los residuos de la tasa en un VAR con producción, precios y el diferencial de crédito: el canal crediticio amplifica el choque
- En México: las sorpresas de anuncios de **Banxico** son construibles con el conector `iter_banxico_decision` (las fechas y comunicados ya están disponibles); el instrumento de mercado exige series intradía de TIIE o futuros de tasa

Refs.: Gertler y Karadi (2015); Nakamura y Steinsson (2018); Känzig (2021).

Proyecciones locales

Inferencia HAC, multiplicadores dependientes del estado y diseños de panel

Semana 10, segunda mitad

Laboratorio: Ramey–Zubairy en vivo

La proyección local estima la IRF sin comprometerse con el VAR

La función de impulso respuesta responde a la pregunta central: ¿cuál es el impacto causal de un choque estructural sobre una variable agregada?

$$\frac{\Delta y_{jt+h}}{\Delta \epsilon_{it}} = d_{ijh},$$

con d_{ijh} función de la variable j, del choque i y del horizonte h. Leída desde un VAR, es una combinación no lineal de todos sus coeficientes: **óptima para cualquier h si el VAR captura el verdadero PGD**, y contaminada en todo horizonte si no. Jordà (2005, 2024) propone estimar cada horizonte por separado:

$$y_{jt+h} = \theta^{i}_{jh}\, \epsilon_{it} + \Gamma X_t + \upsilon_{jt+h},$$

donde θ^{i}_{jh} **es** la respuesta al horizonte h y X_t recoge los controles (rezagos, deterministas).

- Un error de dinámica en $h = 1$ no se propaga a $h = 12$: cada horizonte es una regresión distinta
- Admiten datos de panel, variables instrumentales y efectos geográficos
- Admiten cambios de régimen: un mismo choque fiscal con efecto distinto en expansión y en recesión
- En Python, el módulo `puremacro.lp`; MATLAB tiene toolboxes equivalentes

El residuo de una LP a horizonte h es un MA($h-1$): sin HAC, los EE mienten

En la LP $y_{t+h} = \theta_h \, \epsilon_t + \Gamma X_t + \upsilon_{t+h}$, el residuo acumula **por construcción** los h choques que llegan entre $t+1$ y $t+h$:

$$\upsilon_{t+h} = \epsilon_{t+h} + \psi_1 \epsilon_{t+h-1} + \cdots + \psi_{h-1} \epsilon_{t+1},$$

así que dos observaciones consecutivas comparten choques (solapamiento de horizontes) y υ es un proceso MA($h-1$): sus autocovarianzas solo se anulan a partir del rezago h, y los errores estándar de OLS clásicos están mal.

- **Newey–West**: la respuesta estándar es una matriz de covarianzas HAC con ancho de banda (*bandwidth*) $\geq h-1$ (en la práctica, h) — es exactamente el "`hac`" de `lp.lp_hac`
- **Lag-augmented LP** (Montiel Olea y Plagborg-Møller 2021, *Econometrica*): si se incluyen los rezagos de todas las variables como controles, la inferencia es válida con errores robustos ordinarios, sin elegir truncamiento — y es lo que justifica el "mismos rezagos como controles" del código
- Regla práctica: rezagos como controles siempre; HAC con ancho de banda $\geq h$ como cinturón adicional cuando el horizonte es largo respecto de la muestra

LP vs. SVAR: mismos datos, ¿misma IRF?

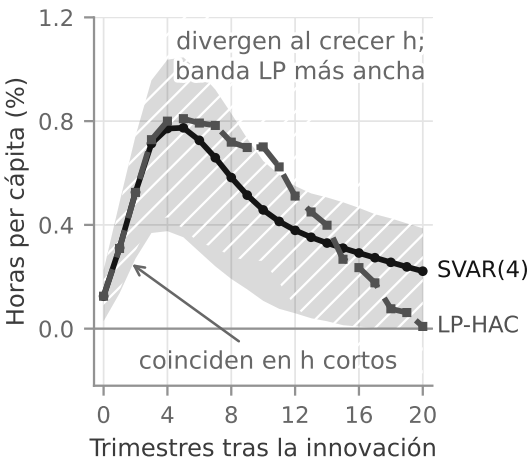
Sobre los datos de Galí, estimamos la IRF por Cholesky-SVAR y por proyección local con los **mismos rezagos**:

```
from puremacro import lp
from puremacro.var.identify.cholesky import cholesky_svar

# df: columnas 'dprod' (100*dlog product.) y 'h' (100*log horas p.c.)
Y = df[['dprod', 'h']].to_numpy()       # cholesky_svar toma el NDARRAY
irf_var = cholesky_svar(Y, p=4, horizon=20)
irf_lp  = lp.lp_hac(df, y='h', x='dprod',   # lp_hac toma el DATAFRAME
                    horizons=range(0, 21), n_lags=4)  # mismos 4 rezagos
```

Las dos IRF, con sus bandas, están en la lámina siguiente.

LP vs. SVAR: coinciden en h pequeños y divergen al crecer h



Coinciden en h pequeños; divergen al crecer h, con bandas LP mucho más anchas.

Las dos líneas salen de los **mismos** datos (`gali1999`, 1948–2007) y los **mismos** cuatro rezagos: lo único que cambia es si la dinámica de horizontes largos la impone el VAR o la estima cada regresión por separado.

En población, LP y VAR estiman la misma IRF: la elección es sesgo–varianza

- En población estiman **la misma** IRF (Plagborg-Møller y Wolf 2021): la elección es sesgo–varianza en muestra finita, no identificación — vacuna contra la guerra de religión LP-vs-VAR

Advertencia Econométrica: Guía de Selección SVAR vs. LP

- **Sesgo vs. Varianza:** LP es robusta a errores de dinámica de corto plazo pero su varianza explota a $h > 12$. SVAR impone la estructura autorregresiva reduciendo varianza, pero acumula sesgo si p es insuficiente.
- **Regla práctica:** Reportar SVAR como especificación base y LP-HAC como prueba de robustez sin sobre-interpretar horizontes muy lejanos ($h > 16$).

Refs.: Plagborg-Møller y Wolf (2021); Li, Plagborg-Møller y Wolf (2024); Jordà (2005).

El multiplicador es un cociente de respuestas acumuladas, no un coeficiente

La literatura fiscal contesta dos preguntas: ¿puede el gasto público generar una expansión o una contracción? y ¿cuál es el efecto de mover los impuestos? La segunda ya tiene tres respuestas —institucional, narrativa y proxy-SVAR—; la del gasto exige antes definir bien el objeto que se reporta:

$$\mathcal{M}_h = \frac{\sum_{s=0}^{h} d_{ygs}}{\sum_{s=0}^{h} d_{ggs}} \times \frac{\bar{Y}}{\bar{G}}.$$

- Derivación del factor de conversión: si las IRFs vienen en puntos porcentuales, $\Delta Y_s = \bar{Y}\, d_{ygs}$ y $\Delta G_s = \bar{G}\, d_{ggs}$, así que el cociente en unidades de producto es el de arriba. Con $\bar{G}/\bar{Y} \approx 0.2$, el factor **multiplica por cinco** la elasticidad: confundir el sentido del cociente cambia un multiplicador de 1 por uno de 0.04
- Ramey–Zubairy evitan el problema especificando Y y G ya divididos entre el PIB de tendencia (a la Gordon–Krenn): el factor desaparece y el coeficiente **es** el multiplicador
- El “multiplicador pico” (cociente de picos) no es este objeto: los picos ocurren en horizontes distintos. Buena parte de la dispersión entre estudios es de contabilidad, no de economía

Al igual que con los choques a la productividad, todo depende de conseguir choques exógenos al gasto.

Choques al gasto público

- Rotemberg & Woodford (1992) usan el residuo de un $AR(p)$ sobre el gasto militar como choques exógenos al gasto público. Encuentran que choques al gasto público aumentan los salarios reales
- Ramey & Shapiro (1998) emplean un enfoque narrativo leyendo notas en “Business Week” sobre el ejército y fechas de conflictos militares
  - Cuando se usa la variable de fechas de guerras en primer lugar en el orden del vector, surgen los EVARs
  - La literatura encuentra que los choques al gasto público aumentan el PIB y las horas de trabajo, pero reducen el consumo y los salarios reales
- McGrattan (1994) realiza una de las primeras estimaciones de choques estructurales al gasto público
- Blanchard & Perotti (2002): para el choque de gasto, la identificación equivale a una Cholesky con G ordenado primero; la del choque impositivo usa la elasticidad institucional (no recursiva, ver la lámina de identificaciones no triangulares)

Estimaciones del multiplicador del gasto público

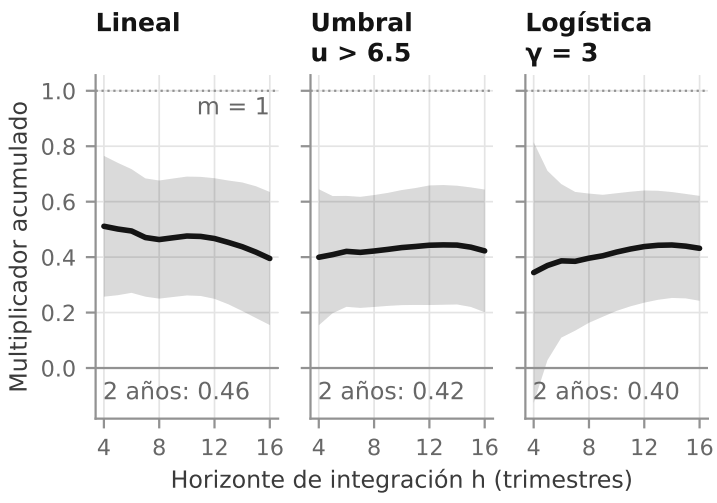
Estudio	Muestra	Identificación	Multiplicador implícito
Barro (1981); Hall (1986, 2009); Barro–Redlick (2011)	Muestras anuales históricas	Gasto militar como instrumento del gasto público	0.6–1
Rotemberg–Woodford (1992)	Trimestral, 1947–1989	Residuo de una regresión del gasto militar sobre sus rezagos y los del empleo militar	1.25
Ramey–Shapiro (1998); Edelberg et al. (1999); Burnside et al. (2004)	Trimestral, 1947–fin. 1990s/2000s	Fechas de Ramey–Shapiro (expansiones militares anticipadas, narrativa)	0.6–1.2, según muestra y método (acum./pico)
Blanchard–Perotti (2002)	Trimestral, 1960–1997	SVAR, Cholesky con G ordenado primero	0.9–1.29, multiplicadores pico
Mountford–Uhlig (2009)	Trimestral, 1955–2000	Restricciones de signo sobre un SVAR	0.65 (aumento financiado con déficit)
Romer y Bernstein (2009)	Trimestral	Promedio de multiplicadores del modelo FRB/US y de un modelo privado de pronósticos	Sube a 1.57 al 8.º trim.
Cogan et al. (2010)	Trimestral, 1966–2004	Modelo Smets–Wouters estimado	0.64 en el pico
Ramey (2011a,b)	Trimestral, 1939–2008 y submuestras	VAR con choques narrativos al valor presente esperado del gasto militar	0.6–1.2, según muestra
Fisher–Peters (2010)	Trimestral, 1960–2007	VAR con choques al exceso de rendimiento bursátil de contratistas militares	1.5, efectos acumulados
Auerbach y Gorodnichenko (2012)	Trimestral, 1947–2008	SVAR con pronósticos profesionales y noticias de Ramey; cambio de régimen	Exp.: -0.3 a 0.8; rec.: 1–3.6
Ben Zeev y Pappa (2017)	Trimestral, 1947–2007	Choque ortogonal al gasto de defensa que mejor explica su dinámica a 5 años	2.1 (multiplicador integral a 6 trim.)

Fuente: Ramey (2016), *Macroeconomic Shocks and Their Propagation*, Handbook of Macroeconomics, vol. 2A, cuadro 3.

Ramey–Zubairy (2018): ¿multiplicadores mayores en recesiones?

La defensa keynesiana estándar: el multiplicador del gasto es mayor cuando hay capacidad ociosa. Ramey y Zubairy (2018) la llevan a 126 años de datos de EUA (1889–2015), con noticias de gasto militar como instrumento y proyecciones locales dependientes del estado.

Resultado que incomoda productivamente: **ninguna** de las tres especificaciones llega a 1, ni siquiera con holgura alta.



Cómo leer esa figura: el estimador vale 0.2 puntos de multiplicador

- El **titular** de Ramey–Zubairy —≈0.66 a dos años y ≈0.71 a cuatro, ambos del caso **lineal** (su cuadro 1); en el estado de holgura los multiplicadores tampoco superan 1: quedan en 0.6–0.8— sale de una LP-IV **de un paso**, y es lo que reproduce `python -m puremacro.examples.ramey_zubairy_2018_multipliers` ($+0.669$ y $+0.710$)
- La figura usa el **cociente de dos formas reducidas** (respuesta acumulada del PIB entre respuesta acumulada del gasto) y da $+0.46$ lineal, $+0.42$ con umbral y $+0.40$ con logística. La diferencia de estimador vale $\sim$0.2 puntos de multiplicador: el punto de política —"no llega a 1"— sobrevive, la cifra exacta no
- En Auerbach–Gorodnichenko (2012) la transición logística es la que produce multiplicadores **mayores** en recesión; con los 126 años de RZ y esta especificación **no** lo hace: $+0.40$ en holgura alta, por debajo del lineal $+0.46$. ¿Cuánta política fiscal se justificó con una elección de especificación que no sobrevive a la muestra larga?

Companion notebook: `T05_B_local_projections` (proyecciones locales lineales, inferencia HAC y multiplicadores acumulados dependientes del estado); véanse también Auerbach y Gorodnichenko (2012) y Ramey (2016).

Laboratorio: Ramey–Zubairy en vivo

El snapshot `rz2018.csv` está en `data_curso/` (corre offline): EUA 1889–2015 con noticias militares, gasto, PIB y desempleo. El bloque reproduce los cocientes de la figura en holgura.

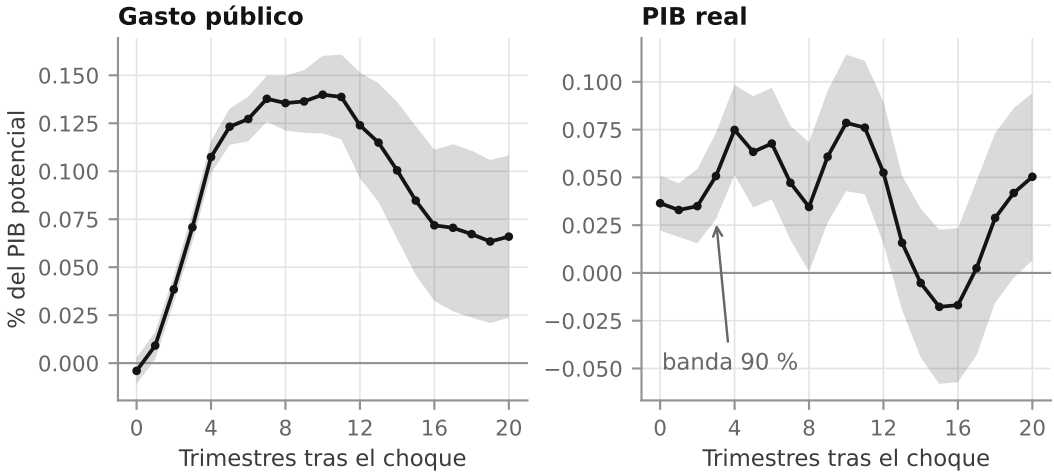
```
import pandas as pd
from puremacro import lp

rz  = pd.read_csv('data_curso/rz2018.csv', parse_dates=['date']).set_index('date')
pot = rz['rgdp_pott6']                          # PIB potencial (Gordon-Krenn)
d = pd.DataFrame({'y': 100*rz['rgdp']/pot, 'g': 100*rz['ngov']/rz['pgdp']/pot,
                  'news': 100*rz['news']/(rz['pgdp']*pot),
                  'unemp': rz['unemp']}).dropna()
d['cy'] = (d['y'] - d['y'].mean()).cumsum()  # y_{t+h} - y_{t-1}: respuesta
d['cg'] = (d['g'] - d['g'].mean()).cumsum()  # acumulada de PIB y gasto
d['ylag'], d['glag'] = d['y'].shift(1), d['g'].shift(1)
d = d.dropna()
kw = dict(state='unemp', horizons=range(17), n_lags=4)
for tr, opc in [('threshold', {'threshold': 6.5}),  # u > 6.5 % (RZ)
                ('logistic', {'gamma': 3.0})]:       # sabor AG
    num = lp.lp_state_dep(d, 'cy', 'news', transition=tr, controls=['glag'], **kw, **opc)
    den = lp.lp_state_dep(d, 'cg', 'news', transition=tr, controls=['ylag'], **kw, **opc)
    print(tr, f"{num['beta_H'].iloc[8] / den['beta_H'].iloc[8]:+.2f}")  # +0.42, +0.40
```

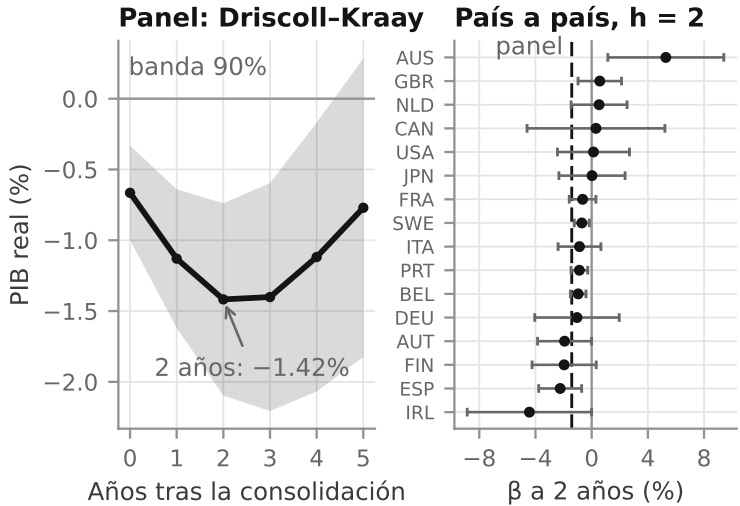
`threshold` va en la escala del estado: `6.5` es 6.5 % de desempleo. Un umbral que deja a todas las observaciones en un solo régimen (p. ej. un z estandarizado de -0.03) lanza `ValueError`. Comparen las dos definiciones de "recesión": ¿cambia la conclusión de política?

Una noticia de gasto militar eleva el gasto y, con él, el PIB

Proyección local de Jordà con 4 rezagos y bandas del 90 % de Newey–West, sobre `rz2018` (EUA, 1947–2015); ambas variables van en % del PIB potencial de Gordon–Krenn.



La austeridad narrativa es contractiva: $-1.4\,\%$ de PIB a dos años



Ojo: el panel izquierdo usa los 17 países; el *forest plot* lleva 16 (el PIB danés arranca en 1995 y su episodio de 1983–86 queda fuera).

Qué arbitra ese -1.42, y qué no

Consolidaciones fiscales **narrativas** de Devries et al. (2011) para 17 países de la OCDE (panel anual hasta 2019). Una LP de panel con efectos fijos de dos vías y errores Driscoll–Kraay da, ante una consolidación de 1 % del PIB, $\beta_2 = -1.42$ (banda 90 %: -2.10 a -0.74).

- El signo depende de la identificación: con el CAPB (ajuste cíclico) la austeridad parece expansiva (Alesina–Ardagna); con las consolidaciones narrativas es contractiva (Guajardo–Leigh–Pescatori). Este panel, eso sí, no arbitra esa disputa: sin PIB antes de 1995 no contiene los episodios canónicos danés (1983–86) ni irlandés (1982–88)
- Jordà–Taylor dan la segunda vuelta: ni las narrativas son exógenas, son predecibles por el ciclo
- El panel entero es la Parte B del Examen Final Computacional: esta LP contra el mismo panel como *event study* TWFE, con prueba de pre-tendencias (en el apéndice)

Refs.: Guajardo, Leigh y Pescatori (2014); Alesina y Ardagna (2010); Jordà y Taylor (2016).

Cinco técnicas, una sola pregunta: ¿de dónde sale la variación exógena?

Respuesta	Supuesto que la sostiene	Dónde aparece	Por dónde se rompe
Recursiva (corto plazo)	Existe un orden en el que unas variables no responden dentro del periodo	Kilian (2009); EPU $\longrightarrow$ producción industrial	Invertir el orden suele ser igual de defendible y la IRF cambia
Restricción de largo plazo	Solo el primer choque mueve el nivel de la variable ordenada primero cuando $h \to \infty$	Galí (1999); Fisher (2006)	$\Psi(1)$ se estima con un VAR truncado; niveles contra diferencias revierte el signo (CEV 2003)
Narrativa	Los documentos fechan el choque y quien decide no anticipa el ciclo	Romer–Romer (2004, 2010); Ramey–Shapiro; Devries et al.	Si la decisión es predecible por el ciclo, no es choque (Jordà–Taylor 2016)
Instrumento externo	z_t correlaciona con el choque de interés y con ningún otro	Mertens–Ravn (2013); Gertler–Karadi (2015); Känzig (2021)	Instrumento débil (F efectivo) y efecto información: la sorpresa revela lo que el banco central sabe
Variación de corte transversal	Tendencias paralelas; los efectos de tiempo absorben lo común	Panel de austeridad; *event study* de exposición a la IA	Pre-tendencias, tratamientos escalonados heterogéneos y, sobre todo, el estimando no es el agregado

Ninguna columna del medio “gana”. En Galí la variable ordenada primero es la productividad; en Fisher es el precio del equipo, y sobre la productividad actúan los **dos** choques tecnológicos. El artículo bueno no es el que usa la técnica de moda, sino el que dice cuál es su fuente de variación exógena y contra qué evidencia la defiende.

Companion notebooks: `T05_C_staggered_did` (estimadores Callaway–Sant’Anna y descomposición de Bacon) y `T05_D_lp_did` (proyecciones locales con DiD de Dube et al. 2023).

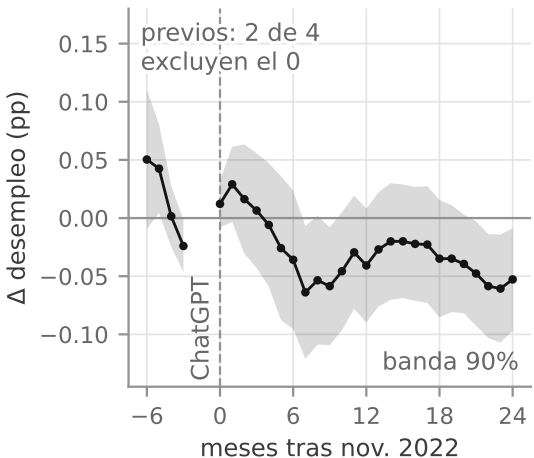
El corte transversal estima un efecto relativo, no el multiplicador agregado

Sea $y_{i,t} = a_i + b\,x_{i,t} + c\,X_t + u_{i,t}$, con $X_t = \sum_i \omega_i x_{i,t}$ la variación agregada del mismo tratamiento y $\sum_i \omega_i = 1$.

- Con efectos fijos de tiempo, δ_t absorbe $c\,X_t$ —es idéntico para toda i— y el estimando es b: el efecto de tratar a i en vez de a j
- Agregando con pesos ω_i: $Y_t = \bar{a} + (b + c)X_t + \bar{u}_t$, de modo que el objeto de política es $b + c$, y el corte transversal no puede identificar c porque c es justo lo que se tira con los efectos de tiempo
- En c viven la política monetaria (que reacciona al agregado, no a la diferencia entre regiones), el financiamiento —lo que una región gasta lo pagan todas— y las filtraciones comerciales, que salen de b pero no del agregado. Su signo no está determinado: con la tasa en su límite inferior, $c > 0$ y $b + c > b$

Refs.: Nakamura y Steinsson (2014, *AER*; 2018, *JEP*); Chodorow-Reich (2019, *AEJ: Policy*); Farhi y Werning (2016).

Un b de manual: el *event study* de exposición a la IA



El *event study* de exposición a la IA entre estados de EUA es un b de manual: un banco central, un presupuesto federal, un mercado de trabajo nacional. Mide reasignación entre estados, no el efecto de la IA sobre el empleo agregado.

El -1.42 del panel de austeridad **no** es ese caso, pero tampoco es limpio: los siete países con moneda propia (AUS, CAN, DNK, GBR, JPN, SWE, USA) aportan algo cercano a $b + c$; los diez del euro, desde 1999, tienen política monetaria común y se la lleva δ_t, así que se parecen al caso b. Eso es el 40 % de las 518 observaciones: el -1.42 es una mezcla.

Pregunta: ¿qué información **adicional** —un modelo, un episodio con la tasa en su límite inferior— hace falta para pasar de b a $b + c$?

Un choque de incertidumbre para México (10 min)

Otro candidato es el choque de incertidumbre (segundo momento; Bloom 2009): en el riesgo se conoce la distribución; en la incertidumbre *knightiana* (ambigüedad), no. El EPU cubre a México desde 1996; la producción industrial, del OECD MEI.

```
from puremacro import lp, uncertainty
from puremacro.fetch import epu, oecd_mei  # fetch.epu -> AttributeError
from puremacro.var.identify.cholesky import cholesky_svar
epu_df = epu.fetch()                   # incluye MEX desde 1996
mei    = oecd_mei.fetch(codes=['MEX'], start_period='1993')  # log_ip
Y   = ...                              # [EPU_MEX, 100*log IP]
res = cholesky_svar(Y, p=12, horizon=36)
# incertidumbre PRIMERO (Bloom): caida con rebote de la IP
# fragilidad: reestimar con el EPU ordenado ULTIMO
# via LP: uncertainty.derive_innovation_shock + lp.lp_hac
```

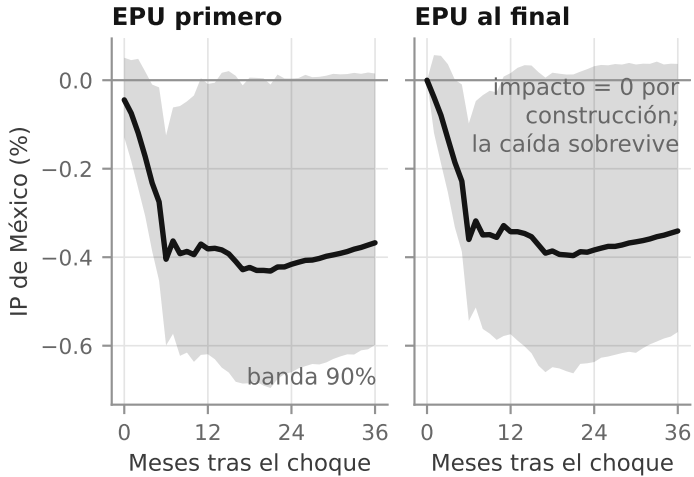
Los dos `fetch` devuelven marcos **largos** (`code, date, variable, value`): filtren `MEX` y la variable, y ordenen por fecha (`oecd_mei` llega desordenado). Sin red: `data_curso/epu_mex_mensual.csv` y `data_curso/oecd_mei_mex_log_ip.csv`.

El resultado de los dos ordenamientos está en la lámina siguiente.

La fragilidad del ordenamiento recursivo atraviesa toda la identificación: ¿qué restricción defenderían y con qué argumento económico?

Refs.: Bloom (2009); Baker, Bloom y Davis (2016); Jurado, Ludvigson y Ng (2015). | Companion notebook: `T05_E_regime_girf` (choques de **condiciones financieras** —ICF simulado y NFCI— dependientes del régimen y GIRFs no lineales).

México: la IP ante un choque de EPU, con los dos ordenamientos

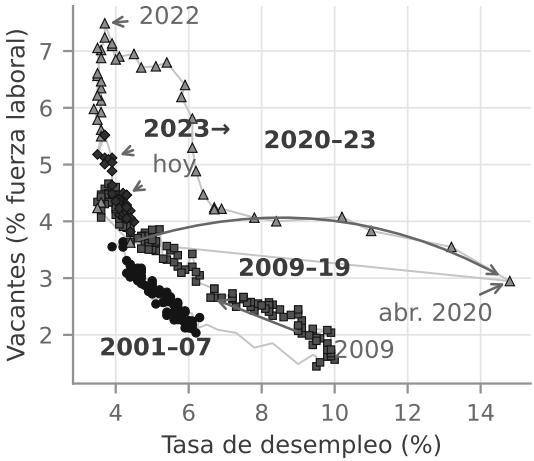


VAR(12) mensual [EPU (z), $100 \cdot \log$ IP], 1996–2019, Cholesky. Con el EPU al final el impacto es cero por construcción, pero la caída de mediano plazo sobrevive.

Tema de cierre: la curva de Beveridge después del COVID

Vacantes (JTSJOL) contra desempleo (UNRATE), con un marcador por episodio: desplazamiento hacia afuera en 2021–22 y descenso casi vertical en 2022–24.

- ¿Choque estructural a la eficiencia del emparejamiento (reasignación, teletrabajo) o movimiento a lo largo de la curva mal medido?
- ¿Qué restricción de exclusión o qué instrumento usarían para identificar un “choque de matching”?



Refs.: Shimer (2005); Elsby, Michaels y Solon (2009); Blanchard, Domash y Summers (2022); Barnichon y Shapiro (2022).

Las técnicas de identificación —SVAR recursivo y de largo plazo, métodos narrativos, proxy-IV y proyecciones locales— permiten establecer la existencia de choques estructurales en los datos. La literatura ha mostrado que anuncios fiscales, compras inesperadas del gobierno o noticias sobre nuevas tecnologías tienen efectos causales sobre las variables endógenas en las que solemos estar interesados los economistas.

Estas técnicas nos dicen qué choques existen y cuánto explican. Pero todos los modelos que hemos escrito hasta aquí suponen un **hogar representativo con mercados completos**, y esa es exactamente la pieza que la evidencia empírica de estas dos semanas no obliga a mantener. La semana que viene rompemos el supuesto: mercados incompletos, ahorro precautorio, la distribución de riqueza de Aiyagari–Huggett y por qué la política monetaria opera por el **ingreso** y no solo por la sustitución intertemporal (**HANK**).

Apéndice

Apéndice: otra forma de rotación

Una forma alternativa de rotar los impactos de largo plazo para hacerlos ortogonales es emplear una matriz de rotación $Q(\psi)$:

$$Q(\psi) = \begin{bmatrix} \cos(\psi) & -\sin(\psi) \\ \sin(\psi) & \cos(\psi) \end{bmatrix},$$

que aplicamos directamente a los efectos a largo plazo de la representación $MA(\infty)$. Posmultiplicamos: $\widetilde{\Theta} = \Theta(1)Q(\psi)$, con los choques rotados $\tilde{\epsilon}_t = Q(\psi)'\epsilon_t$ (así $\Theta(1)\epsilon_t = \widetilde{\Theta}\tilde{\epsilon}_t$ y $\widetilde{\Theta}\widetilde{\Theta}' = \Omega$), donde ψ se elige para que los choques de demanda no tengan efecto a largo plazo sobre el ingreso por hora:

$$\Theta(1)Q(\psi) = \begin{bmatrix} \theta_{ox} & 0 \\ \theta_{oh} & \theta_{dh} \end{bmatrix}.$$

Si $[x_a,\ h_a]$ es la primera fila de $\Theta(1)$, su imagen bajo la rotación es:

$$[x_a,\ h_a]\,Q(\psi) = [\,x_a\cos(\psi) + h_a\sin(\psi),\ \ -x_a\sin(\psi) + h_a\cos(\psi)\,].$$

Imponiendo la restricción sobre el elemento $(1,2)$:

$$-x_a\sin(\psi) + h_a\cos(\psi) = 0 \implies \tan(\psi) = \frac{h_a}{x_a} \implies \psi = \arctan\left(\frac{h_a}{x_a}\right).$$

Apéndice: tabla completa del VAR(3)

En la literatura VAR no suelen mostrarse las estimaciones de la forma reducida (se interpretan sus IRFs y FEVDs). Los únicos coeficientes significativos al 5 % son L1.HRS y L3.HRS en la ecuación de INCPW (-0.123 y -0.115) y L1.INCPW, L1.HRS y L2.HRS en la de HRS (0.391, 0.137 y 0.135): las horas rezagadas predicen negativamente el ingreso por hora, y el ingreso por hora rezagado predice positivamente las horas.

Ecuación INCPW

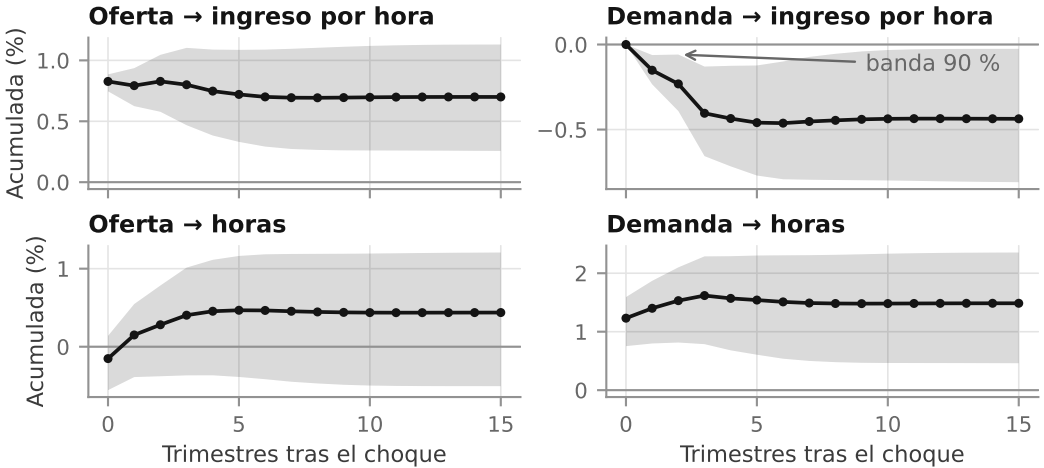
	Coef.	EE	p-valor
const	0.616	0.073	0.000
L1.INCPW	-0.064	0.057	0.261
L1.HRS	-0.123	0.039	0.001
L2.INCPW	0.074	0.058	0.203
L2.HRS	-0.056	0.039	0.151
L3.INCPW	-0.009	0.058	0.881
L3.HRS	-0.115	0.038	0.003

Ecuación HRS

	Coef.	EE	p-valor
const	-0.139	0.110	0.208
L1.INCPW	0.391	0.086	0.000
L1.HRS	0.137	0.058	0.017
L2.INCPW	0.149	0.088	0.089
L2.HRS	0.135	0.059	0.021
L3.INCPW	0.081	0.087	0.349
L3.HRS	0.082	0.058	0.157

Ficha: snapshot `gali1999.csv` de `puremacro` (`data_curso/gali1999.csv`); INCPW $= 100\,\Delta\log$OPHNFB, HRS $= 100\,\Delta\log$HOANBS (horas **totales**); 1948Q2–2026Q1, 312 obs; VAR(3) con constante. Misma estimación que las IRF de la lámina siguiente.

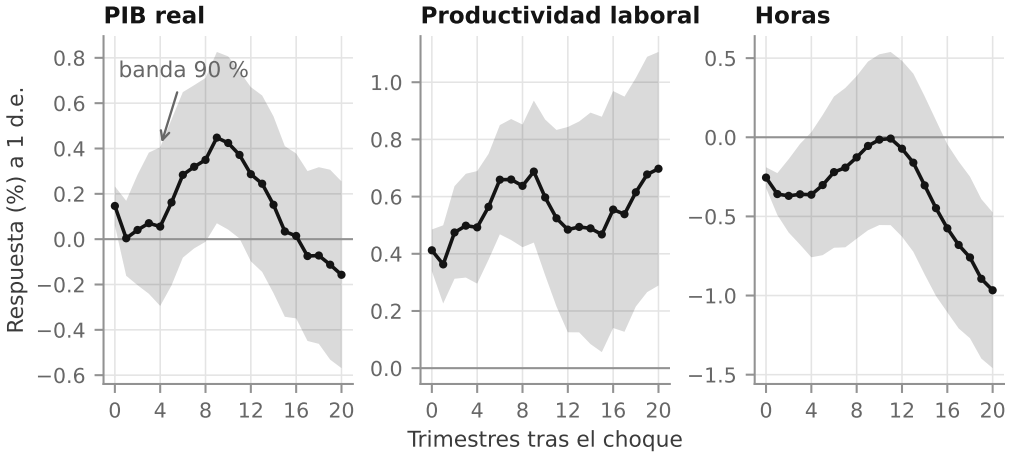
Apéndice: funciones de impulso respuesta acumuladas



Mismo VAR(3) recursivo, con las respuestas acumuladas. Salvedad: la banda al 90 % es la suma acumulada de los percentiles del *bootstrap* —una aproximación, no el percentil de las sumas acumuladas.

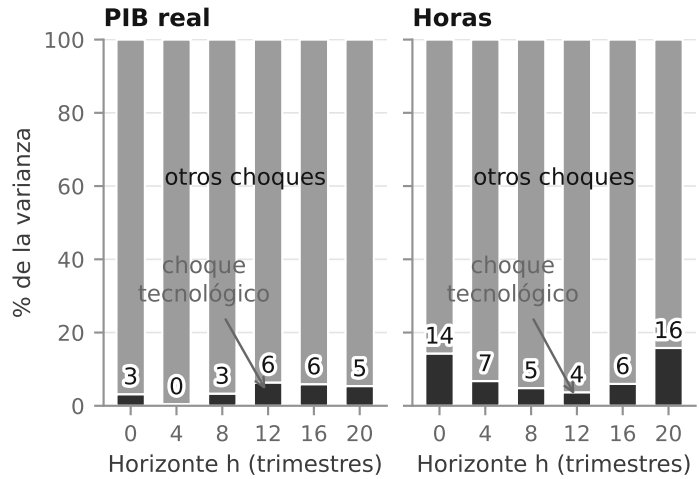
Apéndice: la respuesta al choque tecnológico, por proyección local

Los efectos de los choques tecnológicos estructurales a la productividad también pueden verse con IRFs estimadas por proyección local: una regresión directa de la variable en $t + h$ sobre el choque en t (Jordà 2005).



Apéndice: ¿qué fracción de la varianza del PIB explica el choque tecnológico?

Nota metodológica: la FEVD no sale directamente de una proyección local; la descomposición mostrada usa el enfoque R^2 de Gorodnichenko y Lee (2020, *JBES*).



Apéndice: el modelo VECM

Una forma más natural de introducir choques estructurales es suponer que estos rigen el movimiento a largo plazo de las variables endógenas, lo que puede estudiarse reescribiendo un $VAR(p)$ como un modelo $VECM(p-1)$, restando y_{t-1} en ambos lados y reagrupando términos:

$$\Delta y_t = (A_1 - I)\, y_{t-1} + A_2 y_{t-2} + \cdots + A_p y_{t-p} + u_t.$$

Identidad útil: para $j = 2, \ldots, p$,

$$y_{t-j} = y_{t-1} - \sum_{k=1}^{j-1} \Delta y_{t-k}.$$

Sustituyendo estas identidades se obtiene:

$$\Delta y_t = \underbrace{\left(A_1 + A_2 + \cdots + A_p - I\right)}_{\Pi}\, y_{t-1} \;+\; \sum_{i=1}^{p-1} \underbrace{\left(-\sum_{j=i+1}^{p} A_j\right)}_{\Gamma_i} \Delta y_{t-i} \;+\; u_t.$$

Apéndice: el VECM($p-1$) y el rango de Π

Definición del VECM($p-1$):

$$\Delta y_t = \Pi y_{t-1} + \Gamma_1 \Delta y_{t-1} + \cdots + \Gamma_{p-1} \Delta y_{t-p+1} + u_t.$$

Interpretación de Π:

- $\operatorname{rank}(\Pi) = 0$: no hay cointegración, el modelo es un VAR en diferencias
- $\operatorname{rank}(\Pi) = n$: las variables son estacionarias en niveles
- $0 < \operatorname{rank}(\Pi) < n$: existen r relaciones de cointegración

Factorización de Π:

$$\Pi = \alpha \beta',$$

donde $\beta' y_{t-1}$ son los r vectores de cointegración (equilibrios de largo plazo) y α contiene las velocidades de ajuste hacia esos equilibrios.

Apéndice: VECM(2) estimado sobre los datos de Galí

VECM(2), INCPW $= \log$(ingreso por hora) y HRSPW $= \log$(horas por persona), 1948–2019: cargas α y cointegración β (los rezagos endógenos de corto plazo se reportan aparte)

	Coef.	EE	z	p-valor
(A) Coeficientes de carga α				
ec1 $\rightarrow$ INCPW	-0.0016^{***}	0.000	-7.897	0.000
ec1 $\rightarrow$ HRSPW	0.0006^{***}	0.000	3.465	0.001
(B) Relación de cointegración β (normalizada en INCPW)				
β_1 (INCPW)	1.0000	0.000	0.000	0.000
β_2 (HRSPW)	-10.7302^{*}	5.320	-2.017	0.044
Constante	-90.7069^{*}	41.541	-2.184	0.029

Apéndice: el 15.49 del pretest y el caso determinista

El valor crítico 15.49 de la traza de Johansen es el del caso con constante **no** restringida (Caso III de MacKinnon–Haug–Michelis), y contra él la traza de x_t y h_t es 16.48: se rechaza $r = 0$ al 5 % por muy poco.

La selección de $r = 1$ es, sin embargo, robusta al caso determinista: con la constante restringida dentro de la relación de cointegración (Caso II), la traza es 81.93 contra un valor crítico de 20.26.

Moraleja de método: cuando un titular cuelga de un pretest que rechaza por décimas, hay que reportar el pretest bajo los casos deterministas alternativos, no solo el que resultó favorable.

Apéndice: lectura mecánica de los signos del VECM

Leamos los signos mecánicamente. El término de corrección de error es

$$ec_t = \text{INCPW}_t - 10.73 \cdot \text{HRSPW}_t - 90.71,$$

de modo que $ec_t > 0$ significa productividad **por encima** de su relación de largo plazo con las horas, y $\Delta y_t = \alpha\, ec_{t-1} + \dots$

- $\alpha_1 = -1.6 \times 10^{-3} < 0$: si la productividad está por encima ($ec > 0$), $\Delta\text{INCPW} = \alpha_1 ec < 0$ y el ingreso por hora baja hacia la relación; si está por debajo, sube. La corrección es estabilizadora
- $\alpha_2 = +6 \times 10^{-4} > 0$: si $ec > 0$, las horas suben, lo que eleva $10.73 \cdot$ HRSPW y cierra la brecha por el otro lado
- Chequeo de estabilidad: $\beta'\alpha = \alpha_1 - 10.73\,\alpha_2 = -0.008 < 0$, así que $ec_t \approx (1 + \beta'\alpha)\, ec_{t-1}$ converge — muy despacio (vida media ≈ 21 años): es una relación de **muy** largo plazo
- $\beta_2 = -10.73$ con la normalización $\beta_1 = 1$ implica $ec = 0 \iff \text{INCPW} = 10.73 \cdot \text{HRSPW} + 90.71$: una asociación **positiva** (y estimada con poca precisión) entre productividad y horas por persona a largo plazo
- En el corto plazo el ingreso rezagado predice las horas con fuerza (coeficientes positivos y significativos en ambos rezagos); las horas solo afectan al ingreso en el segundo rezago, con signo negativo

Otra alternativa es argumentar que el ingreso sigue una tendencia exógena, como propone el MNC (modelo neoclásico de crecimiento), y que las horas de trabajo por persona están acotadas, por lo que el PGD (proceso generador de datos) debe ser $I(0)$, a pesar de las propiedades de la muestra pequeña. El modelo VECM también permite estudiar la dinámica de sus variables a través de IRFs y descomponer sus varianzas mediante FEVDs.

Apéndice: VECM(2), rezagos endógenos de corto plazo

	Coef.	EE	z	p-valor
Ecuación INCPW				
L1.INCPW	-0.0487	0.057	-0.852	0.394
L1.HRSPW	0.0386	0.069	0.560	0.575
L2.INCPW	0.1140^{*}	0.057	2.012	0.044
L2.HRSPW	-0.3131^{***}	0.069	-4.517	0.000
Ecuación HRSPW				
L1.INCPW	0.1482^{**}	0.049	3.041	0.002
L1.HRSPW	0.6111^{***}	0.059	10.430	0.000
L2.INCPW	0.1503^{**}	0.048	3.111	0.002
L2.HRSPW	0.0087	0.059	0.147	0.883

Apéndice — Cochrane (1994): un cero de impacto que equivale a uno de largo plazo

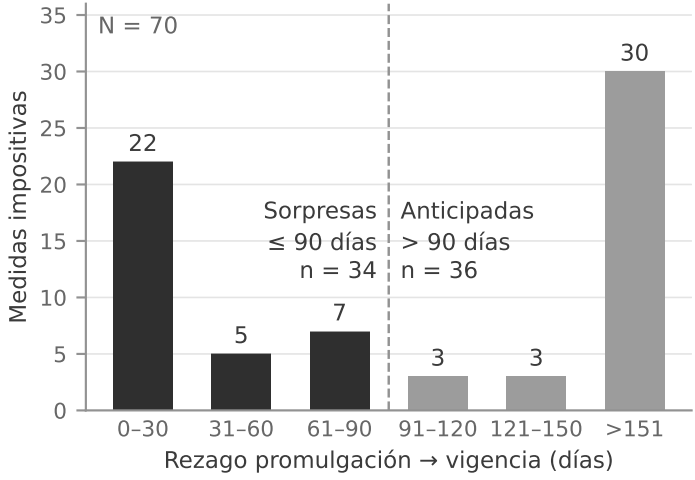
La teoría del ingreso permanente ofrece otra restricción bivariada sobre consumo e ingreso:

$$\begin{pmatrix} u_t^{\Delta c} \\ u_t^{\Delta y} \end{pmatrix} = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix} \begin{pmatrix} \epsilon_t^{permanente} \\ \epsilon_t^{transitorio} \end{pmatrix}$$

- La matriz mostrada es, tal cual, una restricción de **corto plazo**: el cero en $(1, 2)$ dice que el choque transitorio no mueve el consumo **en impacto**
- El puente con la teoría: como el consumo es (casi) un paseo aleatorio, lo que no lo mueve en impacto no lo mueve **a ningún horizonte** — el cero de impacto hereda la interpretación de largo plazo
- Es el ejemplo perfecto para distinguir ambos tipos de restricción: aquí coinciden por una propiedad **económica** del consumo, no por la mecánica del SVAR

Apéndice: Mertens & Ravn (2012)

El rezago entre la aprobación legislativa y la implementación permite separar choques fiscales **anticipados** de **sorpresas**:



Apéndice: choques a los impuestos

Destaca el trabajo de Romer & Romer (2010), que emplea un enfoque narrativo, extrayendo información de los discursos presidenciales y reportes del Congreso para obtener una serie de choques fiscales, en particular aquellos que se financian con déficit frente a los que tienen como motivación el crecimiento económico. Del enfoque narrativo surgen dos líneas de investigación:

- Mertens & Ravn (2011, 2012) usan el enfoque narrativo y el rezago que hay entre legislación y ejecución para distinguir entre choques fiscales esperados y sorpresas

- Mertens & Ravn (2013, AER) desarrollan el método proxy-SVAR para usar los choques obtenidos con el enfoque narrativo como instrumento; Mertens & Ravn (2014, JME) reconcilian con él las estimaciones SVAR y narrativas del multiplicador impositivo

Apéndice: estimaciones del multiplicador impositivo

Los impuestos suelen tener multiplicadores negativos.

Estudio	Muestra principal	Identificación	Multiplicador implícito
Evans (1969)	Trimestral, 1966–1974	Con base en ecuaciones estimadas de los modelos Wharton, Klein–Goldberger y Brookings	-0.5 a -1.7, según horizonte, tipo de impuesto y modelo
Blanchard–Perotti (2002)	Trimestral, 1960–1997	Elasticidades de producto supuestas en un SVAR; los “impuestos” son en realidad impuestos netos de transferencias	-0.78 a -1.33 (pico a impacto)
Mountford–Uhlig (2009)	Trimestral, 1955–2000	Restricciones de signo sobre un VAR; mismas variables que BP	-5 para un aumento impositivo que reduce el déficit
Romer–Romer (2010)	Trimestral, 1947–2007	Cambios impositivos legislados por déficit heredado o para promover crecimiento futuro (narrativa)	-3, con base en el efecto pico; Romer–Romer (2009) muestran que casi no elevan el gasto, por lo que se acercan a choques impositivos puros
Barro–Redlick (2011)	Anual, 1917–2006 y submuestras	Tasa marginal promedio del impuesto sobre la renta	-1.1
Favero y Giavazzi (2012)	Trimestral, 1950–2006	Choques de Romer–Romer incrustados en un SVAR	-0.5
Caldara y Kamps (2012)	Trimestral, 1947–2006	SVAR con elasticidades externas	-0.65 (pico a impacto)
Mertens–Ravn (2014)	Trimestral, 1950–2006	Proxy-SVAR con choques no anticipados de Romer–Romer	-3 a 6 trimestres

Fuente: Ramey (2016), *Macroeconomic Shocks and Their Propagation*, Handbook of Macroeconomics, vol. 2A, cuadro 6.

Apéndice: la curva de especificaciones

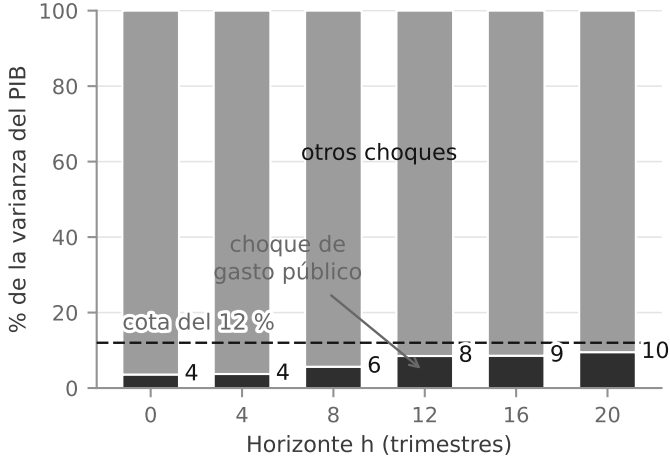
La fragilidad del ordenamiento, llevada al extremo con **otro** choque: una demostración en clase estima **seis esquemas de identificación** de un choque de incertidumbre (EPU $\rightarrow$ producción industrial) sobre un dataset mensual congelado y muestra el abanico completo de IRFs resultante.

- La “spec curve” no es un ejercicio fiscal: es una vacuna general contra el p-hacking de identificación
- Pregunta de debate: si seis identificaciones defendibles dan respuestas distintas, ¿qué debe reportar un artículo honesto?

Apéndice: FEVD del gasto público

Los choques al gasto del gobierno explican menos del 12 % de la varianza del PIB.

Nota metodológica: la FEVD no sale directamente de una proyección local; la descomposición mostrada usa el enfoque R^2 de Gorodnichenko y Lee (2020, *JBES*).



Apéndice: el mismo panel como *event study* — los *leads* convierten la crítica en hipótesis contrastable

Las consolidaciones de Devries et al. son "tratamientos" fechados en un panel, así que admiten una especificación de **diferencias en diferencias** con efectos fijos de dos vías (TWFE):

$$y_{i,t} = \alpha_i + \delta_t + \sum_{k=-2}^{4} \beta_k \, D_{i,t-k} + \varepsilon_{i,t}, \qquad D_{i,t} = 1 \text{ si } i \text{ anuncia consolidación en } t.$$

- α_i absorbe los niveles medios de cada país; δ_t absorbe lo común a los 17 en ese año (crisis globales, ciclo mundial, precios de materias primas). Lo que **no** absorbe, porque es nacional, es la respuesta del banco central propio y el financiamiento del ajuste. El supuesto es **tendencias paralelas**
- Los *leads* β_{-1}, β_{-2} son la prueba de **pre-tendencias**: si son distintos de cero, la consolidación es predecible por el ciclo — la crítica de Jordà–Taylor, ahora contrastable
- Frente a la LP de panel, que trata la consolidación como choque continuo (% del PIB) y estima un β_h por horizonte con errores Driscoll–Kraay, el TWFE usa tratamiento discreto y trae de fábrica ese diagnóstico de exogeneidad
- Salvedad moderna: con tratamientos escalonados y efectos heterogéneos, el coeficiente TWFE mezcla comparaciones "prohibidas" (de Chaisemartin y D'Haultfœuille 2020; Goodman-Bacon 2021). Si ambas versiones difieren, la pregunta es **qué supuesto** falla, no qué estimador "ganó"

Refs.: de Chaisemartin y D'Haultfœuille (2020); Goodman-Bacon (2021); Jordà y Taylor (2016).

Apéndice: el código base del entregable de austeridad

Es la misma receta que produce el -1.42, y corre **sin red**: los dos snapshots del examen (consolidaciones de Devries et al. y PIB real de la OCDE QNA) se leen de la carpeta `./data/` (en el repositorio del curso, los mismos dos archivos están en `data_curso/`). Frecuencia **anual** —la del dataset y la de Guajardo–Leigh–Pescatori— y ventana 1978–2019: panel muy desbalanceado, 518 obs de 714 posibles, porque el PIB de casi todos los europeos empieza hacia 1995.

```
import pandas as pd
from puremacro.lp.panel_dk import panel_lp_dk
from puremacro.lp.jorda import lp_hac

# Los DOS csv del examen (Canvas -> ./data/): nada de red, nada de fetch
cons = pd.read_csv('data/dglp_consolidaciones_trimestrales.csv',
                   parse_dates=['date'])  # code, date, x (% del PIB)
qna  = pd.read_csv('data/oecd_qna_dglp17.csv',
                   parse_dates=['date'])  # code, date, variable, value
# x: suma ANUAL del x trimestral; y: 100*log_gdp_real, promedio anual
# ancho: MultiIndex (code, date) con columnas y, x

res = panel_lp_dk(ancho, y='y', x='x', horizons=range(0, 6), n_lags=2)
#   h = 2: beta = -1.42   (banda 90%: -2.10 a -0.74)
irf = lp_hac(sub, 'y', 'x', horizons=[2], n_lags=2)  # forest por pais
```

Dos avisos. (i) En trimestral el $1\,\%$ se reparte en 0.25 por trimestre durante episodios multianuales y el β por unidad se infla: si su número no se parece al -1.42, revisen primero la frecuencia. (ii) El módulo 09 del curso **simula** un panel con la misma estructura, así que sus cifras no tienen por qué coincidir con las de aquí.

Apéndice: otros choques de importancia

La literatura ha empezado a considerar recientemente dos candidatos a choques estructurales:

- Choques de incertidumbre de segundo momento, con tratamiento moderno por parte de Bloom (2009) —un modelo de volatilidad estocástica, es decir, de riesgo; la incertidumbre *knightiana* en sentido estricto (ambigüedad: no se conoce la distribución, no solo su varianza) es un concepto aparte— y donde la literatura y **los datos** están creciendo rápidamente

- Choques a los mercados laborales como anuncios sobre salarios mínimos o noticias sobre cambios salariales anunciados por grandes empresas, o choques a la eficiencia con la que las vacantes que las empresas publican se emparejan con trabajadores

Apéndice: incertidumbre desde el texto de Banxico

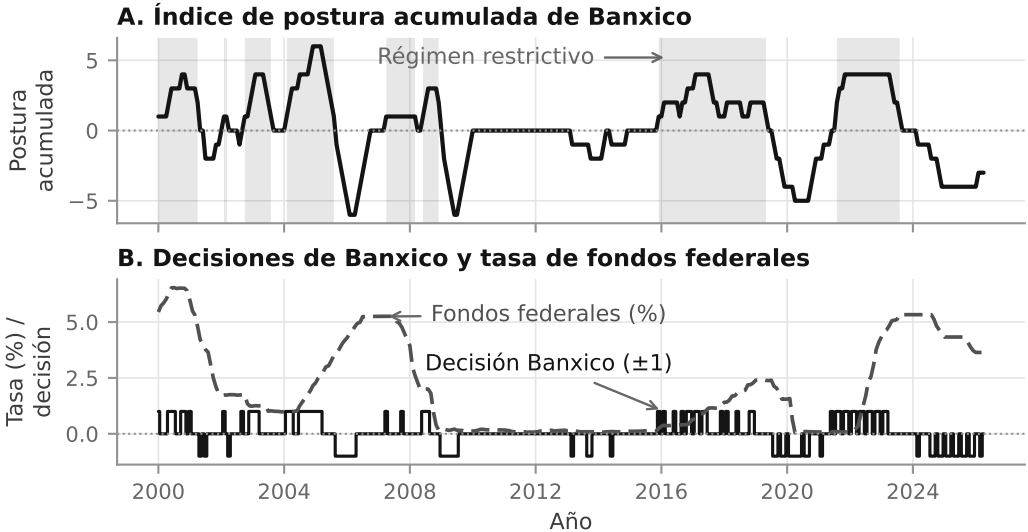
El conector `iter_banxico_decision` entrega los **anuncios de decisiones de política monetaria de Banxico en español** (PDFs del listado oficial), y el paquete trae léxicos LTUI en varios idiomas (es/en/pt/de/fr/it/ja/zh): el corpus se analiza en su idioma original.

```
from puremacro import narrative
from puremacro.narrative.sources import iter_banxico_decision

recs = list(iter_banxico_decision())  # anuncios en espanol (1-2 min)
# list(): el conector es un generador; sin ella ltui_down lo recibe vacio
up   = narrative.ltui_up(recs,  country='MEX', language='es')
down = narrative.ltui_down(recs, country='MEX', language='es')
# indice direccional: riesgo al alza vs. a la baja
```

La lámina siguiente **no** es el LTUI: grafica la postura direccional de los anuncios (`data_curso/banxico_stance_monthly.csv`), es decir, la **suma móvil de 6 meses** de la dirección de cada anuncio (± 1), acotada en ± 6 —el cuaderno la rotula "postura acumulada", pero no es un `cumsum`—. Correr el bloque de arriba sobre el corpus produce otra cosa —los dos índices— y es justo el ejercicio. Lección de fronteras de datos: sigue sin haber medidas de exposición a la IA fuera de EUA; el hueco es real, pero ya no es una excusa lingüística. La figura es la celda 13 del cuaderno `T03_F_narrative_llm_central_banks`; el sombreado marca el régimen restrictivo.

Apéndice: la postura de Banxico, leída de sus anuncios



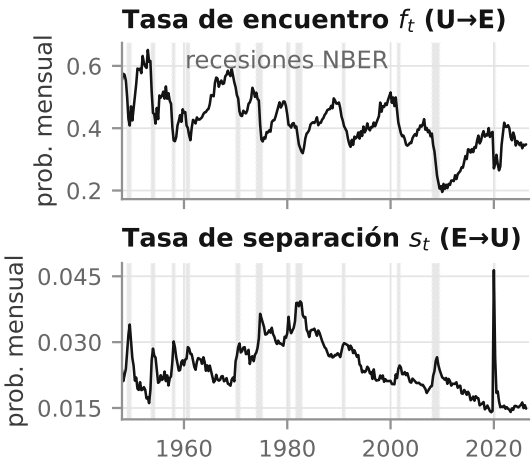
Apéndice: ¿f o s domina en las recesiones?

Los datos de vacantes ya vienen en `puremacro`: `fetch.fetch_jolts` da un panel *tidy* con aperturas, contrataciones, renuncias, despidos y separaciones (nivel y tasa); para una sola serie basta el ID de FRED. Para Europa, `fetch.fetch_eurostat_vacancies`.

```
from puremacro import fetch, labor_flows
jolts = fetch.fetch_jolts()      # [date, industry, element, level, rate]
v  = fetch.fetch_fred('JTSJOL')  # o una serie suelta por ID de FRED
u  = fetch.fetch_fred('UNRATE')  # tasa de desempleo
fs = labor_flows.transitions_from_shimer(u)  # tasas f y s
```

Aviso: `transitions_from_shimer` devuelve $f \approx 0$ en la mayoría de los meses; la figura de la lámina siguiente está estimada con el método de desempleo de corta duración de Shimer (2012), no con esa función.

Apéndice: f cae en las recesiones, s salta al inicio



- ¿Domina la caída de la tasa de encuentro f (Shimer) o el pico de separaciones s (Elsby)?
- Ese es el programa de las fricciones laborales: flujos, emparejamiento y el puzzle de Shimer

Apéndice: el disenso de los pronosticadores sube en recesiones

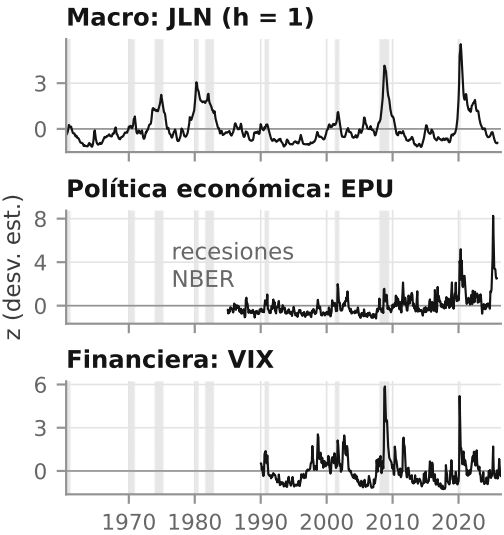
La dispersión entre pronosticadores profesionales (SPF) mide la incertidumbre macroeconómica ex-ante: el desacuerdo entre analistas se dispara en cada recesión.

Canal empírico 1: Desacuerdo en pronósticos (Survey of Professional Forecasters)

- **Métrica**: Desviación estándar o rango intercuartílico (IQR) de los pronósticos a un año para el crecimiento del PIB real, la inflación y el desempleo.
- **Hecho estilizado**: Durante las contracciones (NBER), el disenso entre expertos sube entre un 40 % y 80 % respecto a expansiones normales (Bloom 2009, 2014).
- **Interpretación**: El desacuerdo refleja una combinación de heterogeneidad de modelos, información imperfecta y mayor varianza en los choques fundamentales agregados.

Refs.: Bloom (2009, 2014); Jurado, Ludvigson y Ng (2015); Baker, Bloom y Davis (2016).

Apéndice: los tres termómetros de incertidumbre en el ciclo



La incertidumbre en la prensa (EPU) y los mercados financieros (VIX) co-mueven fuertemente con la incertidumbre macroeconómica real (JLN):

- **EPU (Baker, Bloom y Davis 2016)**: Conteos textuales normalizados en prensa sobre economía, política y regulación.
- **Co-movimiento**: En 2008 y 2020 los tres indicadores saltan coordinadamente; en eventos políticos puntuales (elecciones, Brexit), el EPU sube sin alterar la incertidumbre macroeconómica real (JLN).

(Jurado, Ludvigson y Ng 2015; Baker, Bloom y Davis 2016; Bloom 2014)

Apéndice: la incertidumbre microeconómica y opciones reales

En las recesiones no solo sube la incertidumbre agregada: la dispersión microeconómica entre empresas (crecimiento de ventas, empleo, productividad) se duplica.

Canal microeconómico: Dispersión entre empresas y opciones reales (Bloom 2009)

- **Evidencia micro (Compustat / Censos)**: El rango intercuartílico del crecimiento de ventas entre empresas pasa de $\sim$15 % en expansiones a más de 30 % durante recesiones profundas.
- **Mecanismo de opciones reales**: Cuando el capital y el empleo enfrentan costos de ajuste cuasi-fijos o irreversibilidades parciales, un aumento en la volatilidad incrementa el valor de la opción de esperar (*wait-and-see*).
- **Efecto macro**: La contratación de empleo y la inversión fija se congelan de inmediato; la recuperación posterior exhibe un rebote cuando la incertidumbre se disipa.

Este mecanismo microeconómico fundamenta la identificación estructural de choques de incertidumbre en SVARs y proyecciones locales (Bloom 2009; Fernández-Villaverde et al. 2015).

Refs.: Bloom (2009, *The Impact of Uncertainty Shocks*, Econometrica); Bloom (2014, JEP).